Implementando a estrutura de uma Rede Neural Convolucional utilizando o MapReduce do Spark

A classificação de imagens é uma tarefa na qual dada uma figura é obtido uma saída que representa sua classe (rótulo) ou a probabilidade das classes que descrevem a figura. Neste documento é apresentado um exemplo de problema que pode ser tratado por meio de Redes Neurais Convolucionais sendo implementado utilizando a técnica de MapReduce do Spark.

Rede Neural Convolucional

A Rede Neural Convolucional (do inglês *Convolutional Neural Network* - CNN) vem ganhando destaque na classificação de imagens. A **Figura 1** apresenta um exemplo de arquitetura de CNN.

Figura 1: Exemplo de topologia da Rede Neural Convolucional.

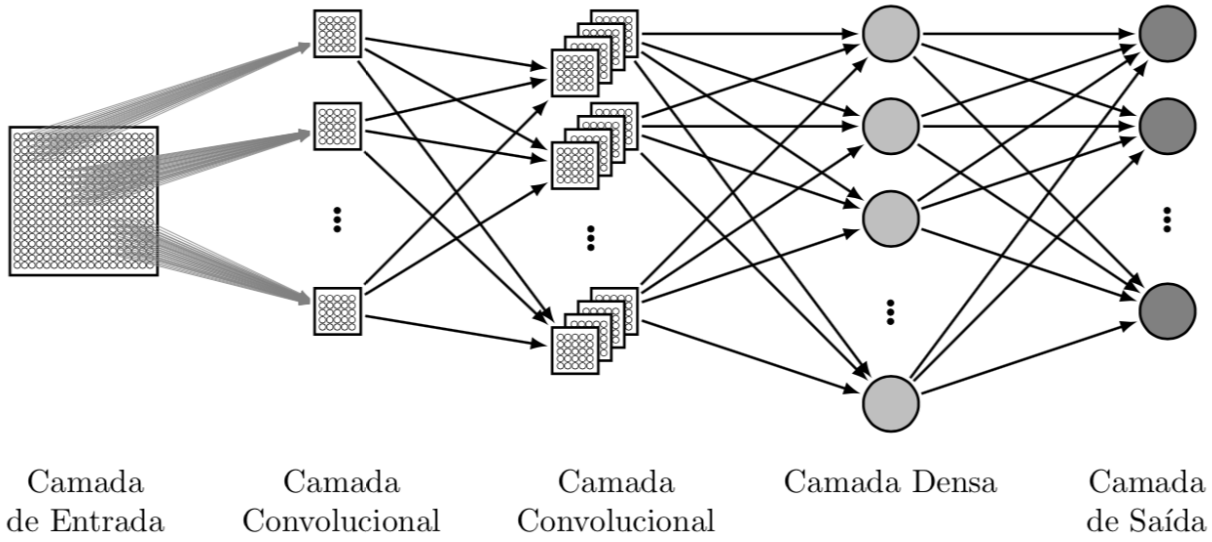

O diferencial das CNNs está nas diversas camadas convolucionais, que aplica uma função matemática de Convolução nos dados de entrada e depois realizando o Agrupamento (*pooling*). A saída da convolução é passada para a próxima camada convolucional até chegar na última camada conhecida como Camada Densa que

normalmente é representada por uma rede *Perceptron* de múltiplas camadas (do inglês *Multilayer Perceptron* - MLP).

Conjunto de dados de treino

A biblioteca *scikit-learn* possui internamente um conjunto de dados composto por 1.797 exemplos de imagens de dígitos 0 à 9.

Neste conjunto de dados estão disponíveis os dígitos e sua classe, como apresentado na **Figura 2**. Cada dígito é formado por uma matriz de dimensão de 8 x 8, como mostrado na **Tabela 1**.

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import load_digits

digits = load_digits()

plt.figure(figsize=(20,4))
for index, (image, label) in enumerate(zip(digits.data[0:5], digits.target[0:5])):
  plt.subplot(1, 5, index + 1)
  plt.imshow(np.reshape(image, (8,8)), cmap=plt.cm.gray)
  plt.title('Training: %i\n' % label, fontsize = 20)
plt.show()
```

Figura 2: Exemplo dos dígitos utilizados no treinamento.

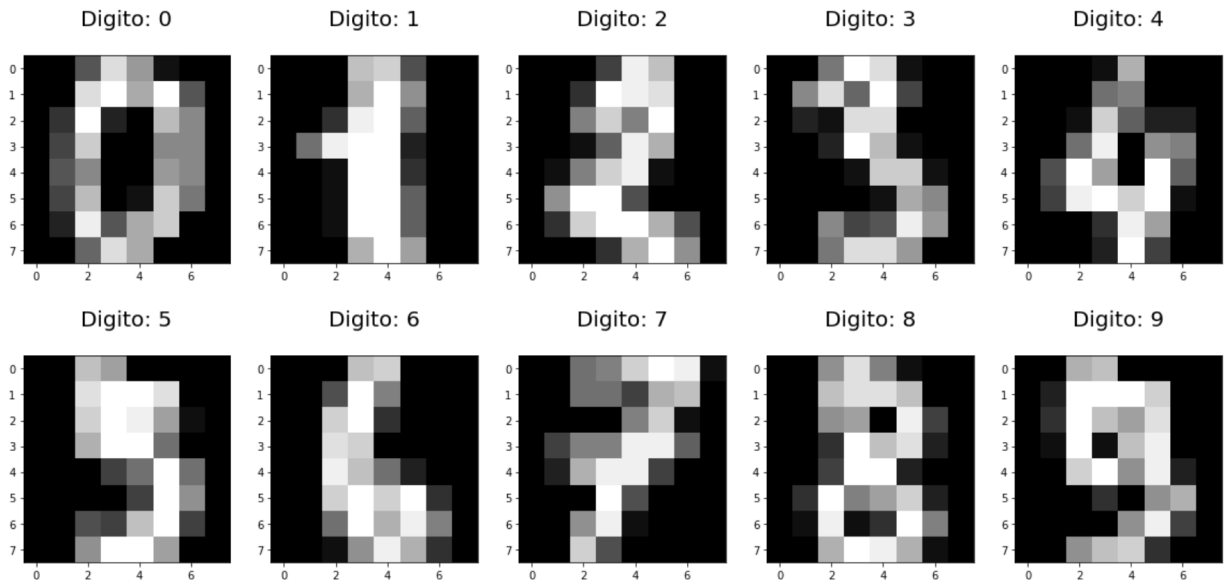

Tabela 1: Matriz de dimensão 8 x 8 com os valores que correspondem ao exemplo de um dígito zero.

```
print(np.reshape(digits.data[0], (8, 8)))
```

0.0	0.0	5.0	13.0	9.0	1.0	0.0	0.0
0.0	0.0	13.0	15.0	10.0	15.0	5.0	0.0
0.0	3.0	15.0	2.0	0.0	11.0	8.0	0.0
0.0	4.0	12.0	0.0	0.0	8.0	8.0	0.0
0.0	5.0	8.0	0.0	0.0	9.0	8.0	0.0
0.0	4.0	11.0	0.0	1.0	12.0	7.0	0.0
0.0	2.0	14.0	5.0	10.0	12.0	0.0	0.0
0.0	0.0	6.0	13.0	10.0	0.0	0.0	0.0

Aplicando Redes Neurais Convolucionais para classificação dos dígitos

Neste exemplo será apresentado o uso da CNN para a partir dos dados do dígitos tentar classificá-lo.

Realizando a convolução

Com base na entrada, por exemplo o digito zero representado na **Figura 3**, pode ser aplicado um mapeamento para gerar diversar partes com tamanho igual ao do *kernel*, como mostrado na **Figura 4**.

```
plt.figure(figsize=(20,4))
for index, (image, label) in enumerate(zip(digits.data[0:1], digits.target[0:5])):
  plt.subplot(1, 1, index + 1)
  plt.imshow(np.reshape(image, (8,8)), cmap=plt.cm.gray)
plt.show()
```

Figura 3: Exemplo do dígito zero.

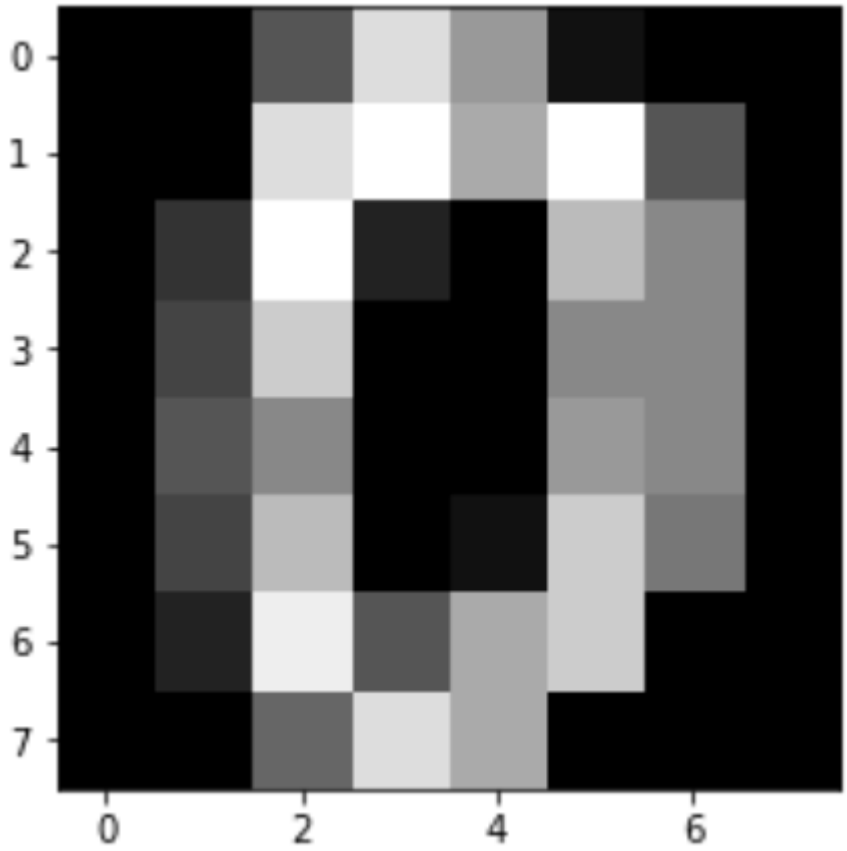


```
plt.figure(figsize=(20, 4))
for index, image in enumerate(partesDigito[0][1]):
  plt.subplot(1, len(partesDigito[0][1]), index + 1)
  plt.imshow(image, cmap=plt.cm.gray)
plt.show()
```

Figura 4: Exemplo de partes que podem ser geradas a partir do dígito zero.

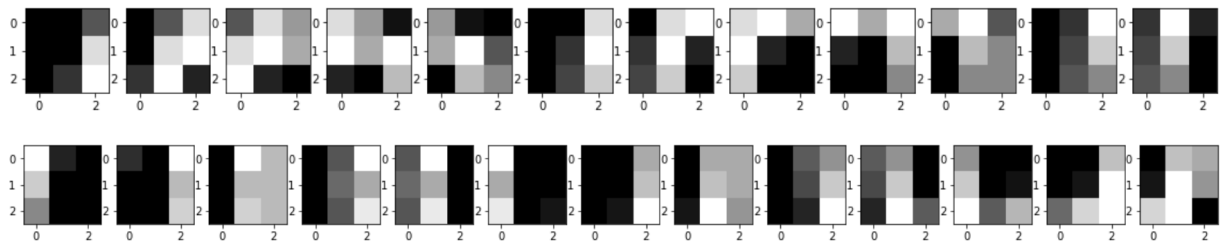

A convolução é aplicada por meio da **Equação 1**.

Equação 1: Equação do calculo da convolução.

$$H(x,y) = \sum_{a=0}^{n-1}\sum_{b=0}^{n-1} E(x-a, y-b)K(a,b)$$

em que dado uma entrada *E* e um *kernel K* de dimensão n x n, é somado o resultado da multiplicação de cada posição do *kernel* por uma área correspondente a partir da posição *x* e *y* da entrada, obtendo como resultado uma resposta de ativação.

```
en = 8 # tamanho da dimensão da entrada
kn = 3 # tamanho da dimensão do kernel
k = 10 # quantidade de kernels
qtdMatrizes = (en - kn) ** 2
kernels = np.random.randn(k, kn, kn)

def partes(x):
    partesDigito = []
    entrada = np.zeros(((en - kn) ** 2, kn, kn))
    X = x.reshape(en, en) # Muda a entrada vetorial para matriz
    for ki in range(0, k): # Para cada kernel separa a entrada em partes
        index = 0;
        for i in range(0, en - kn):
            for j in range(0, en - kn):
                entrada[index] = X[i:i+kn, j:j+kn] # Cada parte é uma submatriz da ent
                index += 1
        partesDigito.append((ki, entrada)) # Para cada kernel gera varias partes da er
    return partesDigito

partesDigito = partes(digits.data[0])
print(partesDigito[0])
```

Saída:

```
(0, array([[[  0.,   0.,   5.],
        [  0.,   0.,  13.],
        [  0.,   3.,  15.]],

       [[  0.,   5.,  13.],
        [  0.,  13.,  15.],
        [  3.,  15.,   2.]],

       [[  5.,  13.,   9.],
        [ 13.,  15.,  10.],
        [ 15.,   2.,   0.]],

       [[ 13.,   9.,   1.],
        [ 15.,  10.,  15.],
        [  2.,   0.,  11.]],
```

```
...
```

Após aplicar o *kernel* em toda área da matriz de entrada, o resultado obtido é um mapa com todas as ativações.

```
import math

def sigmoid(x):
  return 1 / (1 + math.exp(-x))

# t representa a dimensão de um mapa de ativação
t = en - kn + 1

# Aplica a função de ativação no resultado da multiplicação do kernel pela entrada
# Recebe como entrada o kernel e uma matriz com as partes da entrada
def ativacao(k, x):
    mapa = np.zeros((t, t)) #Mapa de ativações de um kernel vazio
    for i in range(0, len(x) - 1): #Para cada parte da matriz da entrada
        mapa[int(i/t)][i%t] = sigmoid((x[i] * k).sum())
    return mapa

print("Mapa de ativações de um kernel")
print(ativacao(kernels[0], partesDigito[0][1]))
```

Saída:

```
Mapa de ativações de um kernel
[[ 0.99998564  0.99999983  0.99999518  1.          1.          0.99999839]
 [ 1.          0.99999999  1.          1.          0.99999951  0.99999995]
 [ 0.99991458  0.99997446  1.          0.99999991  0.99999982  0.98463398]
 [ 0.99995649  0.99999999  0.99999987  1.          0.99908467  0.99998074]
 [ 0.          0.          0.          0.          0.          0.        ]
 [ 0.          0.          0.          0.          0.          0.        ]]
```

A **Figura 5** apresenta um exemplo visual do que poderia ser a representação visual de um mapa de ativações a partir de dez *kernels*.

```
mapas = np.zeros((k, t, t))

for i in range(0, k):
    mapas[i] = ativacao(kernels[partesDigito[i][0]], partesDigito[i][1])

plt.figure(figsize=(20, 4))
for index, image in enumerate(mapas):
  plt.subplot(1, len(mapas), index + 1)
  plt.imshow(image, cmap=plt.cm.gray)
plt.show()
```

Figura 5: Exemplo de mapa de ativações.

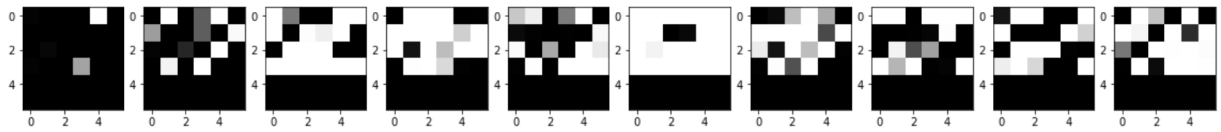

Agrupamento com Max Pooling

Após gerado o mapa de ativações é realizado seu agrupamento, normalmente utilizando a função *Max Pooling*, que agrupa regiões do mapa de ativações mantendo apenas o maior valor de cada região, assim gerando um mapa de ativações mais compacto e mantendo sua principais ativações.

```
pn = 2 # tamanho do pooling
ps = 2 # tamanho do passo do pooling

# Max Pooling
def maxPooling(x):
    agrupado = np.zeros((int(t / pn), int(t / pn)))
    for i in range(0, int(t / pn)):
        for j in range(0, int(t / pn)):
            agrupado[i][j] = x[i * pn : i * pn + kn - 1, j * pn : j * pn + kn - 1].max
    return agrupado

pooling = []
for i in range(0, len(mapas)):
    pooling.append(maxPooling(mapas[i]))

print(pooling[0])
```

Saída:

```
[[ 1.          1.          1.        ]
 [ 0.99999999  1.          0.99999982]
 [ 0.          0.          0.        ]]
```

Camada densa com Multilayer Perceptron

A cada camada convolucional serão gerados mais mapas de ativações, a última camada convolucional passará os mapas para uma MLP que gera como saída a probabilidade de cada dígito entre 0 e 9 dada a entrada inicial da CNN.

```
# weights representa os pesos da camada densa (MLP), aqui ainda falta fazer o backprop
weights = np.random.randn(10, 90)
```

```
# função de ativação RELU
def relu(x):
    return max(0, x)

# Multilayer Perceptron
def mlp(x):
    # A saída é um vetor que será passado para a camada de saída.
    saida = []
    for w in weights:
        saida.append(relu((w * x).sum()))
    return saida

print (mlp(np.asarray(pooling).ravel()))
```

Saída:

```
[0, 0, 0, 4.3701665050961562, 0, 0, 0, 0.60245082809067663, 0, 0, 0.53936137771204695,
```

Camada de saída

A camada de saída aplica a função de ativação softmax para gerar uma distribuição de probabilidades entre 0 e 1 nos valores de saída. A saída é um vetor de 10 valores, cada valor representará a probabilidade de que cada um dos números entre zero e nove, tem de representar o número da figura que será classificada.

```
# weights representa os pesos da camada de saída, aqui ainda falta fazer o backpropaga
weightsOut = np.random.randn(10, 1)

# função de ativação SoftMax
def softmax(x):
    e_x = np.exp(x - np.max(x))
    return e_x / e_x.sum(axis=0)

def out(x):
    # A saída representa a probabilidade de cada número entre zero e nove.
    saida = []
    for i in range(0, len(weightsOut)):
        saida.append((weightsOut[i] * x).sum())
    return softmax(saida)

x = mlp(np.asarray(pooling).ravel())
print(out(x))
```

Saída:

```
[  3.66082504e-252   2.46136020e-096   2.84453882e-197   5.55449523e-273
   2.17623650e-223   2.67780046e-118   8.59637277e-108   1.00000000e+000
   2.25062876e-122   6.18347914e-027]
```

Montando a Rede Neural Convolucional com o MapReduce

A estrutura da CNN é formada por várias camadas que podem ser representadas por meio do mapeamento feito pelo *MapReduce* do Spark.

Uma forma de representar uma CNN usando MapReduce seria:

1. Para cada camada convolucional:
   a) Mapeia a entrada para uma matriz com várias partes de tamanho igual ao *kernel*;
   b) Mapeia cada parte da entrada com o kernel, aplicando a função de ativação e gerando um mapa de ativações;
   c) Aplica o agrupamento em cada mapa de ativações gerando como saída um mapa de ativações com dimensão reduzida;
   d) Junta todos os mapas de ativações, pois serão passados como entrada para a camada seguinte.
2. A saída da última camada convolucional é passada para uma MLP, que:
   a) Mapeia os mapas de ativações para um vetor sequencial;
   b) O vetor sequencial é passado para a camada densa que aplica a função de ativação RELU;
   c) Os dados são passados para a camada de saída que gera as probabilidades representando cada um dos dígitos.

```
sc = SparkContext.getOrCreate()
# Montando um RDD com todo dataset de digitos
rdd = sc.parallelize(digits.data, 4)

# Cria uma matriz com os kernels (filtros) da primeira camada convolucional
kernels1 = np.random.randn(k, kn, kn)

print(rdd
      # 1º convolucao
      .map(lambda x: partes(x)) # Separa as 25 partes da imagem para cada um dos 10 ke
      .map(lambda x: list(map(lambda y: ativacao(kernels1[y[0]], y[1]), x))) # Gera o
      .map(lambda x: list(map(lambda y: maxPooling(y), x))) # Aplica o max pooling na
      # Camada Densa (MLP)
      .map(lambda x: np.asarray(x).ravel()) # Converte a matriz de saída da camada cor
      .map(lambda x: mlp(x)) # Manda os dados da última camada convolucional agrupada
      .map(lambda x: out(x)) # Aplica o softmax e retorna os valores das probabilidade
      .take(1))
```

Saída:

```
[[0.2303787084411721, 0.2099451726892583, 0.06508030989360919,
0.1055256000866959, 0.9971740047740627, 0.09117066280446567,
0.9999356557510007, 1.3844127613072241e-05, 0.8562682290831856,
0.38278995757093703]]
```

A implementação deste exemplo usando Jupyter Notebook está disponível no GitHub.

Conclusão

A estrutura da Rede Neural Convolucional pode ser aplicada utilizando a técnica de MapReduce, tendo como objetivo paralelizar o processo de convolução e agrupamento. Mas é necessário obter os mapas de ativações gerados por todos os *kernels* de uma camada convolucional, antes de seguir adiante, pois estes mapas serão a entrada da camada convolucional seguinte. Também é necessário aguardar todos as convoluções paralelas finalizarem para obter a entrada da MLP e após isso, com sua saída, aplicar a retropropagação para ajustar os pesos.

Implementando a estrutura de uma Rede Neural Convolucional utilizando o MapReduce do Spark was published on December 20, 2017.

YOU MIGHT ALSO ENJOY **(VIEW ALL POSTS)**

- Introdução a classificação de textos
- Regressão Linear Múltipla
- Regressão Linear Simples
