

Dissertação apresentada à Pró-Reitoria de Pós-Graduação e Pesquisa do Instituto Tecnológico de Aeronáutica, como parte dos requisitos para obtenção do título de Mestre em Ciências no Programa de Pós-Graduação em Ciências e Tecnologias Espaciais (PG-CTE), Área de Sistemas Espaciais, Ensaios e Lançamentos.

**André Yoshimi Kusumoto**

**IDENTIFICAÇÃO DE ALVOS EM ENSAIOS DE SEPARAÇÃO  
DE CARGA UTILIZANDO VISÃO COMPUTACIONAL**

**Dissertação aprovada em sua versão final pelos abaixo assinados:**

Prof. Dr. Rogério Pirk  
Orientador

Dr. Nelson Paiva Oliveira Leite  
Coorientador

Prof. Dr. Luiz Carlos Sandoval Góes  
Pró-Reitor de Pós-Graduação e Pesquisa

Campo Montenegro  
São José dos Campos, SP – Brasil  
2015

**Dados Internacionais de Catalogação-na-Publicação (CIP)**  
**Divisão de Informação e Documentação**

Kusumoto, André Yoshimi

Identificação de Alvos em Ensaios de Separação de Carga utilizando Visão Computacional / André Yoshimi Kusumoto.

São José dos Campos, 2015.

107f.

Dissertação de mestrado – Curso de Ciências e Tecnologias Espaciais, Área de Sistemas Espaciais, Ensaios e Lançamentos – Instituto Tecnológico de Aeronáutica, 2015. Orientador: Prof. Dr. Rogério Pirk. Coorientador: Dr. Nelson Paiva Oliveira Leite

1. Visão por computadores. 2. Reconhecimento de alvo. 3. Separação de cargas externas. 4. Processamento de imagens. 5. Ensaios em voo. 6. Engenharia eletrônica. I. Instituto Tecnológico de Aeronáutica.

## **REFERÊNCIA BIBLIOGRÁFICA**

KUSUMOTO, André Yoshimi. **Identificação de Alvos em Ensaios de Separação de Carga utilizando Visão Computacional**. 2015. 107f. Dissertação de mestrado em Sistemas Espaciais, Ensaios e Lançamentos – Instituto Tecnológico de Aeronáutica, São José dos Campos.

## **CESSÃO DE DIREITOS**

NOME DO AUTOR: André Yoshimi Kusumoto

TÍTULO DO TRABALHO: Identificação de Alvos em Ensaios de Separação de Carga utilizando Visão Computacional

TIPO DO TRABALHO/ANO: Dissertação / 2015

É concedida ao Instituto Tecnológico de Aeronáutica permissão para reproduzir cópias desta dissertação e para emprestar ou vender cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte desta dissertação ou tese pode ser reproduzida sem a sua autorização (do autor).

---

André Yoshimi Kusumoto  
Rua Francisca Maria de Jesus, nº68 - aptº 202  
Floradas de São José  
12.230-083 - São José dos Campos - SP

**IDENTIFICAÇÃO DE ALVOS EM ENSAIOS DE  
SEPARAÇÃO DE CARGA UTILIZANDO VISÃO  
COMPUTACIONAL**

**André Yoshimi Kusumoto**

Composição da Banca Examinadora:

Prof. Dr.	Carlos d'Andrade Souto	Presidente	- ITA
Prof. Dr.	Rogério Pirk	Orientador	- ITA
Dr.	Nelson Paiva Oliveira Leite	Coorientador	- ITA/IPEV
Prof. Dr.	Carlos Henrique Netto Lahoz	Membro Interno	- ITA
Dr.	Alexandre de Barros Barreto	Membro Externo	- ICEA

**ITA**

Dedico este trabalho de maneira especial à minha família que,  
com paciência, compreensão e amor,  
me apoiaram em todos os momentos.

## Agradecimentos

À Deus pela minha existência.

Aos meus pais pelo dom da vida e pelo sacrifício que fizeram um dia, em deixar tudo para trás, para poder oferecer uma educação adequada aos seus filhos. Vocês são exemplos para mim.

À minha esposa, Nayla, por estar sempre ao meu lado em todos os momentos de alegria e de dificuldades. Sinônimo de compreensão e sabedoria.

Aos meus filhos, Ana Clara e Henrique, que me inspiram a cada dia e são a razão dos meus esforços.

Ao meu irmão, Dr. Anderson, pelo auxílio no entendimento das capacidades da visão humana.

Ao Prof. Rogério Pirk, que desde a minha entrada no programa, mesmo estando longe em alguns momentos, me apoiou e me orientou em todo o processo.

Ao Dr. Nelson Paiva Oliveira Leite, que me deu a oportunidade de participar deste projeto e por me orientar com sua forma cativante.

Aos amigos do IPEV, em especial, ao Luiz Eduardo Guarino de Vasconcelos, afilhado e companheiro de estudos e pesquisa. Ao Jorge Tadano pela amizade, apoio e compreensão em todos os momentos. Aos colegas Lucas, Ivana, Matheus, Dias, Marco Aurélio, Bruno Giordano, Zanetti e todos da CTI pelo apoio em vários momentos deste trabalho. Ao SO Costa, 2S Lopes, 2S Renan, 2S Thiago, 3S Thiago, 3S Cesar e Antônio Euctímio pelo apoio nos ensaios de separação em solo.

Aos amigos Fernando Mauro de Souza, Paulo Roberto do Nascimento Travassos e Elcio Hideiti Shiguemori pelas orientações e pela amizade.

À FINEP, responsável pelo suporte financeiro em algumas atividades realizadas durante o desenvolvimento deste trabalho.

*"É necessário fazer outras perguntas, ir atrás das indagações que produzem o novo saber, observar com outros olhares através da história pessoal e coletiva, evitando a empáfia daqueles e daquelas que supõem já estar de posse do conhecimento e da certeza".*

(Mário Sergio Cortella)

## Resumo

O presente trabalho apresenta a aplicação de técnicas de visão computacional na identificação de alvos (i.e. marcações) na superfície de cargas em campanhas de ensaios de separação de cargas externas. A identificação dos alvos na superfície da carga alijada é o primeiro passo para o seu rastreamento e consequentemente, para a análise de sua trajetografia. Foram utilizados os atributos Haar-like e MB-LBP para composição dos classificadores que realizaram a identificação dos alvos nas imagens capturadas em alta resolução (i.e. 720p ou mais) e em alta velocidade (i.e. 200 quadros por segundo ou mais). Em ambos os casos, foi necessária a realização de duas etapas, a saber: treinamento dos classificadores e identificação dos alvos na imagem. Como premissa básica, todas as ferramentas utilizadas foram de livre acesso e, portanto, não possuem restrições de uso. As bibliotecas do OpenCV foram utilizadas para a manipulação das imagens e para a aplicação das técnicas escolhidas. Para a validação da ferramenta desenvolvida, foram analisadas sequências de imagens de um voo de ensaio de separação de carga capturadas em uma campanha de desenvolvimento de uma bomba guiada a laser e de ensaios de separação em solo realizadas no IPEV. O tempo de execução do processo de identificação dos alvos em um computador portátil foi comparado ao tempo de execução do mesmo processo em um dispositivo que pode ser embarcado na aeronave, com a finalidade de se verificar o desempenho da ferramenta. Os resultados obtidos nos experimentos se mostraram satisfatórios e puderam comprovar a aplicação das técnicas na identificação dos alvos em ensaios de separação de carga.

## Abstract

The present study presents the application of computer vision techniques to identify track targets (i.e. reference points) on the store surface in external stores separation testing campaigns. The targets identification on the surface of released store is the first step in their tracking and thus, to its trajectory analysis. The Haar-like and MB-LBP attributes were used to compose the set of classifiers which is used by targets identification process in images captured at high resolution (i.e. 720p or more) and high speed (i.e. 200 frames per second or more). In both cases, two steps are required: classifiers training and targets identification in the image. As a requirement, all tools used were open access and therefore have no use restrictions. The OpenCV libraries were used for the images manipulation and the techniques application selected. To validate the developed tool, images sequences captured of store separation flight tests in laser-guided bomb development and store separation of ground tests carried by IPEV were analyzed. To verify the tool performance, the running time of targets identification process in a laptop computer was compared to the same process on a device that can be embedded in the aircraft. The results achieved in the experiments were satisfactory and could demonstrate the techniques application the targets identification in store separation tests.

## Lista de Figuras

FIGURA 1.1 - Sequência de fotos de um acidente ocorrido durante um voo de ensaio de separação de cargas externas (LEITE, VASCONCELOS e KUSUMOTO, 2013).....	19
FIGURA 1.2 - Instrumentação de Ensaio.....	21
FIGURA 1.3 - Casulo Fotográfico (LEITE, VASCONCELOS e KUSUMOTO, 2013).....	22
FIGURA 2.1 - Processo de Ensaios em Voo (VIANA, 2011) .....	28
FIGURA 2.2 - Ensaio de Separação em Solo.....	32
FIGURA 2.3 - Estrutura da Aquisição de Dados (SOUSA, 2005).....	33
FIGURA 2.4 - Figura sem retoques transmitida por cabo submarino de Londres a Nova Iorque em 1929. Na imagem os Generais Pershing e Foch (GONZALEZ e WOODS, 2010).....	35
FIGURA 2.5 - Representação de uma imagem digital (GONZALEZ e WOODS, 2010) .....	36
FIGURA 2.6 - Três tipos de processos computacionais (GONZALEZ e WOODS, 2010) ....	37
FIGURA 2.7 – Três grandes áreas da Computação Gráfica (CONCI, AZEVEDO e LETA, 2008).....	38
FIGURA 2.8 – Corte com os principais elementos do olho humano (CONCI, AZEVEDO e LETA, 2008).....	40
FIGURA 2.9 – Variações de foco no globo ocular .....	41
FIGURA 2.10 - Representação gráfica do olho focalizando uma árvore (GONZALEZ e WOODS, 2010) .....	42
FIGURA 2.11 - <i>Global Shutter</i> (a) e <i>Rolling Shutter</i> (b) (WILLIS e LANGER, 2014).....	44
FIGURA 2.12 – Categorias para geração do conjunto de amostras positivas (HUMMEL, <i>et al.</i> , 2014).....	47
FIGURA 2.13 – Exemplos de atributos simples (VIOLA e JONES, 2001) .....	49

FIGURA 2.14 – Exemplo para cálculo de área para uma Imagem Integral (VIOLA e JONES, 2001).....	49
FIGURA 2.15 – Exemplo de cálculo do valor de TU (OJALA, PIETIKAINEN e HARWOOD, 1996).....	51
FIGURA 2.16 – Representação MB-LBP 9 por 9 pixels .....	51
FIGURA 3.1 – Etapas de Treinamento e Identificação do processo de identificação de alvos	55
FIGURA 3.2 - Exemplos de amostras positivas em imagens de alvos. ....	55
FIGURA 3.3 – Processo de Treinamento .....	56
FIGURA 3.4 – Exemplo de arquivo de configuração de amostras positivas .....	57
FIGURA 3.5 – Exemplo de amostras negativas.....	57
FIGURA 3.6 – Exemplo de arquivo de configuração de amostras negativas. ....	57
FIGURA 3.7 – Configuração do armamento na aeronave plataforma A-1 (DEPARTAMENTO DE CIÊNCIA E TECNOLOGIA AEROESPACIAL, 2012) .....	59
FIGURA 3.8 - Câmera MotionBLITZ EoSens® Cube7 da Mikrotron (MIKROTRON, 2012) .....	59
FIGURA 3.9 – Quadros 4, 53, 75 e 98 do vídeo analisado .....	60
FIGURA 3.10 - Exemplos de amostras positivas utilizadas no processo de treinamento .....	61
FIGURA 3.11 – Extrato do arquivo de configuração de amostras positivas .....	62
FIGURA 3.12 - Exemplos de amostras negativas utilizadas no processo de treinamento.....	63
FIGURA 3.13 - Extrato do arquivo de configuração de amostras negativas .....	64
FIGURA 3.14 - Gráfico comparativo entre o tempo de treinamento dos atributos Haar-like e LBP.....	66
FIGURA 3.15 - a) Quadro original, b) quadro em escala de cinza e c) após equalização do histograma .....	67

FIGURA 3.16 - Resultado do processo de identificação utilizando os atributos Haar-like (a) e LBP (b) - Quadro n° 1 (KUSUMOTO, <i>et al.</i> , 2014).....	67
FIGURA 3.17 - Resultado do processo de identificação utilizando os atributos a) Haar-like e b) LBP - Quadro n° 74 (KUSUMOTO, <i>et al.</i> , 2014).....	68
FIGURA 3.18 - Montagem final do dispositivo de ensaio de separação em solo.....	71
FIGURA 3.19 - Marcações (i.e. adesivos) usados na superfície da carga .....	71
FIGURA 3.20 - Instalação da carga no pilone .....	72
FIGURA 3.21 - Casulo fotográfico e carga instalados sob a asa do AT-26 Xavante .....	72
FIGURA 3.22 - Sequência de imagens do ensaio de separação em solo capturadas pela câmera frontal. Alvos nas cores preto/amarelo e preto/branco. ....	74
FIGURA 3.23 - Sequência de imagens do ensaio de separação em solo capturadas pela câmera traseira. Alvos nas cores preto/amarelo e preto/branco. ....	75
FIGURA 3.24 - Exemplos de amostras positivas utilizadas no experimento de ensaio de separação em solo.....	77
FIGURA 3.25 - Exemplos de amostras negativas utilizadas no experimento de ensaio de separação em solo.....	77
FIGURA 3.26 - Gráfico de comparação entre o tempo de treinamento no primeiro e no segundo experimento. ....	78
FIGURA 3.27 – ROI aplicada aos quadros na análise da câmera frontal .....	79
FIGURA 3.28 - ROI aplicada aos quadros na análise da câmera traseira.....	80
FIGURA 3.29 - Alvos identificados utilizando os atributos Haar-like (esquerdo) e LBP (direito) - Quadros n° 1, 70 e 100 da câmera frontal com alvos preto/amarelo .....	81
FIGURA 3.30 - Alvos identificados utilizando os atributos Haar-like (esquerdo) e LBP (direito) – Quadros n° 1, 70 e 100 da câmera frontal com alvos preto/branco.....	82

FIGURA 3.31- Alvos identificados utilizando os atributos Haar-like (esquerdo) e LBP (direito)	
– Quadros n° 101, 170 e 200 da câmera traseira com alvos preto/amarelo.....	83
FIGURA 3.32 - Alvos identificados utilizando os atributos Haar-like (esquerdo) e LBP (direito)	
– Quadros n° 1, 70 e 100 da câmera traseira com alvos preto/branco.....	84
FIGURA 3.33 – Alvos considerados para a consolidação dos resultados. Câmera frontal (esquerdo) e câmera traseira (direito) .....	85
FIGURA 3.34 – Raspberry Pi - Modelo B .....	89
FIGURA 3.35 – Gráfico da incerteza da medição dos tempos do processo de identificação considerando os 100 quadros.....	91
FIGURA 3.36 – Gráfico de desempenho do processo de identificação em um computador portátil.....	92
FIGURA 3.37 – Gráfico comparativa do desempenho entre um computador portátil e o Raspberry Pi .....	93
FIGURA 3.38 - Gráfico de desempenho do processo de identificação no Raspberry Pi.....	94
FIGURA 3.39 – Resultados obtidos no processo de rastreamento de alvos (KUSUMOTO, <i>et al.</i> , 2014).....	95

## **Lista de Tabelas**

TABELA 3.1 - Relação de parâmetros gerais (OPENCV DEV TEAM, 2011-2014) .....	64
TABELA 3.2 - Relação de parâmetros de processamento em cascata (OPENCV DEV TEAM, 2011-2014) .....	65
TABELA 3.3 – Relação de parâmetros AdaBoost (OPENCV DEV TEAM, 2011-2014) .....	65
TABELA 3.4 – Resultados do processo de identificação de alvos do vídeo analisado .....	69
TABELA 3.5 - Resultado obtido utilizando a métrica Precisão .....	69
TABELA 3.6 – Resultados consolidados para 900 alvos nas cores preto/amarelo.....	85
TABELA 3.7 – Resultados consolidados para 900 alvos nas cores preto/branco.....	86
TABELA 3.8 – Resultados consolidados considerando 4 alvos na carga - Câmera traseira com alvos nas cores preto/amarelo.....	87
TABELA 3.9 – Resultados de $P_k$ considerando todos os alvos identificados pelo algoritmo.	88
TABELA 3.10 – Relação dos recursos disponíveis no Raspberry Pi Model B .....	89
TABELA 3.11 – Tempo do processo de identificação em computador portátil .....	90

## Lista de Abreviaturas e Siglas

3D	Três dimensões
AdaBoost	<i>Adaptive Boosting</i>
AI	Análise de Imagens
AIAA	<i>The American Institute of Aeronautics and Astronautics</i>
CCD	Dispositivo de Carga Acoplada, em inglês, <i>Charge Coupled Device</i>
CEV	Curso de Ensaios em Voo
CFD	<i>Computational Fluid Dynamics</i>
CMOS	Dispositivo Semicondutor de Óxido Metálico Complementar, em inglês <i>Complementary Metal Oxide Semiconductor</i>
COTS	<i>Commercial off-the-shelf</i>
DCTA	Departamento de Ciência e Tecnologia Aeroespacial
DoD	<i>Department of Defense</i>
DoF	<i>Degrees-of-Freedom</i>
FEFV	Divisão de Formação em Ensaios em Voo
Embraer	Empresa Brasileira de Aeronáutica
EP	Engenheiro de Prova
ESM	Divisão de Suprimento e Manutenção
FAB	Força Aérea Brasileira
FN	Falso Negativo
FP	Falso Positivo
FTC	<i>Flight Test Campaign</i>
FTI	<i>Flight Test Instrumentation</i>
GIMP	<i>GNU Image Manipulation Program</i>
GNU	<i>GNU is Not Unix</i>
GPIO	<i>General Purpose Input/Output</i>
GPL	<i>General Public License</i>
GPS	<i>Global Positioning System</i>
GPU	<i>Graphics Processing Unit</i>
GS	<i>Ground Station</i>
HTML	<i>HyperText Markup Language</i>
IAE	Instituto de Aeronáutica e Espaço

ICT	Instituição de Ciência e Tecnologia
IEEE	<i>Institute of Electrical and Electronics Engineers</i>
IPEV	Instituto de Pesquisas e Ensaios em Voo
ITA	Instituto Tecnológico de Aeronáutica
OpenCV	<i>Open Source Computer Vision</i>
PDCA	<i>Plan, Do, Check, Act</i>
PI	Processamento de Imagens
Pixel	<i>Picture Element</i>
PNG	<i>Portable Network Graphics</i>
PP	Piloto de Prova
RAM	<i>Random Access Memory</i>
RNA	Redes Neurais Artificiais
ROI	<i>Region Of Interest</i>
RTL	<i>Real-Time Telemetry Link</i>
SAD	Sistema de Aquisição de Dados
SETP	<i>Society of Experimental Test Pilots</i>
SI	Síntese de Imagens
SIFT	<i>Scale Invariant Feature Transform</i>
SURF	<i>Speeded Up Robust Features</i>
VANT	Veículo Aéreo Não Tripulado
VC	Visão Computacional
VP	Verdadeiro Positivo
W3C	<i>World Wide Web Consortium</i>
XML	<i>eXtensible Markup Language</i>

## Listas de Símbolos e Unidades

°	graus
GB	<i>Gigabyte</i>
GHz	<i>GigaHertz</i>
Kbps	Kilobits per second ou Kb/s
kHz	<i>kiloHertz</i>
m	metro
MB	<i>Megabyte</i>
Mbps	<i>Megabits per second</i> ou Mb/s
MHz	<i>MegaHertz</i>
mm	milímetro
p	Varredura Progressiva
px	<i>pixel</i>
qps	quadros por segundo, em inglês, <i>frames per second</i> ou fps
s	segundos

# Sumário

<b>1</b>	<b>INTRODUÇÃO .....</b>	<b>19</b>
<b>1.1</b>	<b>Objetivos.....</b>	<b>24</b>
<b>1.2</b>	<b>Estrutura da Dissertação .....</b>	<b>25</b>
<b>2</b>	<b>FUNDAMENTOS TEÓRICOS.....</b>	<b>27</b>
<b>2.1</b>	<b>Ensaios em Voo .....</b>	<b>27</b>
2.1.1	Ensaios de Separação de Carga .....	30
2.1.2	Instrumentação da Aeronave .....	32
<b>2.2</b>	<b>Processamento Digital de Imagens.....</b>	<b>35</b>
2.2.1	Imagem Digital .....	36
2.2.2	Visão Computacional .....	37
2.2.3	Aquisição de Imagens.....	39
2.2.4	Visão Humana .....	40
2.2.5	Aquisição de imagens por meio de câmeras digitais .....	43
<b>2.3</b>	<b>Técnicas de reconhecimento de padrões.....</b>	<b>44</b>
2.3.1	Características Haar-like.....	47
2.3.2	Padrão Local Binário (LBP) .....	50
<b>3</b>	<b>DESENVOLVIMENTO.....</b>	<b>52</b>
<b>3.1</b>	<b>Processo de identificação de alvos.....</b>	<b>55</b>
<b>3.2</b>	<b>Experimento com vídeo de ensaios IPEV .....</b>	<b>58</b>
3.2.1	Preparação .....	58
3.2.1.1	Criação do conjunto de amostras positivas .....	61
3.2.1.2	Criação do arquivo de configuração e binário das amostras positivas .....	62
3.2.1.3	Criação do conjunto de amostras negativas.....	63
3.2.1.4	Criação do arquivo de configuração das amostras negativas .....	64
3.2.2	Processo de Treinamento .....	64
3.2.3	Processo de Identificação .....	66
3.2.4	Resultados.....	68
<b>3.3</b>	<b>Experimento com ensaios de separação em solo.....</b>	<b>70</b>
3.3.1	Preparação .....	70
3.3.2	Execução dos ensaios .....	73

3.3.3	Processo de Treinamento .....	76
3.3.4	Processo de Identificação .....	78
3.3.5	Resultados.....	84
<b>3.4</b>	<b>Avaliação de desempenho .....</b>	<b>88</b>
<b>4</b>	<b>CONCLUSÃO.....</b>	<b>96</b>
	<b>REFERÊNCIAS .....</b>	<b>99</b>
	<b>APÊNDICE A – MEDIÇÕES DE TEMPO DO PROCESSO DE IDENTIFICAÇÃO .</b>	<b>103</b>
<b>A.1</b>	<b>Medição de 100 quadros em Computador Portátil .....</b>	<b>103</b>
<b>A.2</b>	<b>Medição de 100 quadros no Raspberry .....</b>	<b>105</b>

# 1 Introdução

A atividade de ensaios de separação de cargas externas (e.g. bombas, armamentos e tanques de combustível) de aeronaves militares é considerada como uma atividade de alto risco, pois na realidade, durante a separação, a carga pode realizar uma trajetória diferente daquela previamente estimada.

A análise de separação de cargas é definida como a “determinação do histórico da posição e atitude da carga, depois dela ser deliberadamente separada ou ejetada enquanto a mesma ainda está sob a área de interferência da aeronave” (SPAHR, 1975). Portanto, as não conformidades do escoamento aerodinâmico, que ocorrem durante a fase inicial da separação da carga externa, podem causar uma trajetória errática e imprevisível da separação. Tal ocorrência prejudica significativamente a segurança dos voos de ensaios experimentais. Como consequência destas anomalias, tem-se: atrasos da entrega de um produto e em alguns casos, até a perda de equipagens de ensaios em voo e da aeronave (Figura 1.1), na qual pode-se constatar a colisão da carga após a sua separação ocorrida em uma campanha real de ensaios em voo.



FIGURA 1.1 - Sequência de fotos de um acidente ocorrido durante um voo de ensaio de separação de cargas externas (LEITE, VASCONCELOS e KUSUMOTO, 2013)<sup>1</sup>

A estimativa do grau de risco associado à execução de voos de ensaios de separação de cargas, depende do conhecimento prévio da trajetografia da separação a qual deverá ser

---

<sup>1</sup> Algumas imagens foram extraídas de sequência de vídeo, portanto, tem a sua qualidade degradada.

analizada e estimada através de simulações em laboratório. Entretanto, os modelos e condições de contorno usados nestas estimativas nem sempre correspondem às condições reais do lançamento, sendo assim, torna-se necessária à sua validação experimental. O modelo da trajetória real da separação, com 6 graus de liberdade (*Degrees-of-Freedom* - DoF), deverá ser determinado durante a execução dos voos de ensaios.

As campanhas de ensaios em voo (*Flight Test Campaign* - FTC) são atividades com o propósito de obter informações valiosas relacionadas ao desempenho real de aeronaves, bem como relacionados às qualidades de voo e às características dos sistemas em geral. São compostas por atividades de planejamento, preparação, execução e análise. De uma forma mais específica, a execução de voos de ensaio tem como propósito demonstrar que a operação de uma aeronave ou sistema é segura dentro do seu envelope de voo (i.e. conjunto de condições autorizadas, por meio de uma certificação, que garante o voo seguro de uma aeronave). Os voos de ensaios experimentais são executados pelas equipagens de ensaios (i.e. Pilotos de Provas - PP e Engenheiros de Prova - EP), que recebem um treinamento específico para a execução desta atividade. Entretanto, a execução de tal serviço requer a utilização de uma equipe de apoio especializada em ensaios em voo, que inclui técnicos e engenheiros de instrumentação.

Nas campanhas onde a aeronave de ensaio é um avião de grande porte (e.g. Embraer KC-390), todos os equipamentos utilizados para aquisição, processamento e apresentação em tempo real de dados, podem ser facilmente acondicionados dentro da aeronave. Toda a equipe de ensaio, como engenheiros e técnicos, pode permanecer dentro da cabine acompanhando o comportamento dos parâmetros adquiridos em cada ponto de ensaio. As análises e reduções de dados também podem ser realizadas a bordo já que todos os dados capturados podem ser acessados diretamente da sua fonte geradora. Caso seja necessário, alguns parâmetros selecionados podem ser transmitidos via rádio enlace de telemetria para a estação em solo (*Ground Station* - GS) para análise e tomada de decisão (STOLIKER, 1995).

Em aeronaves de caça, onde o espaço disponível para a instalação da instrumentação de ensaios (Figura 1.2) é restrito, as etapas de processamento e apresentação em tempo real dos dados adquiridos não podem ser executadas a bordo da aeronave. Em função disto, a maioria dos dados adquiridos são transmitidos para a GS (STOLIKER, 1995).



FIGURA 1.2 - Instrumentação de Ensaio

Entretanto, no caso específico de ensaios de separação de cargas externas em qualquer tipo de aeronave, a permanência da equipe de ensaio dentro da aeronave viola a doutrina de segurança de voo (STOLIKER, 1995), pois coloca em risco a integridade física da tripulação a bordo. Tal restrição impede que o processamento e a apresentação dos dados sejam realizados a bordo, tornando mandatória a transmissão dos dados em tempo real através de um enlace de telemetria (*Real-Time Telemetry Link - RTL*). Nos ensaios em voo, a utilização de um canal de transmissão de dados em tempo real por telemetria torna-se uma condição necessária para satisfazer os seguintes objetivos:

1. Caso haja uma falha catastrófica na qual a aeronave é destruída, dados recebidos e armazenados na GS servirão para a identificação das causas da falha e correção do projeto;
2. Dados recebidos, processados e apresentados em tempo real poderão ser visualizados pela equipe técnica da GS, para a verificação de que não existe nenhuma violação das condições de segurança do voo experimental. Tal funcionalidade poderá evitar a ocorrência da 1<sup>a</sup> condição;
3. Dados recebidos, processados e apresentados em tempo real poderão ser visualizados pela equipe técnica da GS, para a verificação de que as condições necessárias para a validação do ponto de ensaio foram efetivamente cumpridas. Tal funcionalidade poderá evitar a repetição de voos e, com isso, aumentar a eficiência das campanhas de ensaios em voo; e

4. Os conjuntos de dados validados do atual ponto de ensaio podem ser agregados com os anteriores. Assim, será possível realizar em tempo quase real a redução dos dados e a apresentação dos resultados finais dos voos de ensaio. Tal funcionalidade aumenta a eficiência da campanha de ensaios em voo.

O modelo da trajetória da separação com 6DoF pode ser determinado por meio de sistemas inerciais, onde são instalados acelerômetros, girômetros e giroscópios na carga para obtenção das informações relativas aos seus ângulos e componentes de aceleração, ou com receptores do Sistema Global de Navegação por Satélites (i.e. *Global Navigation Satellite System - GNSS*) instalados na carga (LEITE, 1997). Entretanto, a utilização desses dispositivos é limitada, pois como normalmente a carga separada é destruída, a recuperação dos dados colhidos no artefato requer o estabelecimento de um canal para transmissão dos dados com altíssima confiabilidade. Outro fator importante é o custo associado, já que os sensores e sistemas de aquisição e de transmissão de dados tornam-se materiais descartáveis e isso aumenta o investimento requerido para o ensaio.

Sendo assim, a solução mais usual utiliza um sistema óptico para realizar a aquisição de imagens da separação. Essa sequência de imagens pode ser utilizada para a determinação da trajetória da carga durante a sua separação com a utilização das técnicas de triangulação (DAVIS e FOOTE, 1953). Esse sistema é composto de duas ou mais câmeras de alta resolução (i.e. acima de 720p) e alta velocidade (i.e. maior que 200 quadros por segundo - qps) que devem ser sincronizadas e integradas à instrumentação de ensaio em voo (*Flight Test Instrumentation - FTI*). As câmeras são instaladas dentro de um casulo fotográfico (Figura 1.3).



FIGURA 1.3 - Casulo Fotográfico (LEITE, VASCONCELOS e KUSUMOTO, 2013)

A limitação de largura de banda para uso no RTL impede a transmissão das imagens da separação e o processamento em tempo real da trajetória de separação na GS. Tal limitação é decorrente do fato de que as imagens são geradas em alta velocidade e alta resolução. Um

segundo de imagens capturada em alta velocidade e em alta resolução requer uma banda de até 3200 MHz para cada câmera, considerando o tamanho de cada imagem com 2 MB e 200 imagens capturadas em um segundo (i.e. 2 MB x 8 bits x 200 amostras) e a equivalência de 1 kHz (i.e. fluxo de transmissão de dados) para 1 Kbps (i.e. volume de dados transmitidos).

Alternativamente, poderia ser usado alguma técnica de compressão de vídeo (TELEMETRY GROUP, 2013). As técnicas com perdas, geralmente, descartam informações irrelevantes para o olho humano e o uso de tal estratégia pode prejudicar a resolução da imagem (HALLAMASEK, *et al.*, 2012) e, consequentemente, a exatidão da medição da trajetória de separação. Esse fato não prejudica uma análise qualitativa (i.e. visual) das imagens capturadas. Entretanto, pode comprometer uma análise quantitativa, pois informações importantes podem ter sido descartadas, não permitindo a determinação do grau de correlação da trajetória de separação real com a estimada. Em função disto, a equipe técnica da GS não terá os elementos necessários para decidir se a próxima separação deverá ser realizada ou não. Esse processo não permite alcançar o rigor científico necessário nas Campanhas de Ensaios em Voo.

Utilizando-se de técnicas de compressão de vídeo sem perdas, a imagem poderá ser reconstruída posteriormente, entretanto, essas técnicas são pouco eficientes na taxa de compressão dos dados, já que a banda requerida para transmissão das imagens ainda seria maior do que a disponível (e.g. acima de 640MHz, para uma taxa de compressão de 5:1).

Cabe aqui ressaltar que, a banda máxima liberada para os canais de telemetria em conformidade com as normas do Consórcio Internacional para o Espectro de Telemetria (*International Consortium for Telemetry Spectrum – ICTS*), não pode exceder a banda de 40 MHz (TELEMETRY GROUP, 2013). Tal limitação, está muito aquém do necessário para transmissão de um canal de vídeo em alta resolução e em alta velocidade.

Atualmente, a determinação da trajetória de separação e a análise do grau de correlação com as estimativas são realizadas após o voo. A determinação da trajetória utiliza um aplicativo comercial (*Commercial off-the-shelf - COTS*), ao fim desta etapa. Se o ponto de ensaio for considerado seguro, um novo voo será realizado para a verificação em um novo ponto de ensaio cuja condição é mais crítica. Este processo é muito ineficiente e caro, pois demanda muitas horas de trabalho e a execução de muitos voos de ensaios, já que em cada voo só é possível realizar um único ponto de ensaio.

Assim, o desenvolvimento de um sistema embarcado para determinar em tempo quase real a trajetória da separação irá aumentar a eficiência e segurança desta campanha de ensaios e, em alguns casos, permite a execução de mais de um lançamento num só voo de ensaio. Tal capacidade será uma grande quebra de paradigma desta atividade. Para isso, o ponto inicial

desse desenvolvimento requer a implementação e validação de uma ferramenta para a identificação, localização e acompanhamento de pontos de referência na superfície da carga, durante a sua separação.

A realização deste trabalho, com o integral apoio institucional do IPEV, foi fundamental para que o autor pudesse realizar a pesquisa exploratória conhecendo melhor as especificidades das atividades de ensaios em voo, a importância de cada procedimento, as etapas necessárias para a sua realização, as pessoas envolvidas e a teoria aplicada no atendimento aos requisitos no desenvolvimento de novos produtos aeronáuticos.

A busca do estado da arte nessa área de conhecimento por meio da revisão bibliográfica, que é condição necessária para a execução deste trabalho acadêmico, foi possível utilizando as instalações e facilidades existentes no Instituto Tecnológico de Aeronáutica (ITA) como as bases de dados de artigos, teses e dissertações disponíveis para os alunos. O ITA oferece o acesso às bases de dados das principais editoras científicas do Mundo (e.g. *Institute of Electrical and Electronics Engineers - IEEE* e *The American Institute of Aeronautics and Astronautics - AIAA*) bem como de normas técnicas (e.g. Associação Brasileira de Normas Técnicas - ABNT).

O trabalho teve como diretrizes básicas a utilização de ferramentas de código aberto para que seja possível a sua reprodução, sem limitação de direitos de propriedade intelectual sobre as ferramentas de desenvolvimento e de ambiente operacional. Essa diretriz também foi definida, pois, mesmo que este trabalho busque atender a objetivos acadêmicos dentro do programa de pós-graduação, os seus resultados podem evoluir para o desenvolvimento de novas tecnologias resultando na criação de produtos inovadores e patentes. Portanto, buscou-se mitigar qualquer limitação nesse sentido.

## 1.1 Objetivos

Este trabalho apresenta um estudo com a avaliação experimental sobre a aplicação de técnicas de visão computacional no processo de identificação de múltiplos alvos em imagens de alta velocidade e alta definição que será integrada no sistema em tempo quase real de trajetografia ótico, embarcado nas campanhas de ensaios em voo de separação de cargas externas.

Os objetivos deste trabalho incluem:

- Estudo das técnicas de visão computacional aplicadas em reconhecimento de padrões;
- Identificação dos alvos de forma visual e a sua localização em relação às coordenadas na imagem;
- Desenvolvimento de um protótipo para validação experimental da ferramenta;
- Validação preliminar da ferramenta com a utilização de vídeos de campanhas de ensaios em voo;
- Execução de ensaios de separação em solo (i.e. *pit drop*) para, em condições controladas, validar a ferramenta; e
- Implementação da ferramenta em um dispositivo embarcado para verificação do seu desempenho.

Pretende-se com esse trabalho apresentar a viabilidade da utilização de técnicas de processamento de imagem aplicadas na atividade de ensaios em voo, especificamente, em ensaios de separação de cargas externas.

A identificação dos alvos na superfície das cargas externas e os resultados apresentados neste trabalho fazem parte da etapa inicial para a aplicação de técnicas de rastreamento e que consequentemente, irão contribuir com a determinação da trajetografia de uma carga externa.

A aplicação de técnicas de visão computacional no desenvolvimento de soluções no setor aeroespacial é de grande valia e pode gerar muitas outras novas soluções para diversos problemas existentes, que inclui a atividade de ensaios em voo. A análise quantitativa através de imagens de vídeo, principalmente em ambientes remotos e algumas vezes inóspitos, é um desafio sempre presente nessa área do conhecimento.

## 1.2 Estrutura da Dissertação

Este capítulo apresentou a Introdução deste trabalho, contextualizando sobre as atividades de ensaios em voo, especificamente, nos ensaios de separação de carga e suas especificidades. Também são apresentadas algumas diretrizes na realização desta pesquisa e os seus objetivos.

No capítulo 2 é apresentada a Fundamentação Teórica, identificando trabalhos correlatos ao tema da pesquisa e os conceitos necessários para o bom entendimento no desenvolvimento da pesquisa.

No capítulo 3, são apresentados os passos realizados para o alcance dos objetivos definidos, identificando os materiais e os métodos utilizados. São apresentados os experimentos realizados, desde o seu planejamento até a sua execução, seus óbices e sucessos. Os resultados obtidos e sua análise também são apresentados nesse capítulo.

O Capítulo 4 (Conclusão) apresenta uma análise comparativa dos objetivos com os resultados alcançados. Também identifica e sugere melhorias, além de relacionar possíveis trabalhos futuros.

## 2 Fundamentos Teóricos

### 2.1 Ensaios em Voo

Ensaios em voo é uma atividade da engenharia aeronáutica desenvolvida com a finalidade de verificar as características de voo e validar o comportamento de um sistema aeronáutico. É uma fase necessária para o desenvolvimento, certificação e integração de qualquer produto aeronáutico. A Doutrina Básica da Força Aérea Brasileira - FAB (BRASIL, 2012), define que “o ensaio em voo é a Ação que consiste em empregar Meios de Força Aérea para aquilarar as qualidades de voo e o desempenho de aeronaves e sistemas”. No Regimento Interno do IPEV (BRASIL, 2013) ensaios em voo é definido como uma atividade que tem “o propósito de obter conhecimentos referentes às qualidades de voo e ao desempenho de aeronaves, bem como os relacionados ao desempenho e características de armamentos aéreos e sistemas embarcados em geral”. Em todos os casos, a realização de uma campanha de ensaios em voo tem como objetivo “coletar dados, os quais permitam uma análise conclusiva do comportamento do componente submetido ao referido ensaio” (LEITE, 1997).

As atividades de ensaios em voo são executadas por poucas organizações no Brasil. A única Instituição de Ciência e Tecnologia (ICT) que realiza campanhas de ensaios em voo experimentais é o Instituto de Pesquisas e Ensaios em Voo (IPEV). Localizado em São José dos Campos, o IPEV é uma organização militar pertencente ao Departamento de Ciência e Tecnologia Aeroespacial (DCTA) e tem por finalidade “prestar serviços tecnológicos especializados na área de ensaios em voo, instrumentação de aeronaves e telemetria de dados para apoio à pesquisa, desenvolvimento e certificação de produtos aeronáuticos, bem como formar pessoal especializado em ensaios em voo” (BRASIL, 2013). Uma outra organização que realiza ensaios em voo no Brasil é a Empresa Brasileira de Aeronáutica (Embraer). Na Embraer as equipagens de ensaio, que em sua grande maioria, são PP e EP formados e provenientes do IPEV. A Helibrás também realiza serviços especializados na área de ensaios em voo. A Helibrás foi fundada em 1978 no antigo Centro Técnico Aeroespacial (CTA), agora DCTA, e hoje pertence ao grupo Airbus Helicopters.

O processo para a execução de uma campanha de ensaios em voo é composto de quatro etapas: Planejamento, Preparação, Execução e Análise (VIANA, 2011). A Figura 2.1 representa as etapas de uma campanha de ensaios em voo, onde os requisitos definidos pelo cliente são

considerados como entrada para o processo e no final, a informação, através da documentação gerada é considerada o produto final que será entregue ao cliente. O conjunto das etapas pode ser considerado como uma adaptação do Ciclo de Deming ou, como é mais conhecido, Ciclo PDCA (Planejar, Executar, Verificar e Agir, em inglês, *Plan, Do, Check, Act*). No ciclo PDCA a aplicação das ações de correção ocorre na etapa Agir. No caso de uma campanha de ensaios em voo, as correções ocorrem nas reuniões de preparação e de análise dos voos (i.e. *Debriefing*) que, para este caso específico, estariam de forma equivalente contidas na etapa Verificar do PDCA. Tal necessidade é decorrente do risco que é inerente à atividade de ensaios em voo, já que as melhorias devem ser adotadas de forma imediata e necessariamente antes do próximo voo.

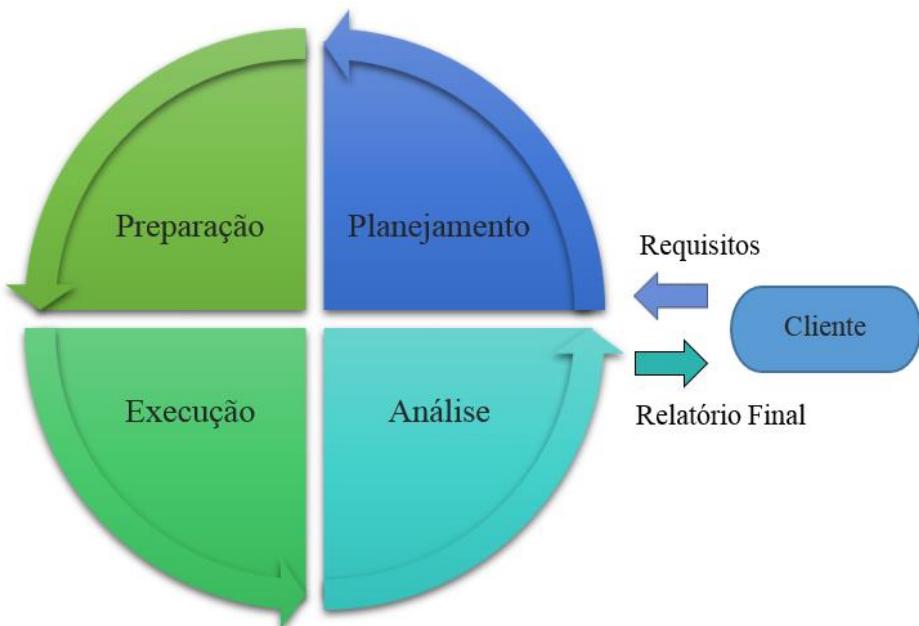


FIGURA 2.1 - Processo de Ensaios em Voo (VIANA, 2011)

No planejamento, o EP realiza o levantamento dos requisitos para que o Cliente possa receber as informações necessárias ao desenvolvimento e/ou certificação do produto. A partir dos requisitos, o EP define todos os insumos necessários (i.e. Meios, Métodos e Recursos) a execução da referida campanha. Neste contexto, um bom entendimento das necessidades do cliente torna-se essencial para que o serviço seja realizado de forma segura e eficiente (FOLLADOR, 2009). De uma forma geral, os meios utilizados nos ensaios incluem: a aeronave e a sua configuração; a instrumentação a ser utilizada; a lista de parâmetros necessários; a exatidão das medições; e o pessoal envolvido. Durante a fase de planejamento a equipe responsável deverá elaborar um Programa de Ensaio (PE) e uma Ordem de Ensaio (OE) para

cada voo que será executado. O PE especifica todos os meios e métodos necessários a execução de uma campanha de ensaios em voo que inclui informações, tais como: a aeronave, a lista de parâmetros, o número de voos e a exatidão das medidas. Nas OE estão contidos a descrição exata dos perfis de voo que serão executados e para cada perfil de voo, a descrição detalhada dos pontos de ensaios e suas respectivas condições de validação.

É muito importante considerar no planejamento dois fatores indispensáveis: a segurança e o custo (BIDINOTTO, 2007). O custo para qualquer atividade é de suma importância, pois pode limitar os recursos necessários para a sua realização. Em uma atividade de alto risco, a limitação de recursos poderá degradar a segurança de voo e/ou até inviabilizar a sua execução. No caso de um órgão público e/ou uma ICT, a legislação vigente de administração pública impõe muitas restrições para a utilização de recursos financeiros que são providos pela sociedade. Por outro lado, em uma empresa privada, a redução dos custos é desejável, entretanto, o seu esforço não deve prevalecer sobre o primeiro fator que é a segurança.

Em relação à segurança de voo, o gerenciamento dos riscos envolvidos deve considerar condições aceitáveis de segurança. Situações de riscos existem e não devem ser menosprezadas. Tanto o conhecimento explícito, que pode ser articulado e consultado através de manuais e relatórios, quanto o conhecimento tácito, que advém da experiência pessoal e envolve crenças e valores, são importantes nesse contexto. O pessoal envolvido deve estar comprometido com a segurança no sentido de mitigar qualquer risco que possa resultar em um acidente (i.e. evento associado a operação de uma aeronave no qual pessoas são feridas ou mortas; ou, no qual a aeronave apresenta danos ou falhas estruturais e/ou é destruída ou desaparecida) ou em um incidente (i.e. evento, diferente do acidente, que degrada a segurança da operação de uma aeronave) (INTERNATIONAL CIVIL AVIATION ORGANIZATION, 2013).

Na fase de Preparação, é necessário: projetar, instalar e certificar a Instrumentação de Ensaios em Voo (FTI) para aquisição dos dados; calibrar e determinar a incerteza de todos os parâmetros; desenvolver e validar os meios e métodos necessários para a realização dos voos de ensaios da campanha.

A execução da campanha de Ensaios em Voo deve seguir as condições estabelecidas no PE. A responsabilidade da execução dos voos é compartilhada entre o PP e o EP. Neste caso, o PP realiza os voos de ensaios em conformidade com as condições descritas na OE. De forma complementar, o EP realiza a coordenação técnica dos voos garantindo que as condições de validação dos pontos de ensaios foram atendidas pelo PP de forma segura. Durante um voo de ensaio, uma equipe de solo faz o acompanhamento em tempo real dos parâmetros adquiridos

na aeronave auxiliando o EP, que poderá estar junto com o piloto na aeronave ou em solo. Este processo tem como finalidade a verificação de possíveis violações de segurança e a validação dos parâmetros adquiridos pela FTI em cada ponto de ensaio. Esses dados são armazenados e/ou transmitidos por telemetria para a estação em solo. A realização dos voos de ensaios possui dois objetivos principais: trazer a aeronave e tripulação de volta de forma íntegra (i.e. Segurança de voo); e adquirir informações valiosas (i.e. precisas) que será a base para a emissão dos relatórios com os resultados dos ensaios.

Após os voos de ensaios, a equipe responsável, usando uma ferramenta matemática de processamento de dados de ensaios em voo (i.e. R-Dat®), realiza uma análise detalhada dos resultados obtidos e elabora o Relatório de Ensaio (RE) que será entregue ao cliente, em atendimento aos requisitos definidos no início do processo.

É notório que os PP e EP, assim como toda a equipe de instrumentação, engenheiros e técnicos, devem possuir grande conhecimento técnico especializado para executar satisfatoriamente esta atividade, de forma condizente à complexidade envolvida. Para isso, o IPEV possui uma Divisão de Formação em Ensaios em Voo (EFEV) que tem como finalidade a formação de PP e EP e ainda de engenheiros e técnicos de instrumentação de ensaios. Os cursos oferecidos pelo EFEV são, desde 2004, formalmente reconhecidos pela Sociedade de Pilotos de Provas Experimentais (i.e. *Society of Experimental Test Pilots - SETP*). Com isso o EFEV foi a 5ª escola a receber tal reconhecimento no Mundo.

### **2.1.1 Ensaios de Separação de Carga**

Na fase de planejamento foi mostrado que cada campanha de ensaio possui um objetivo específico. Como exemplo:

1. Ensaios de aeroelasticidade tem a finalidade de verificar o comportamento das estruturas de uma aeronave. Tais estruturas estão sujeitas a grandes cargas aerodinâmicas e isso pode provocar deformações que podem gerar falhas estruturais (BIDINOTTO, 2007).
2. Ensaios de parafuso têm como objetivo determinar as limitações e a melhor técnica de recuperação da aeronave; e
3. Informações exatas de altitude e velocidade são essenciais para que uma aeronave possa voar de forma segura (VASCONCELOS, 2011). Durante o voo, essas medições são corrompidas pelo efeito aerodinâmico. Ensaios de calibração

anemométrica têm como objetivo determinar experimentalmente os coeficientes do modelo de correção das medições do sistema anemométrico para minimização dos erros.

Mais especificamente, os ensaios de separação de cargas têm como objetivo principal avaliar a atitude e a posição de uma carga externa (e.g. bomba, míssil) durante a sua separação. A norma MIL-STD-1289D (UNITED STATES, 2003), estabelece requisitos e procedimentos de teste para instalação de todas as munições e cargas transportadas em uma aeronave e define que a carga é “qualquer dispositivo destinado para o transporte interno ou externo, afixado na aeronave e que pode ser liberada intencionalmente ou em situações de emergência durante o voo”. Acrescenta também que um equipamento ou dispositivo fixado permanentemente à aeronave não é considerado uma carga. No manual MIL-HDBK-1763 (UNITED STATES, 1998, p. 12), a carga pode ser classificada como um dispositivo que pode ser alijado (e.g. bomba, míssil, foguete) ou não (e.g. tanque de combustível, casulo de armamento ou fotográfico).

O manual MIL-HDBK-1763 estabelece os requisitos de compatibilidade entre a aeronave, cargas e seus equipamentos de fixação e transporte que garantem a aeronavegabilidade da carga instalada em uma aeronave. Pode ser aplicado em todas as atividades do ciclo de vida de um sistema envolvendo aeronaves militares e suas cargas. Define também metodologia de testes, instrumentação e dados.

Ensaios de separação de carga podem ser considerados de alto risco, pois o efeito aerodinâmico gerado entre carga liberada/ejetada e a estrutura da aeronave (e.g. asa do avião) é praticamente imprevisível e pode levar a uma condição de colisão com consequências catastróficas (LEITE, VASCONCELOS e KUSUMOTO, 2013). A trajetória percorrida pela carga na região de fluxo aerodinâmico não uniforme é muitíssimo menor do que o resto da trajetória em regime balístico e/ou propulsado. As perturbações na trajetória da carga durante a primeira fase da separação, onde ainda existe influência aerodinâmica da aeronave alteram significativamente as condições iniciais da separação, que são as variáveis de entrada para o cálculo da posição estimada de lançamento e/ou de impacto que são mostradas para o Piloto (KUSUMOTO, *et al.*, 2014).

A execução de um voo de ensaio deve ser necessariamente precedida por uma análise de risco. Neste caso específico, são utilizadas diversas ferramentas de ensaios e de simulações para estimativa da trajetória de lançamento, tais como ensaios em túnel de vento, simulações e ensaios de separação em solo (i.e. *pit drop*).

Os ensaios de separação de carga em túnel de vento foram desenvolvidos durante os anos 60 e permitem simular a trajetória de separação da carga em um ambiente controlado e verificar a influência do ar (i.e. vento) através do seu escoamento ao redor da carga e da aeronave (DENIHAN, 2003). Nesse caso, entretanto, em simulações com modelos de menor escala, os resultados geralmente não são semelhantes aos resultados dos ensaios em voo (CENKO, 2009). Outro método para se estimar a trajetória com 6DoF da carga durante a sua separação é a simulação por Dinâmica dos Fluidos Computacional (*Computational Fluid Dynamics - CFD*), entretanto, a sua validação requer a realização de ensaios em túnel de vento e por fim, em voo.

Os ensaios de separação em solo permitem a avaliação em condição estática de que a separação atende a um grau mínimo de segurança. Além disto, este ensaio serve para verificar a correta operação de todos os sistemas usados na campanha de ensaio e ainda prover medições de referência da trajetória de separação para calibração e validação da FTI. A Figura 2.2 ilustra um ensaio de separação em solo utilizando uma bomba acoplada na asa de uma aeronave A-1 (AM-X).

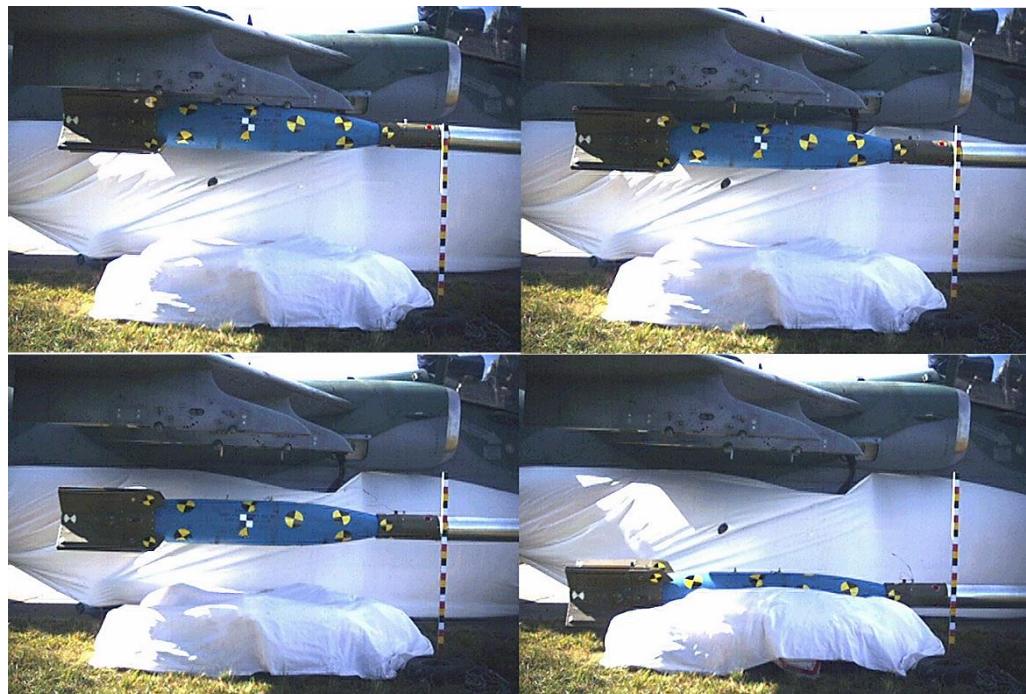


FIGURA 2.2 - Ensaio de Separação em Solo

### 2.1.2 Instrumentação da Aeronave

Para que qualquer ensaio seja realizado, é necessária uma preparação da aeronave que abrange a instalação de sensores e do sistema de aquisição de dados para captura, registro e transmissão dos parâmetros durante o voo de ensaio. O processo de instrumentação da aeronave

é uma atividade estratégica, pois garante que os dados necessários para a verificação dos requisitos sejam adquiridos e fiquem disponíveis para os engenheiros durante a sua análise. Tipicamente numa FTI são instalados diversos sensores tais como:

1. Girometros, que realiza a medição das componentes X, Y e Z da velocidade angular da aeronave
2. De pressão absoluta e estática, que realizam as medições das pressões estáticas e de impacto que serão utilizadas para o cálculo das velocidades e altitude da aeronave;
3. Extensômetro que realiza a medição de deformação de um material, tal como a força aplicada pelo piloto no manche e/ou no pedal para comandar a aeronave.

Todos os componentes e sensores que constituem esse conjunto formam basicamente dois segmentos: Embarcado e de Terra. A Figura 2.3 apresenta o diagrama de blocos dos segmentos que realizam a aquisição dos dados.

Dados observados pelos sensores instalados são condicionados, amostrados, quantizados e formatados pelo Sistema de Aquisição de Dados (SAD) e gravados e/ou transmitidos através de um enlace de telemetria. Das diversas fontes de dados pode-se incluir uma ou mais câmeras de vídeo embarcadas que serão utilizadas na aquisição de imagens para análise. Esse sinal de vídeo será anexado com as diversas outras medidas e poderá ser transmitido ou armazenado conforme a necessidade da aplicação.

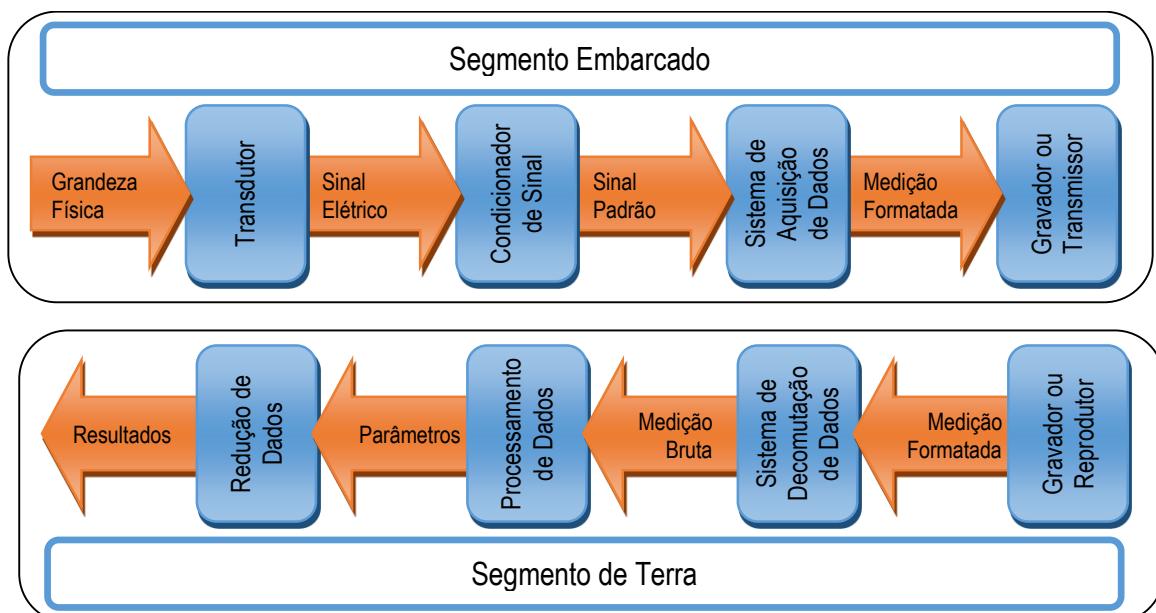


FIGURA 2.3 - Estrutura da Aquisição de Dados (SOUSA, 2005)

As câmeras de vídeo utilizadas atualmente em ensaios de separação de carga devem capturar imagens em alta resolução (i.e. 720p ou mais) e em alta velocidade (i.e. 200 qps ou mais). Para uma análise mais exata, a alta resolução da imagem apresenta uma quantidade de pixels maior e consequentemente, mais informação. A possibilidade de se adquirir 200 qps ou mais, permite uma melhor discretização da trajetória, porém também aumenta consideravelmente o volume de dados de entrada para análise.

Tipicamente o tempo de duração da trajetória de separação da carga na zona de influência aerodinâmica da aeronave não é maior do que 2s. Portanto, considerando uma aquisição padrão de vídeo de 30 qps e em alta velocidade (i.e. 200qps), as quantidades de quadros a ser analisada em 2 segundos seria respectivamente de 60 quadros e 400 quadros. De uma forma geral a discretização da trajetória em 60 pontos restringe a observação de componentes de alta frequência nas perturbações da trajetória de separação e poderia produzir um resultado incompleto. De uma forma mais específica, as melhores práticas, recomendadas pela AGARD (1986), requerem o uso de câmeras com amostragem mínima de 200qps para a realização de ensaios de separação.

A reconstituição da trajetória de separação com 6DoF a partir de imagens por meio de triangulação, requer o uso de 2 ou mais câmeras sincronizadas. As câmeras são normalmente instaladas em casulos fotográficos em pilones situados embaixo da aeronave ou sob a asa. Sua instalação deverá ser integrada com a instrumentação da aeronave. Com isso o PP pode ativar o início da aquisição de imagens quando for necessário. Geralmente as câmeras possuem um dispositivo de armazenamento para a gravação das imagens para análise posterior.

Em algumas aplicações, imagens comprimidas podem ser transmitidas para a GS para permitir a realização de uma análise preliminar da separação. Neste caso existem duas técnicas para a transmissão do vídeo que são:

1. Anexar as imagens aos dados da FTI e transmitir em tempo real via enlace de telemetria; ou
2. Enviar as imagens num segundo canal de transmissão de dados para a GS.

Em ambos os casos, existe a limitação de banda do enlace de telemetria. Especificamente no primeiro caso, as imagens anexadas compartilham (i.e. dividem) o mesmo canal com os dados adquiridos pelo sistema de aquisição de dados. No segundo caso, o canal utilizado para a transmissão das imagens é dedicado. Como exemplo, para uma transmissão em um canal dedicado de imagens em alta resolução (i.e. 720p) com cadência de 30 qps,

comprimidas no padrão H.264 é necessário uma largura de banda de no mínimo 20 Megabits por segundo (Mbps) (HALLAMASEK, *et al.*, 2012). Se tais imagens forem anexadas com os dados da FTI, a banda requerida será maior.

## 2.2 Processamento Digital de Imagens

O processamento de imagens é uma área da computação gráfica que manipula e transforma as imagens. Analogamente, pode ser comparada ao processamento de dados que é uma atividade da computação que manipula e transforma os dados (CONCI, AZEVEDO e LETA, 2008). Entretanto, na atualidade, a maioria dos sistemas existentes realiza o processamento de imagens em formato digital. No início dos anos 20, a aplicação inicial das técnicas de processamento de figuras digitais realizou o melhoramento de imagens utilizadas em jornais. Essas imagens eram codificadas e transmitidas via cabo submarino de Londres para Nova Iorque para serem publicadas em jornais da época. Antes, as imagens eram transportadas por navio. O tempo de transporte foi reduzido de um pouco mais de uma semana para apenas três horas (GONZALEZ e WOODS, 2010). Na Figura 2.4, é possível verificar uma imagem transmitida em 1929 por um equipamento que discretizava a tonalidade em 15 níveis na escala de cinza.



FIGURA 2.4 - Figura sem retoques transmitida por cabo submarino de Londres a Nova Iorque em 1929. Na imagem os Generais Pershing e Foch (GONZALEZ e WOODS, 2010)

Nos dias atuais, com a evolução da tecnologia, o processamento das imagens está sendo utilizado em uma grande variedade de áreas e aplicações. Além das aplicações na área aeroespacial, a visão computacional também está sendo utilizada em diversas áreas, tais como: sistemas de monitoramento de desastres naturais (KO e KWAK, 2012), vigilância utilizando

câmeras de vídeo (SPIE; IS&T, 2013), controle de tráfego, biometria, sensoriamento remoto, e produção industrial.

### 2.2.1 Imagem Digital

Uma imagem digital pode ser considerada como uma “representação de uma imagem em uma região discreta, limitada através de um conjunto finito de valores inteiros que representam cada um de seus pontos” (CONCI, AZEVEDO e LETA, 2008). É a representação visual de um conteúdo, seja ele um objeto, uma paisagem ou o registro de um determinado momento. Uma imagem pode ser reproduzida através de técnicas de desenho manual ou registrada através de dispositivos ópticos como câmeras fotográficas. Uma imagem pode ser definida como uma função bidimensional  $I(x,y) = f(x,y)$ , onde  $x$  e  $y$  representam as coordenadas no plano do sensor da imagem (e.g. película do filme) e  $I(x,y)$  é a intensidade de luz da imagem projetada na coordenada  $x,y$  do elemento sensor (GONZALEZ e WOODS, 2010).

Uma imagem digital é o resultado obtido da discretização e da quantização de uma imagem e é composta por um número finito de elementos representados pelas coordenadas de  $x_i$  e  $y_j$  em uma matriz de dimensão  $n \times m$ . Cada elemento da imagem digital é chamado de pixel (i.e. *Picture Element*).



FIGURA 2.5 - Representação de uma imagem digital (GONZALEZ e WOODS, 2010)

Na Figura 2.5 é apresentada a representação de uma imagem digital, onde as coordenadas  $x_i$  e  $y_j$  têm por definição a sua origem no canto superior esquerdo. Neste caso  $I(x_i,y_j) = f(x_i,y_j)$  em seguida  $I(x_i,y_j)$  deverá ser discretizado em  $l$  elementos na escala de cinza ou decompostos em  $k \times k$  elementos na escala colorida.

Imagens podem ser classificadas de acordo com a frequência da intensidade de energia gerada. No espectro eletromagnético, as imagens em espectro de luz visível são as mais conhecidas, mas as imagens podem ser formadas também por: raios gama, utilizadas para aplicações na medicina e astronomia, por raios X para o diagnóstico médico, e infravermelho, para medições de diferenças de temperaturas.

### 2.2.2 Visão Computacional

Não existe um consenso entre os autores sobre o correto escopo do processamento de imagens, a síntese de imagens e visão computacional. Essas áreas se entrelaçam e algumas vezes se sobrepõem, o que resulta nesse desacordo. GONZALEZ e WOODS (2010) sugerem um paradigma com três tipos de processos computacionais, representado na Figura 2.6, que considera uma linha contínua entre processamento de imagens e a visão computacional.

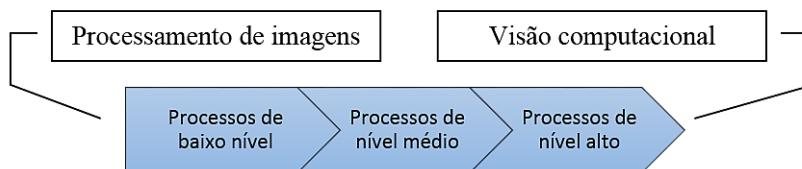


FIGURA 2.6 - Três tipos de processos computacionais (GONZALEZ e WOODS, 2010)

Os processos de baixo nível usam imagens como entradas e saídas do processo. Realiza o pré-processamento de imagens que envolvem operações como: realce de imagem, minimização de ruídos e restauração. No caso dos processos de nível médio as saídas são atributos extraídos dessas imagens que em alguns casos, para se otimizar o processamento, usam técnicas de segmentação (i.e. subdividir a imagem em regiões de interesse ou objetos) para a extração do conhecimento desejado. Nos processos de alto nível, são realizadas operações para analisar um conjunto de objetos identificados no nível anterior para se obter informações associadas às funções cognitivas da visão.

CONCI, AZEVEDO e LETA (2008) apresentam uma abstração um pouco diferenciada, principalmente, em relação aos três tipos. Estes autores classificam a computação gráfica em três grandes áreas, na qual duas áreas são praticamente o agrupamento dos três tipos apresentados por GONZALEZ e WOODS (2010). Esta abordagem introduz uma grande área chamada de Síntese de Imagens (SI), que utiliza de dados para a criação de novas imagens digitais tais como o ultrassom e tomografias.

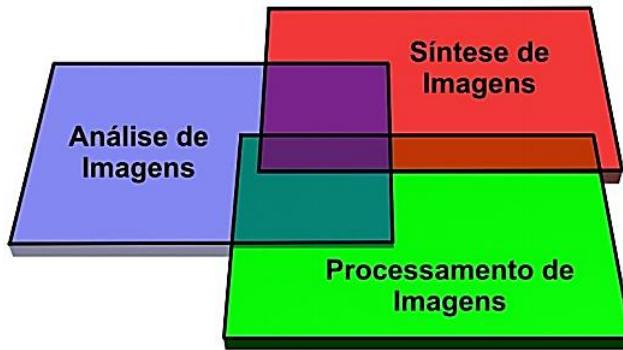


FIGURA 2.7 – Três grandes áreas da Computação Gráfica (CONCI, AZEVEDO e LETA, 2008)

A grande área de Análise de Imagens (AI), apresentada na Figura 2.7 incorpora os processos de nível médio e alto apresentados por GONZALEZ e WOODS (2010) e tem como objetivo a extração de informações úteis das imagens. Nesse contexto, a Visão Computacional (VC), assim como a segmentação das imagens, estão contidas nessa grande área.

Portanto, a visão computacional pode ser definida como a aplicação de métodos e técnicas de processamento e análise de imagens com o objetivo de extrair informações relevantes de imagens digitais, de maneira similar às capacidades biológicas da visão humana e/ou superando tais capacidades. No processamento de uma imagem digital, o computador deve processar uma grande matriz de dados para reconhecer a imagem de forma a simular as capacidades da percepção visual humana. O objetivo é reconstruir, a partir de uma ou mais imagens, através de propriedades como a iluminação, suas formas e cores, o que é visto do mundo pela visão humana (SZELISKI, 2011).

CONCI, AZEVEDO e LETA (2008) apresentam uma comparação da visão computacional com a visão humana, em relação aos aspectos funcionais, destacando:

- Adaptabilidade - capacidade de ajustes automáticos do sistema em suas operações;
- Tomada de Decisão – depende da interpretação da imagem pelo ser humano, que envolve seu conhecimento prévio e o que está sendo visto, ou por um sistema de visão computacional que avalia somente as características da imagem.
- Qualidade das medições - sistemas computacionais podem manipular dados que a visão humana não pode sequer discernir, entretanto, a sua análise é realizada de forma quantitativa, enquanto a humana é qualitativa;

- Tempo de Resposta – o tempo de resposta de um ser humano é da ordem de 0,06 segundos, enquanto que um sistema de visão computacional pode chegar a ser 10 vezes mais rápido (depende do tamanho da imagem, das técnicas aplicadas e de outras variáveis);
- Percepção da Banda Espectral - um sistema de visão computacional pode analisar diversas faixas do espectro eletromagnético, dependendo somente das características do sensor de imagem, o sistema de visão humana está restrito ao espectro de luz visível; e
- Dimensão dos objetos - a percepção de distância e profundidade de um objeto é inerente ao ser humano, já um sistema de visão computacional precisará, por exemplo, de um sistema de aquisição da imagem estereoscópica para adquirir uma visão tridimensional do ambiente.

Diante desses aspectos, é possível concluir que existem limitações em ambos os lados e um sistema de visão computacional deve levar em consideração todos os componentes na interpretação de uma imagem digital.

De maneira geral, para que um sistema de visão computacional opere, algumas etapas são necessárias, a saber: aquisição de imagens; processamento das imagens; e geração do resultado final que será utilizado para a tomada de decisão. Portanto, é importante conceituar como é realizada a etapa de aquisição de imagens, visto que, as outras tarefas serão abordadas neste trabalho.

### **2.2.3 Aquisição de Imagens**

O processo de aquisição de imagens é a primeira etapa a ser realizada. O objetivo é a criação de uma representação digital de uma pessoa, objeto ou ambiente. Uma câmera digital utiliza um sensor que captura amostras (i.e. quadros) da energia (i.e. intensidade de luz) emitida e/ou refletida pelo objeto ou ambiente, convertendo cada ponto do quadro (i.e. pixel) em um sinal elétrico que será quantizado. Dessa forma, o sensor é o elemento mais crítico em uma câmera digital.

## 2.2.4 Visão Humana

Os sistemas de visão computacional têm o objetivo de reproduzir e/ou ampliar as capacidades cognitivas da visão humana, em termos de interpretação e percepção das imagens. A visão humana é um sistema complexo, onde o olho é o órgão sensorial que captura a energia luminosa e a converte em sinais elétricos que são transmitidos para o cérebro para processamento e formação das imagens.

O olho também realiza as funções ópticas (i.e. focalização e controle da intensidade luminosa) que resultam no ato de ver ou enxergar dos seres humanos. Sua morfologia básica é apresentada na Figura 2.8. O olho é quase uma esfera composta pela retina, que é o tecido nervoso que recebe os raios luminosos e os converte em sinais elétricos para o processamento visual, pela coróide, que é responsável pela sua nutrição do olho e pela córnea.

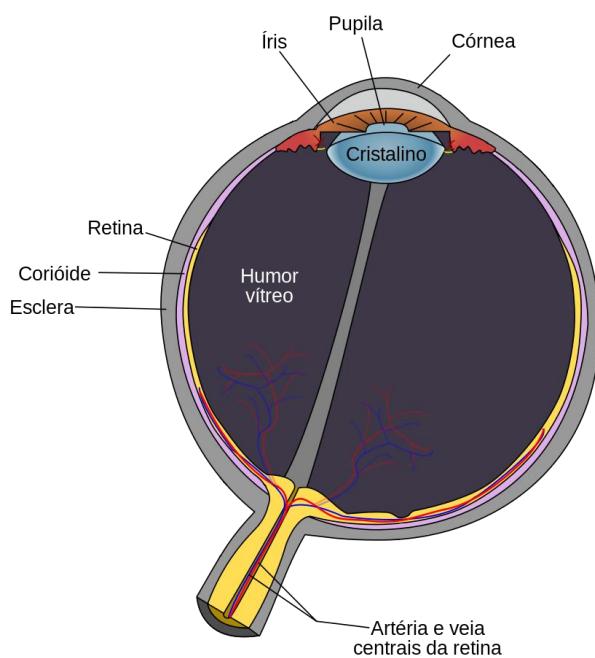


FIGURA 2.8 – Corte com os principais elementos do olho humano (CONCI, AZEVEDO e LETA, 2008)

A córnea é formada por um tecido transparente que permite a passagem dos raios luminosos para a retina na formação da imagem. A íris é uma membrana que regula a quantidade de luz que passa pelo seu orifício central, que é a pupila. A íris aumenta (i.e. dilatação) ou diminui (i.e. constrição) a área da pupila para controlar a intensidade de luz. Esse mecanismo de defesa foi sendo aperfeiçoado com a evolução do homem. Em uma situação de perigo, por exemplo, o organismo libera uma descarga de adrenalina que resulta na dilatação

da pupila, melhorando a percepção visual.

Logo atrás da íris se encontra o cristalino, que atua como uma lente para focalização da imagem. Controlado pelos músculos, o raio de curvatura do cristalino se modifica de acordo com o foco desejado para uma visão nítida de objetos mais perto ou mais afastados do olho. Esse processo é chamado de acomodação (CONCI, AZEVEDO e LETA, 2008). O formato do cristalino tende a ser esférico. Como ele não é rígido, à medida que o objeto se afasta, o relaxamento dos músculos ciliares que o sustentam, faz com que ele fique mais plano.

Em um olho normal (i.e. emétreope), o ponto focal da imagem ocorre em cima da retina (Figura 2.9-a). Em alguns casos, as alterações e/ou degenerações no processo de acomodação, causados por desvios do eixo normal do globo ocular, resultam em visão com hipermetropia (Figura 2.9-b) ou miopia (Figura 2.9-c), cujos pontos focais ficam, respectivamente, atrás ou adiante da retina. De uma forma geral, a visão hipermétrope dificulta a focalização de objetos próximos enquanto os mais distantes ficam nítidos. No caso da visão míope, o efeito é o oposto. Em ambos os casos, o uso de lentes artificiais é indicado para a correção destas distorções.

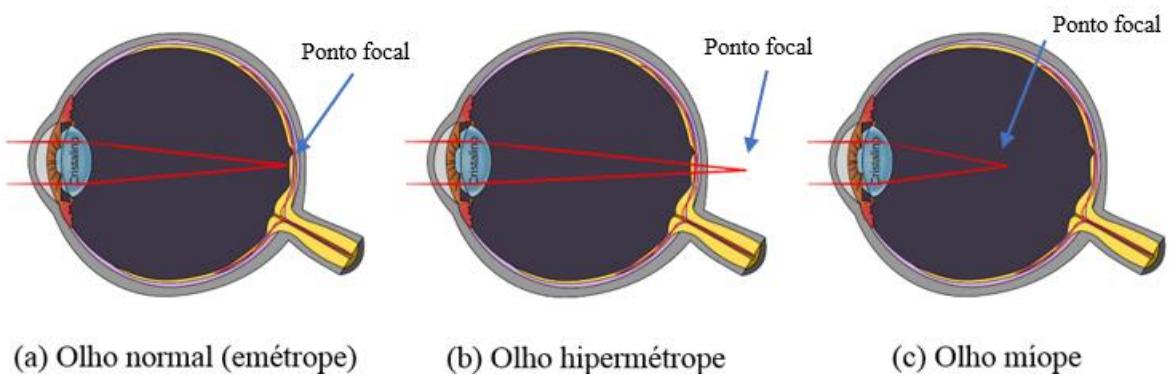


FIGURA 2.9 – Variações de foco no globo ocular

Na porção posterior do globo ocular localiza-se a retina, onde a imagem é formada. Através dos cones e bastonetes, a imagem é convertida em sinais nervosos que serão transmitidos para o cérebro pelo nervo óptico. A imagem formada na retina é invertida, conforme mostra a Figura 2.10 e isso é uma característica congênita. A criança quando nasce, aprende a interpretar a imagem da forma correta.

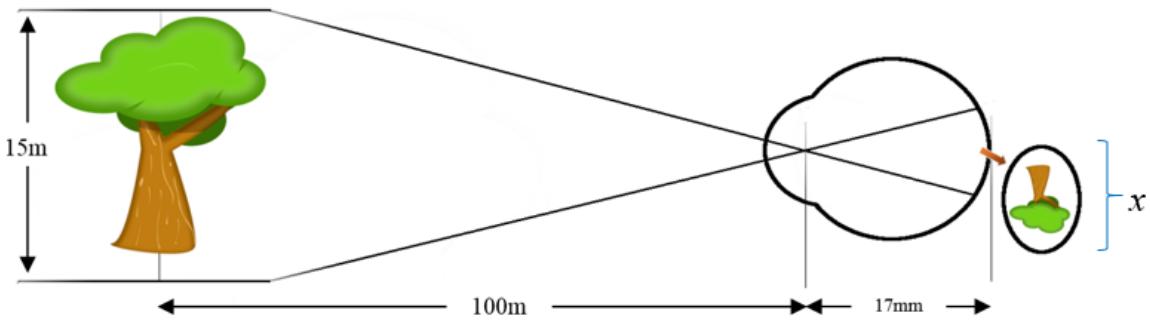


FIGURA 2.10 - Representação gráfica do olho focalizando uma árvore (GONZALEZ e WOODS, 2010)

Como qualquer sistema óptico é possível calcular o tamanho da imagem projetada na retina ( $x$ ), caso sejam conhecidas o tamanho ( $h$ ) e a distância ( $d$ ) do objeto focado e ainda a distância do centro do cristalino até a retina do globo ocular ( $D$ ). A Equação 2.1 apresenta o cálculo para determinar o tamanho da imagem na retina.

$$\frac{h}{d} = \frac{x}{D} \quad (2.1)$$

Como exemplo, um observador está a uma distância ( $d$ ) de 100 metros de uma árvore que possui uma altura ( $h$ ) de 15 metros. Considerando que a distância do centro do cristalino até a retina ( $D$ ) é de 17 milímetros (Figura 2.10), temos que:

$$\frac{15}{100} = \frac{x}{17} \rightarrow x = 2,55 \text{ mm}$$

Neste caso, a projeção da imagem invertida da árvore na retina terá 2,55 milímetros de altura.

No olho humano, a distância ( $D$ ) entre a lente (i.e. cristalino) e o plano da imagem (i.e. retina) é fixa. Sendo assim, a focalização de uma imagem na retina é obtida variando a forma do cristalino (i.e. dilatação e constrição).

Por outro lado, nas câmeras fotográficas, a focalização de uma imagem é obtida variando-se a distância entre a lente que é fixa e a imagem.

Uma câmera fotográfica possui funcionalidades similares às do olho humano, no qual a retina é o filme que registra a imagem, o cristalino é o conjunto de lentes (i.e. objetiva da câmera), a sua acomodação ou modificação, pode ser considerado o foco, e por fim, a íris é o diafragma que controla a quantidade de luz que entra no sistema óptico.

### 2.2.5 Aquisição de imagens por meio de câmeras digitais

Nos dias atuais, o meio mais comum de captura de uma imagem é por meio das câmeras digitais. Aplicações de vigilância utilizam câmeras de vídeo para monitoramento de áreas. Aplicações de controle de navegação autônoma para Veículos Aéreos Não Tripulados (VANT), de análise de imagens para diagnóstico médico ou de identificação de placas de automóveis para verificação de tributos pendentes ou infrações no trânsito, também utilizam dispositivos com sensores ópticos que capturam sequências de imagens.

De uma forma mais abrangente, uma câmera ou filmadora, realizam a mesma operação fundamental, que é a captura de um quadro, que representa a imagem. A principal diferença é que a filmadora é capaz de registrar uma sequência de imagens, que são amostradas com frequência constante que resulta na sensação de movimento. Inicialmente, a taxa de amostragem de um vídeo era de 24 qps. Atualmente, a maioria das cameras de vídeo usa a taxa de amostragem de 30 qps. De uma forma mais específica, um vídeo gravado com taxa de 200 qps ou mais, será definido como vídeo em alta velocidade.

Atualmente, são usadas duas tecnologias para a fabricação de sensores de imagens para câmeras de vídeo digitais, que são:

1. Dispositivo de Carga Acoplada (*Charge Coupled Device - CCD*), que é uma matriz de células fotossensíveis onde cada célula gera uma carga elétrica proporcional à intensidade luminosa projetada em sua superfície. O CCD, geralmente realiza a captura da imagem de forma global (i.e. *Global Shutter*). Neste caso, todas as células que compõem a matriz, geram a carga elétrica que representa a intensidade luminosa no mesmo instante. A Figura 2.11-a apresenta o resultado da aquisição utilizando um sensor CCD.
2. Dispositivo Semicondutor de Óxido Metálico Complementar (*Complementary Metal Oxide Semiconductor - CMOS*), que é um outro dispositivo que gera cargas elétricas em função da intensidade de luz projetada numa matriz de células. No CMOS, a amostragem é feita linha a linha (i.e. *Rolling Shutter*), o que pode resultar em distorções como apresentadas na Figura 2.11-b.

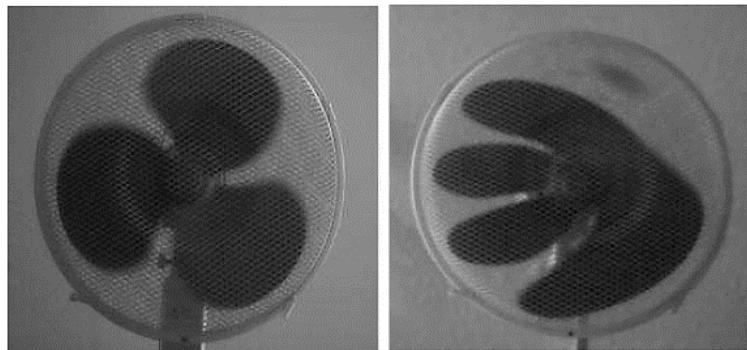


FIGURA 2.11 - *Global Shutter* (a) e *Rolling Shutter* (b) (WILLIS e LANGER, 2014)

Por muito tempo, os sensores do tipo CCD, dominaram o mercado de câmeras digitais por possuírem cores e imagens mais nítidas, melhor sensibilidade e menor ruído, entretanto o consumo de energia destes sensores é mais alto.

Por outro lado, os sensores CMOS tiveram uma evolução muito grande e atualmente, estão sendo utilizados em grande parte das câmeras digitais do mercado, pois as poucas desvantagens que ainda perduram nesta tecnologia são compensadas pelo uso mais eficiente de energia.

### 2.3 Técnicas de reconhecimento de padrões

O reconhecimento de padrões tem a finalidade de realizar a classificação ou categorização de um objeto (BIANCHI, 2006). Para isso, engloba três etapas, a saber:

- Aquisição de dados e pré-processamento - envolve processos de baixo nível;
- Representação e/ou segmentação dos dados - envolve processos de nível médio; e
- Reconhecimento ou Tomada de decisão - envolve processos de alto nível, cuja finalidade é o reconhecimento do objeto.

Inicialmente, o grande desafio tecnológico era realizar o reconhecimento de gestos, pessoas e faces. Aplicações com essa capacidade seriam utilizadas em sistemas de vigilância e monitoramento de ambientes como *shopping centers*, eventos públicos e esportivos, com a finalidade de aumentar a segurança desses locais e das pessoas que lá estão.

Na área aeroespacial, as imagens têm sido utilizadas como fonte de informação para extração de dados quantitativos no processo de desenvolvimento de novos produtos e sistemas. VASCONCELOS (2011) utiliza as imagens geradas por uma câmera digital de vídeo para extrair em tempo real as informações de altura de passagem durante os pontos de ensaios de calibração anemométrica. Tal processo aumenta a eficiência da campanha de ensaio e a exatidão

das informações. Com isso, as informações geradas pela aplicação podem ser comparadas em tempo real com os parâmetros obtidos e transmitidos pelo enlace de telemetria e também aqueles obtidos pelo Sistema Global de Navegação por Satélites (GNSS), para se calcular os erros do sistema anemométrico da aeronave ensaiada. HUMMEL *et al.* (2014) realiza o reconhecimento de automóveis com VANT utilizando imagens de vídeo capturadas pela própria aeronave. Já SHIGUEMORI, MARTINS e MONTEIRO (2007) apresentam um sistema de reconhecimento mais abrangente, pois identificam pontos de referência (e.g. pontes, passarelas, campos de futebol e entroncamentos ferroviários) em imagens de satélites que serão utilizadas pelo sistema de navegação autônoma de VANT, que usa técnicas de Redes Neurais Artificiais (RNA) para realizar o treinamento e a identificação dos pontos de referência.

Existem várias abordagens que resultaram em métodos e técnicas na área de visão computacional que tratam do reconhecimento de padrões. LOWE (2004) apresenta um método para realizar a classificação confiável em diferentes angulos de visão de um objeto. O método utiliza atributos (i.e. características) que são invariantes à escala e rotação das imagens para classificar um objeto. Esses atributos também são parcialmente invariantes à iluminação.

Os estágios para gerar o conjunto de atributos são: identificação de pontos chaves (i.e. *keypoints*) invariantes à escala (e.g. detecção do maior valor de intensidade luminosa em uma matriz tridimensional, onde cada matriz representa diferentes escalas); atribuição de orientações para cada ponto chave (i.e. direção predominante de um histograma de orientações de gradiente no ponto-chave); e atribuição de descritores para cada ponto chave.

Essa abordagem foi intitulada de Transformada de Característica Invariante à Escala (*Scale Invariant Feature Transform - SIFT®*). O método gera uma quantidade grande de descritores, cada descritor referente a um ponto chave. A análise de semelhança desses descritores entre duas imagens pode ser realizada utilizando a distância Euclidiana (dE) entre dois pontos chave identificados P(x<sub>1</sub>,y<sub>1</sub>) e Q(x<sub>2</sub>,y<sub>2</sub>):

$$dE(P, Q) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} \quad (2.2)$$

Onde P(x<sub>1</sub>,y<sub>1</sub>) é um ponto chave localizado nas coordenadas x<sub>1</sub> e y<sub>1</sub> e Q(x<sub>2</sub>,y<sub>2</sub>) é outro ponto chave localizado nas coordenadas x<sub>2</sub> e y<sub>2</sub> de uma imagem. Pontos com menor distância Euclidiana (i.e. pontos próximos) tendem a ser o melhor candidato do objeto procurado.

Já BAY, TUYTELAARS e VAN GOOL (2006) apresentam em seu trabalho um método de identificação de objetos, chamado Características Robustas Aceleradas (*Speeded Up Robust Features - SURF®*), que é baseado em detector e descritores que usam pontos de interesse

invariantes a escala e rotação. Na análise dos pontos de interesse, os autores se basearam parcialmente no SIFT®. Na obtenção dos descritores, os autores utilizaram o conceito de Imagem Integral (*Integral Image*) definido por VIOLA e JONES (2001) e seus atributos em retângulos. Os resultados apresentados pelos autores em seus experimentos são interessantes, com taxa de acerto de reconhecimento de 82.6%.

Ambos os métodos apresentam características importantes para o reconhecimento de objetos tais como a utilização de atributos invariantes a escala e rotação. Entretanto, tais métodos são patenteados e a sua utilização em aplicações comerciais estão protegidas e devem ser autorizadas pelos seus autores. O método apresentado por LOWE (2004) é patenteado pela Universidade da Columbia Britânica (*University of British Columbia*) e SURF® é patenteado pelos seus autores.

Nesse mesmo contexto é que as técnicas Haar-like e Padrão Local Binário (*Local Binary Pattern - LBP*) se posicionam. Tais métodos foram apresentados, respectivamente, por VIOLA e JONES (2001) e OJALA, PIETIKAINEN e HARWOOD (1996). São técnicas que utilizam classificadores a partir de atributos extraídos dos objetos, para realizar o reconhecimento de padrões em uma imagem. Inicialmente, as técnicas Haar-like e LBP foram apresentadas para o reconhecimento de faces, mas também podem ser aplicadas para o reconhecimento de objetos.

A efetividade destas técnicas depende bastante da montagem do conjunto de amostras positivas (i.e. imagens dos objetos a serem identificados) e negativas (i.e. imagens que não contém os objetos). A quantidade e a qualidade destas amostras são fatores que irão influenciar o resultado final do processo de identificação.

Para o reconhecimento de automóveis com VANT, HUMMEL *et al.* (2014) utilizou 7.200 imagens de fundo aleatórias para montagem do conjunto de amostras negativas e 140.000 amostras positivas que foram geradas combinando imagens de automóveis (Figura 2.12) em diferentes ângulos de orientação do veículo ( $\gamma$ ) e de elevação da câmera ( $\alpha$ ) e em diversas alturas ( $h$ ).

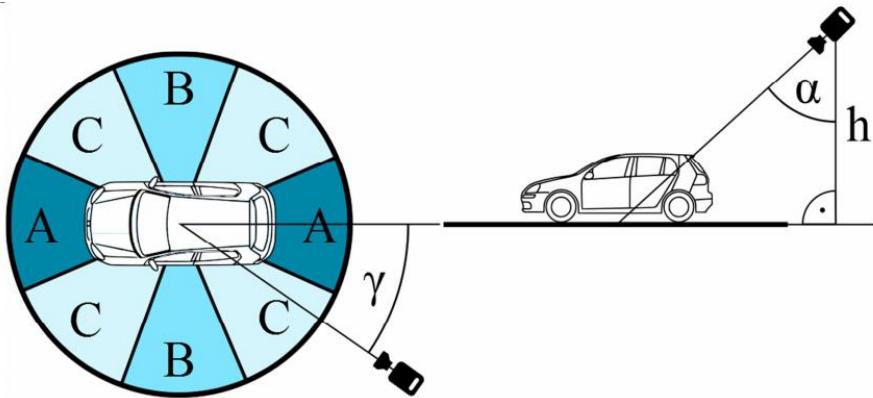


FIGURA 2.12 – Categorias para geração do conjunto de amostras positivas (HUMMEL, et al., 2014)

Nesta aplicação, a duração do processo de treinamento dos classificadores Haar-like, foi de até 2 semanas. No processo de treinamento dos atributos LBP, a duração dessa etapa foi de até 3 dias. Em ambos os casos, o treinamento foi executado em um computador de alto desempenho computacional com 276 núcleos de processamento e 2.048 GB de memória RAM. Os resultados demonstram um desempenho melhor dos classificadores Haar-like em comparação com os atributos LBP.

### 2.3.1 Características Haar-like

A grande maioria das técnicas de reconhecimento de objetos é baseada na seleção dos descritores do objeto a ser reconhecido. Descritores podem ser definidos como as características ou atributos de uma região da imagem ou de um objeto que serão utilizadas como um padrão de reconhecimento. Esses descritores podem ser utilizados de diferentes formas para identificar o objeto.

O algoritmo apresentado por VIOLA e JONES (2001) é baseado nos atributos Haar-like para a detecção visual de objetos e possui uma abordagem de aprendizado de máquina no reconhecimento de objetos. É proposto um ambiente para a identificação extremamente rápida e robusta de objetos e, para isso, utilizam atributos como classificadores tornando-o mais rápido do que em sistemas baseados em *pixel*. Outra característica importante, para esse trabalho é que ele pode ser implementado em dispositivos móveis e processadores embarcados.

VIOLA e JONES (2001) não tratam unicamente do reconhecimento de pessoas ou gestos, mas utilizam em seus experimentos o algoritmo para a identificação de faces e trabalha com imagens em tons de cinza para tornar o processamento mais rápido. As contribuições da pesquisa, segundo os autores, estão baseadas na:

- Representação intermediária da imagem chamada de Imagem Integral, que é baseada na soma das áreas de retângulos e permite que os atributos utilizados pelo detector sejam computados muito mais rapidamente;
- Utilização do algoritmo de aprendizagem da máquina AdaBoost, que seleciona um conjunto pequeno de atributos, que são chamados de classificadores fracos, os quais são devidamente combinados para se obter classificadores eficientes (i.e. fortes); e,
- Combinação dos classificadores em uma estrutura em cascata que melhora a rapidez da identificação de um objeto na imagem, pois a cada estágio o treinamento, ocorre a eliminação das regiões de fundo e prioriza o processamento das regiões onde podem conter os objetos.

Esse algoritmo é invariante a pequenas mudanças de translação e escala, pois utiliza atributos simples, para classificar as imagens.

Como exemplo, um atributo que será usado para a classificação das imagens pode ser obtido de uma combinação aritmética entre a soma da intensidade luminosa dos pixels que se encontram dentro de um ou mais retângulos brancos e a soma da intensidade luminosa dos pixels que se encontram dentro de um ou mais retângulos cinzas. Tais atributos, que são baseados no Haar-like (VIOLA e JONES, 2001 *apud* PAPAGEORGIOU, OREN e POGGIO, 1998) são determinados a partir das seguintes combinações aritméticas:

- Entre dois retângulos (Figura 2.13 - A e B), que usa a diferença da soma da intensidade luminosa de um retângulo branco e de um cinza. Neste caso os retângulos devem ter o mesmo tamanho e formato e devem ser adjacentes na horizontal ou vertical;
- Entre três retângulos (Figura 2.13 - C), que calcula diferença entre a soma da intensidade luminosa de dois retângulos externos e a soma da intensidade luminosa de um retângulo interno. Os três retângulos possuem a mesma dimensão e os dois retângulos externos são adjacentes às duas laterais verticais do retângulo interno; e
- Entre quatro retângulos (Figura 2.13 - D), que calcula diferença entre a soma das intensidades luminosas de dois retângulos diagonais e a soma das intensidades luminosas dos outros dois retângulos também diagonais.

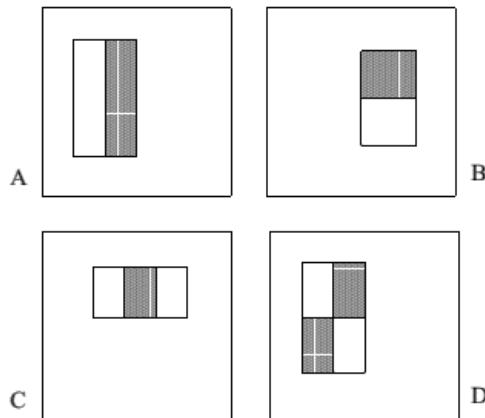


FIGURA 2.13 – Exemplos de atributos simples (VIOLA e JONES, 2001)

Os atributos retângulos podem ser calculados rapidamente usando uma representação intermediária da imagem. A Imagem Integral em um ponto de coordenadas  $x, y$  é determinado pela soma das intensidades luminosas dos pixels acima e a esquerda de  $x, y$  inclusive. A Equação 2.3 apresenta o cálculo da imagem integral:

$$ii(x, y) = \sum_{x'=1}^x \sum_{y'=1}^y i(x', y') \quad (2.3)$$

Onde  $ii(x, y)$  é a imagem integral e  $i(x, y)$  é a imagem original.

Assim, tendo como base a Figura 2.14, a Imagem Integral no ponto 4 ( $ii_4$ ), é  $IA + IB + IC + ID$ . O valor da imagem integral no ponto 1 ( $ii_1$ ) é a soma dos pixels no retângulo A. O valor no ponto 2 ( $ii_2$ ) é dado por  $IA + IB$  e no ponto 3 ( $ii_3$ ),  $IA + IC$ . Onde IA, IB, IC e ID são respectivamente as somas das intensidades luminosas dos pixels contidos nas áreas delimitadas pelos retângulos A, B, C e D.

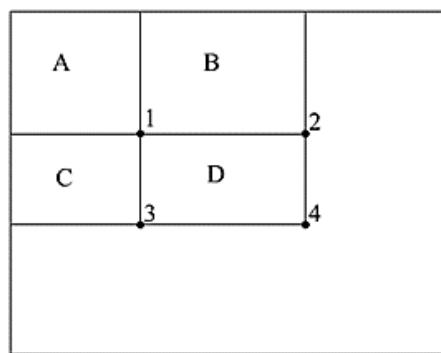


FIGURA 2.14 – Exemplo para cálculo de área para uma Imagem Integral (VIOLA e JONES, 2001)

Em consequência disso, ID pode ser calculada pela Equação 2.4.

$$ID = ii_4 + ii_1 - (ii_2 + ii_3) \quad (2.4)$$

No sistema proposto por VIOLA e JONES (2001), a seleção dos atributos dentro de um conjunto de imagens e o treinamento do classificador é realizado por uma variante do algoritmo AdaBoost. Ao invés de utilizar todos os atributos retângulos do AdaBoost original, os autores sugerem a utilização de poucos atributos combinados para obter um classificador mais efetivo. Na classificação em cascata, cada estágio do treinamento irá descartar regiões que não contém o objeto buscado com a finalidade de diminuir a taxa de falso positivo e, por fim, aumentar a taxa de reconhecimento.

### 2.3.2 Padrão Local Binário (LBP)

O LBP se baseia num modelo de análise de textura chamada de Unidade de Textura (*Texture Unit* - TU) que foi introduzida por WANG e HE (1990). A TU é representada por oito elementos em uma área de 3 por 3 pixels. Com isso o espaço de busca será reduzido.

Assim, a intensidade luminosa do ponto central será comparada com as intensidades dos demais elementos da matriz. O resultado é discretizado em três níveis possíveis (i.e. 0, 1 e 2). Neste caso existem 6.561 (i.e.  $3^8$ ) valores possíveis de TU. Além disto, o espectro da textura pode ser obtido pela representação da distribuição da TU em uma determinada região.

Mais tarde, OJALA, PIETIKAINEN e HARWOOD (1996), usaram este método para a analisar as texturas em imagens. Segundo os autores, a textura da imagem pode ser considerada como um atributo importante a ser analisado. Valores atribuídos às texturas são usados para realizar a classificação do objeto buscado. Entretanto, ao se utilizar esses valores, muitas informações importantes podem ser perdidas.

OJALA, PIETIKAINEN e HARWOOD (1996) introduziram uma versão simplificada do TU na qual a discretização foi feita em dois níveis, permitindo assim a utilização de uma representação binária (i.e. 0 ou 1). A discretização é obtida pela comparação da intensidade luminosa de um pixel central com os demais elementos da matriz. Dessa forma, o espaço amostral da TU é reduzido para 256 (i.e.  $2^8$ ) valores, ao invés dos 6.561 da proposta original.

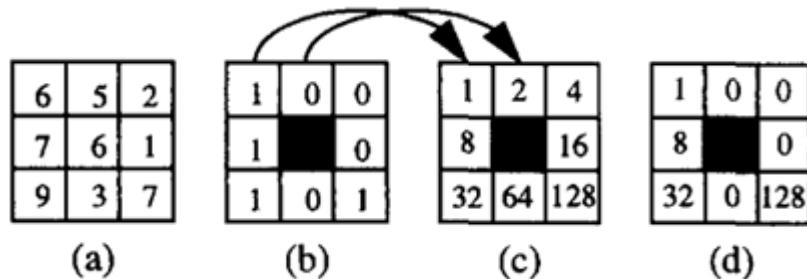


FIGURA 2.15 – Exemplo de cálculo do valor de TU (OJALA, PIETIKAINEN e HARWOOD, 1996)

Nessa nova versão, pixels com intensidade luminosa maior ou igual ao do pixel central receberão o valor 1 (um), caso contrário este pixel terá o valor 0 (zero). Uma palavra de oito bits com os valores resultantes será formada. O bit mais significativo representa o resultado obtido da comparação com o pixel do canto inferior direito. Os bits subsequentes serão ordenados linha por linha. Como exemplo, Na Figura 2.15a, considerando que os valores contidos na matriz 3x3 representam a intensidade luminosa de cada pixel, na Figura 2.15-b, a comparação (Figura 2.15-b) resultaria na representação binária igual a 10101001 (Figura 2.15-c) para o TU. Em seguida, esse valor binário deverá ser convertido para a forma decimal que corresponde ao valor de TU da região (i.e. TU = 169).

LIAO, *et al.* (2007), em seu trabalho, apresenta uma nova abordagem para aplicação em reconhecimento de faces e utiliza uma representação em escala múltipla do LBP (MB-LBP). Dessa forma, os autores expandiram a região de análise para uma matriz de 9 por 9 pixels, onde cada elemento, é uma matriz de 3 por 3 pixels (Figura 2.16).

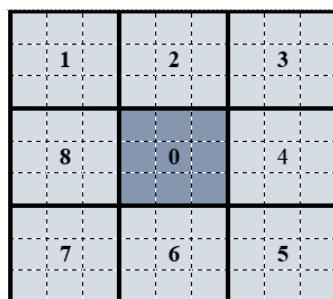


FIGURA 2.16 – Representação MB-LBP 9 por 9 pixels

Assim, a soma das intensidades dos pixels de cada elemento (i.e. cada sub-região formada por uma matriz de 3 por 3 pixels) é comparada com a da região central usando o processo introduzido por OJALA, PIETIKAINEN e HARWOOD (1996).

### 3 Desenvolvimento

Este capítulo apresenta o desenvolvimento do trabalho, seus métodos e os meios utilizados para a sua avaliação experimental.

As etapas de pesquisa bibliográfica e levantamento do referencial teórico foram de grande valia para a definição dos materiais a serem utilizados durante os experimentos. Sem essa etapa, haveria grande dificuldade para se definir a solução ótima a ser utilizada para o reconhecimento de padrões e para o desenvolvimento das ferramentas.

Para a implementação das técnicas escolhidas, considerou-se a possibilidade de se utilizar o ambiente de programação Matlab® que é um aplicativo de cálculo numérico, desenvolvido pela empresa Mathworks. O Matlab® permite o desenvolvimento de rotinas para análise e visualização de dados em um ambiente de desenvolvimento com linguagem de programação própria. Este ambiente utiliza matrizes de dados como componente básico, e disponibiliza uma série de operações nativas para manipulação de vetores e matrizes. Também oferece várias ferramentas complementares (e.g. Processamento de Imagens e Visão Computacional, Processamento Digital de Sinais e Sistemas Embarcados) que podem ser incorporadas ao Matlab® para o desenvolvimento de aplicações específicas.

Entretanto, neste trabalho, optou-se por utilizar todo o ambiente e ferramentas de programação baseados em ferramentas abertas. Como já mencionado, apesar deste trabalho ser o desenvolvimento de um projeto acadêmico, o resultado e a evolução do que estão sendo apresentados podem resultar em um produto comercial. Portanto, a utilização de ferramentas, tecnologias, métodos e técnicas de uso livre (i.e. sem obrigação de acordos comerciais para o seu uso), foi o principal requisito que norteou a seleção das possíveis alternativas. Assim, o ambiente de sistema operacional utilizado neste trabalho foi o Linux.

Linus Torvalds em 1991 apresentou a primeira versão oficial do núcleo (*kernel*) do sistema operacional Linux o qual logo em seguida se integrou ao Projeto GNU desenvolvido por Richard Stallman. Tal projeto fornecia uma série de ferramentas complementares. O GNU/Linux é baseado no UNIX, que é um sistema operacional multiusuário e multitarefa bastante utilizado em estações de trabalho (i.e. *workstations*). O Linux é distribuído por meio de uma Licença Pública Geral (*General Public License - GPL*) que permite ao usuário acessar, modificar e distribuir o código fonte de acordo com as suas necessidades. Dessa forma, é

possível alterar o seu código fonte e criar uma versão para ser comercializada, desde que essa versão seja distribuída com o código fonte. Assim, diversas distribuições surgiram desde a sua criação, tais como o Debian, Slackware, Red Hat e SuSe. Neste trabalho, a versão selecionada foi o Ubuntu Desktop 13.10, que é baseado na distribuição Debian.

Como ambiente de programação, optou-se por utilizar o OpenCV. Este ambiente é multiplataforma e pode ser definido como um poderoso conjunto de bibliotecas (i.e. *framework*) de código aberto com rotinas que são utilizadas para o desenvolvimento de programas na área de visão computacional. Esta biblioteca contém centenas de funções e algoritmos, tais como ferramentas de manipulação de imagens e de vídeo. Por ser de código aberto, existe uma grande comunidade com milhares de desenvolvedores que utilizam este ambiente para a criação de novos aplicativos de visão computacional nas mais diversas áreas de conhecimento. O OpenCV pode ser utilizado com as linguagens de programação Java, Python, C e C++ e permite o desenvolvimento de aplicativos que serão executados nos sistemas operacionais Windows, Lixux, Mac OS, iOS e Android. Ele possui uma estrutura modular com diversos pacotes disponíveis tais como o:

- *imgproc* - para processamento de imagens com funções de filtragem, transformações e histograma;
- *highgui* - que é uma interface para captura de vídeos e imagens;
- vídeo - que engloba funções de análise de vídeos; e
- gpu - que disponibiliza algoritmos para utilização de Unidades de Processamento Gráficos (*Graphic Processing Unit – GPU*).

A versão do OpenCV utilizada foi a 2.4.8 e a linguagem de programação utilizada foi o C++.

As técnicas de reconhecimento de padrões selecionadas foram os classificadores Haar-like (VIOLA e JONES, 2001) e o LBP (LIAO, *et al.*, 2007). Alguns fatores contribuíram para essa escolha. Apesar do OpenCV disponibilizar suporte aos algoritmos de reconhecimento SIFT® e SURF®, a utilização desses algoritmos é permitida somente para fins acadêmicos, por possuírem patentes registradas em alguns países. Assim, sua utilização para fins comerciais requer a autorização dos autores registrados. Este trabalho não possui fins comerciais, mas por haver, posteriormente, a possibilidade da continuidade da pesquisa e consequentemente, o desenvolvimento de um produto comercial, essas técnicas foram descartadas. O OpenCV possui uma biblioteca intitulada nonfree, a qual contém rotinas para implementação dos algoritmos SIFT® e SURF®, mas informa que eles são patenteados (OPENCV DEV TEAM, 2011-2013)

e, portanto, que a utilização dos mesmos está condicionada ao atendimento de determinadas regras de proteção de propriedade intelectual.

Outro fator importante, é que o OpenCV possui ferramentas e rotinas específicas para implementação dos classificadores Haar-like e LBP. Na etapa de treinamento, o OpenCV disponibiliza uma ferramenta para execução desta tarefa, que permite a configuração de alguns parâmetros. Na etapa de classificação, a saída gerada pelo treinamento é utilizada como parâmetro de entrada em rotinas de reconhecimento. Estas características são adequadas para a aplicação pretendida e também contribuíram para escolha.

Definidos o ambiente de desenvolvimento e as ferramentas que foram utilizadas, outros requisitos foram avaliados.

Para avaliação inicial do sistema os experimentos seriam realizados a partir de imagens de vídeos gravados pelo IPEV em campanhas de ensaios de separação de carga externa. Neste contexto, os vídeos analisados deveriam ter sido gravados em alta velocidade e em alta resolução.

Em um primeiro momento, havia uma grande motivação para que os experimentos fossem executados com imagens oriundas de uma campanha de ensaios em voo real. Assim, seriam aproveitados os voos de instrução que fazem parte do currículo do Curso de Ensaios em Voo (CEV), que é ministrado pela EFEV, para a realização dos experimentos e validação das técnicas propostas. Entretanto o sucesso desta estratégia depende principalmente do arranjo perfeito de tempo entre o desenvolvimento de um protótipo funcional e a realização da campanha de ensaios de separação de cargas do CEV. Apesar de o arranjo parecer difícil, o que definitivamente impossibilitou essa ação foi o fato de que o IPEV não possui câmeras de vídeo com saídas de imagens de alta velocidade e de resolução em tempo real. Assim as imagens capturadas serão armazenadas em dispositivos de memória e, portanto, a análise só ocorrerá após o voo.

Além dos vídeos registrados em campanhas de ensaios de separação de cargas, foi planejada a realização de ensaios de separação de cargas em solo, em condições controladas. Os vídeos gravados nesta aplicação também foram utilizados nos experimentos de validação.

### 3.1 Processo de identificação de alvos

O processo de identificação de alvos utilizando os atributos Haar-like e LBP é composto de duas etapas distintas e igualmente importantes. Na primeira etapa, é necessário realizar o treinamento dos classificadores. Em seguida, com os resultados dessa etapa, é realizada a identificação dos alvos. A Figura 3.1 apresenta as duas etapas do processo de identificação de alvos. Entretanto, considerando que a efetividade do processo de identificação de alvos é muito dependente da qualidade das imagens, faz-se necessário a utilização de operações de tratamento dos quadros (e.g. equalização do histograma) em uma fase de pré-processamento.

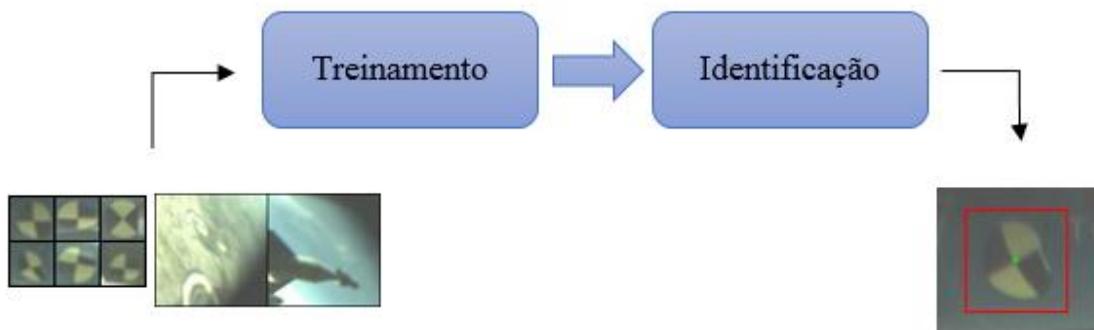


FIGURA 3.1 – Etapas de Treinamento e Identificação do processo de identificação de alvos

Na etapa de Treinamento é necessária a preparação das entradas (i.e. imagens) que serão aplicadas nesse processo. Geralmente, as imagens são segmentadas em regiões de interesse as quais poderão conter ou não a projeção da vista do objeto que queremos identificar. Assim define-se como amostra positiva, um segmento da imagem que contém informações do objeto a ser identificado, caso contrário, o segmento é classificado como amostra negativa. A Figura 3.2, apresenta diversos exemplos de amostras positivas aplicadas no processo de treinamento para a identificação de alvos.



FIGURA 3.2 - Exemplos de amostras positivas em imagens de alvos.

Todas as amostras positivas devem possuir a mesma dimensão. As amostras negativas podem ter dimensões diferentes. A composição desses conjuntos de imagens, positivas e

negativas, pode ser decisiva para o sucesso da identificação. Como exemplo, no processo de identificação de automóveis em imagens é necessário compor o conjunto de imagens positivas de milhares de amostras dos veículos para que seja construído um bom classificador. No caso específico deste trabalho, como os alvos variam pouco no seu formato, portanto, é possível utilizar uma quantidade menor de amostras.

O OpenCV fornece ferramentas para a realização do treinamento dos classificadores. Para tanto, além das amostras positivas e negativas são necessários o atendimento de outros requisitos complementares. A Figura 3.3 apresenta as etapas necessárias para a execução do treinamento.

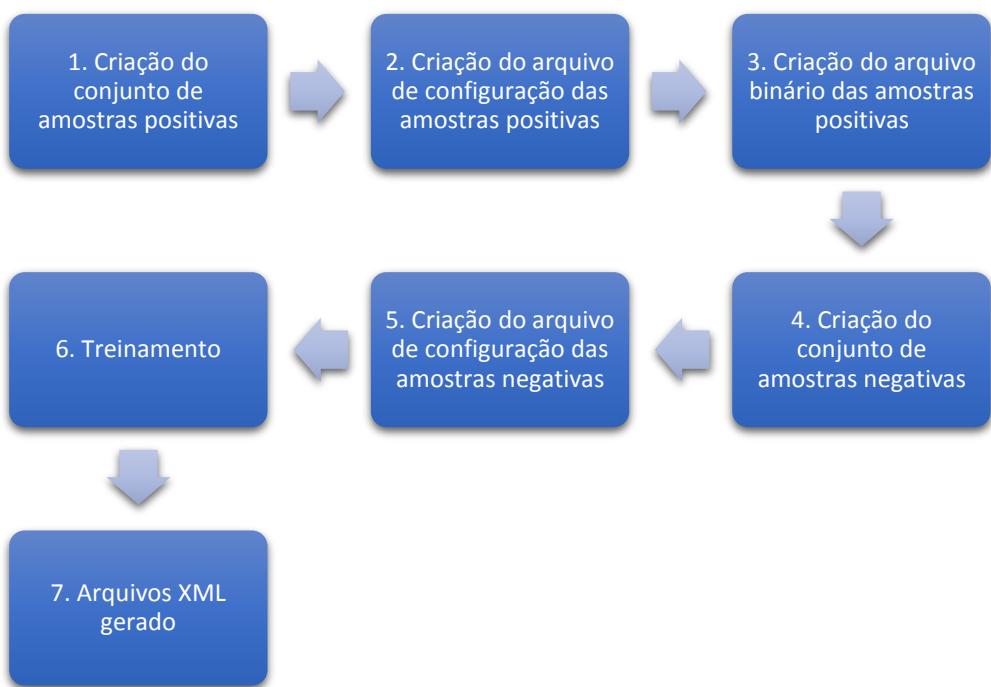


FIGURA 3.3 – Processo de Treinamento

O primeiro passo é criar um conjunto de amostras positivas. Depois, um arquivo de configuração deve ser criado. Este arquivo, que é formatado em texto, contém o endereço relativo de cada amostra positiva, além de possuir informações da quantidade de objetos em cada amostra e das coordenadas desses objetos na imagem. A Figura 3.4 apresenta um exemplo do conteúdo de um arquivo de configuração de amostras positivas. O primeiro parâmetro é o endereço do arquivo da imagem, o segundo parâmetro é a quantidade de objetos na imagem e mais quatro parâmetros que são: as coordenadas  $x$  e  $y$  do canto superior e esquerdo do retângulo que contém o objeto buscado e suas dimensões (largura e altura).

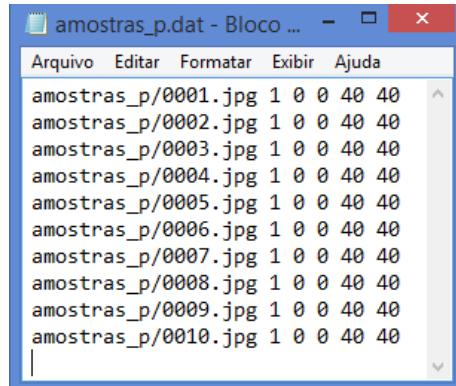


FIGURA 3.4 – Exemplo de arquivo de configuração de amostras positivas

Esse arquivo de configuração é utilizado como entrada para a criação de um arquivo binário que localiza e identifica as amostras positivas. Em seguida, o conjunto de amostras negativas deve ser criado. A Figura 3.5 apresenta exemplos de amostras negativas utilizadas no processo.



FIGURA 3.5 – Exemplo de amostras negativas

Da mesma forma, é necessário criar um arquivo de configuração das amostras negativas. Entretanto, nesse caso, este arquivo contém somente o endereço relativo aos arquivos com as amostras negativas. A Figura 3.6 apresenta um exemplo de arquivo de configuração de amostras negativas.

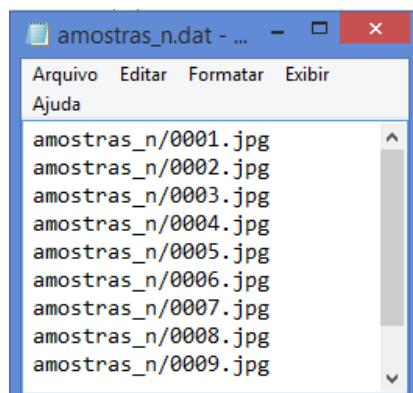


FIGURA 3.6 – Exemplo de arquivo de configuração de amostras negativas.

Com esses elementos, é possível executar o treinamento dos classificadores. O AdaBoost seleciona através das amostras positivas, os atributos Haar-like ou LBP, que são os

classificadores fracos, que serão utilizados a cada estágio no processo de identificação. Em cada estágio, as amostras negativas são utilizadas para descartar regiões que não contém o alvo. Para ser considerado um provável alvo, a região deve passar por todos os estágios.

O resultado desse treinamento tem como produto um arquivo em formato de Linguagem de Marcação Extensível (*eXtensible Markup Language* - XML). O XML é um padrão do Consórcio Mundial de Redes (*World Wide Web Consortium* - W3C), e é utilizado principalmente para tramitação de dados na Rede (W3C, 2014). Atualmente, o XML é utilizado em consultas a banco de dados que retornam os valores nesse formato ou em serviços de rede (i.e. *webservices*). Um exemplo conhecido de um serviço de rede é a consulta de CEP disponibilizada pelos Correios. Qualquer sítio pode enviar um CEP para este serviço que retorna as informações do endereço postal que são formatadas em XML. O XML é um arquivo texto e possui uma estrutura de forma hierárquica que usa marcadores, tal qual a Linguagem de Marcação de Hipertexto (*HyperText Markup Language* - HTML).

No caso específico do processo de treinamento, o arquivo XML gerado contém os valores dos classificadores fracos gerados em cada estágio para composição do classificador forte e dos atributos utilizados na identificação.

## **3.2 Experimento com vídeo de ensaios IPEV**

### **3.2.1 Preparação**

Para a realização do primeiro experimento, foi feito um levantamento dos vídeos de ensaios de separação de carga disponíveis no IPEV e diante de algumas opções optou-se pelos vídeos da campanha de ensaios intitulada Operação Poker, pois as imagens tinham uma resolução aparentemente melhor que as de outras companhias de ensaios.

A Operação Poker tinha como finalidade o desenvolvimento no Brasil de uma bomba guiada a laser. Uma das etapas do desenvolvimento aconteceu em 2012 com a participação do IPEV. Na etapa de certificação do armamento, dados obtidos nos ensaios de separação de carga foram necessários para se demonstrar a operação segura do armamento. A plataforma de lançamento utilizada foi a aeronave A-1 (AM-X). A Figura 3.7 apresenta a configuração do armamento utilizado no lançamento da carga externa durante a campanha de ensaio em voo.



FIGURA 3.7 – Configuração do armamento na aeronave plataforma A-1  
(DEPARTAMENTO DE CIÊNCIA E TECNOLOGIA AEROESPACIAL, 2012)

As câmeras de vídeo foram instaladas em um casulo fotográfico, embaixo da aeronave. Foram utilizadas duas câmeras da marca Mikrotron, modelo MotionBLITZ EoSens® Cube7. Esta camera pode capturar imagens a uma velocidade de até 1640 quadros por segundo com uma resolução de 1280 por 720 pixels. Possui gatilho com acionamento físico ou lógico por meio da rede Ethernet Rápida ou Gigabit (i.e. 100 Mbps/1000 Mbps), memória interna para gravação de até 12 segundos em alta resolução em alta velocidade. A Figura 3.8 apresenta a câmera de vídeo Cube 7 da Microtron.



FIGURA 3.8 - Câmera MotionBLITZ EoSens® Cube7 da Mikrotron (MIKROTRON, 2012)

Dentre as imagens disponíveis, foi escolhido um vídeo que tinha a melhor iluminação e contraste visual. As imagens foram registradas com a resolução de 1152 por 1320 pixels e amostradas com 400 qps. No total, o vídeo era composto por 270 quadros e o tamanho do arquivo era de 1,55 GB. A Figura 3.9 apresenta quatro imagens do vídeo analisado.

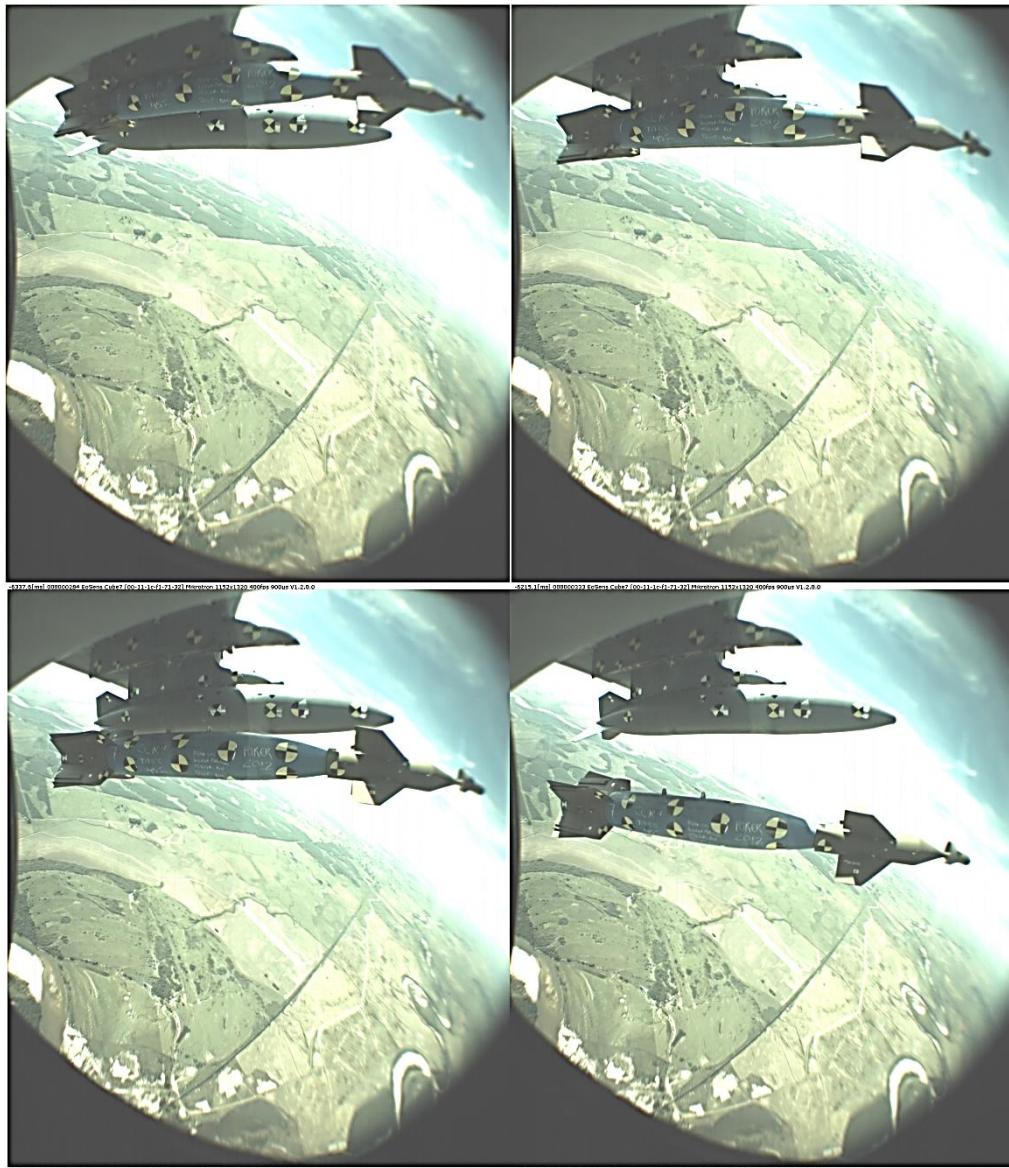


FIGURA 3.9 – Quadros 4, 53, 75 e 98 do vídeo analisado

As bordas dos quadros da Figura 3.9, apresentam uma grande distorção, pois na aplicação foi utilizada uma lente do tipo “olho de peixe”. Esse tipo de lente é utilizado para capturar uma área maior da imagem com objetos próximos. Tipicamente tais lentes podem possuir uma abertura angular de até 180°.

Nesta aplicação a determinação da trajetória da separação com 6DoF requer a utilização de um modelo para minimização dos erros decorrentes das distorções do sistema óptico. O

desenvolvimento e a validação deste modelo não fazem parte do contexto deste trabalho e, portanto, não serão considerados.

A fim de evitar que as distorções das bordas das imagens pudessem prejudicar a aplicação das técnicas de processamento de imagem, a análise foi limitada aos primeiros 100 quadros do vídeo. A partir desse ponto, os quadros foram descartados e desconsiderados no experimento.

Esta delimitação foi utilizada para possibilitar a adoção de uma métrica de avaliação dos resultados obtidos da aplicação das técnicas para identificação de alvos. A finalidade de se utilizar uma sequência de imagens não visa ao rastreamento dos alvos no vídeo. Tal estratégia, foi adotada para se aumentar o espaço amostral de identificação positiva de alvos. Além disto, o processo de rastreamento, o qual não faz parte do escopo deste trabalho, utiliza outras técnicas, pois tratam com outras especificidades. Entretanto, a localização de alvos é ponto de origem do processo de rastreamento.

### **3.2.1.1 Criação do conjunto de amostras positivas**

O conjunto de amostras positivas foi composto a partir de imagens de alvos de diferentes fontes de dados e de ROI que foram segmentadas do vídeo analisado. Para o primeiro experimento, o conjunto de amostras positivas foi composto de 240 imagens positivas. Todas as imagens foram redimensionadas para que tivessem a dimensão de 20 por 20 pixels (Figura 3.10).

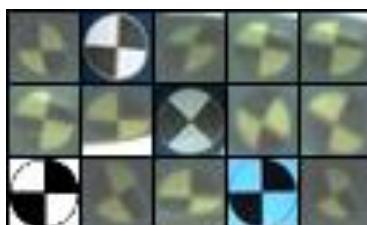


FIGURA 3.10 - Exemplos de amostras positivas utilizadas no processo de treinamento

Neste experimento, o tratamento de todas as imagens (i.e. edição, recorte e redimensionamento) foi realizado de forma manual, utilizando para isso, o programa de edição de imagens chamado GIMP (i.e. *GNU Image Manipulation Program*). A definição do GIMP está de acordo com a diretriz básica deste trabalho, pois também segue os conceitos do programa de uso livre.

Os quadros da sequência de vídeo foram armazenados como uma imagem no formato de Portabilidade Gráfica em Rede (*Portable Network Graphics - PNG*) e assim, foram retiradas dessas imagens apenas a ROI com o alvo a ser identificado.

### 3.2.1.2 Criação do arquivo de configuração e binário das amostras positivas

Ao se executar o processo de treinamento é necessário informar ao programa de controle, onde estão as imagens que serão utilizadas. Para isso, utiliza-se um arquivo de configuração (Figura 3.11), o qual é formatado em texto e contém o endereço relativo de cada arquivo com imagens positivas, suas coordenadas e dimensões.

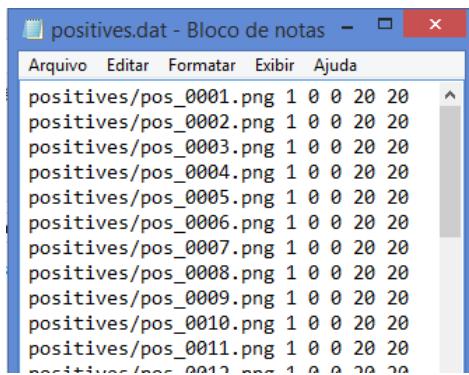


FIGURA 3.11 – Extrato do arquivo de configuração de amostras positivas

As coordenadas, largura e altura são representadas em pixels. Assim, neste experimento, o arquivo gerado continha 240 linhas.

Depois da criação do arquivo de configuração, é necessário criar um arquivo binário (i.e. formato.vec). Esse arquivo armazena todas as amostras em um vetor sem a aplicação de nenhuma forma de distorção das imagens. O OpenCV inclui uma ferramenta para realizar essa tarefa. O utilitário *opencv\_createsamples* tem como variáveis de entrada o nome do arquivo de configuração (i.e. *-info*), o nome do arquivo binário a ser criado (i.e. *-vec*), a largura (i.e. *-w*) e altura (i.e. *-h*) das amostras e a quantidade de amostras positivas (i.e. *-num*). Nesta aplicação, a execução do utilitário foi iniciada com o seguinte comando:

```
$ opencv_createsamples -info positives.dat -vec samples.vec -w 20 -h 20 -num 240
```

Com isso o resultado da execução foi o seguinte:

```

Info file name: positives.dat
Img file name: (NULL)
Vec file name: samples.vec
BG file name: (NULL)
Num: 240
BG color: 0
BG threshold: 80
Invert: FALSE
Max intensity deviation: 40
Max x angle: 1.1
Max y angle: 1.1
Max z angle: 0.5
Show samples: FALSE
Width: 20
Height: 20
Create training samples from images collection...
Done. Created 240 samples

```

O arquivo *samples.vec* criado será utilizado como parâmetro de entrada no processo de treinamento.

### 3.2.1.3 Criação do conjunto de amostras negativas

As amostras negativas utilizadas neste experimento foram retiradas do próprio vídeo a ser analisado além de diferentes fontes. Foram utilizadas 500 imagens negativas com diferentes dimensões. As imagens negativas (i.e. images de fundo) não podem conter o objeto de interesse, e, por definição, devem ser maiores que a dimensão definida para as amostras positivas.

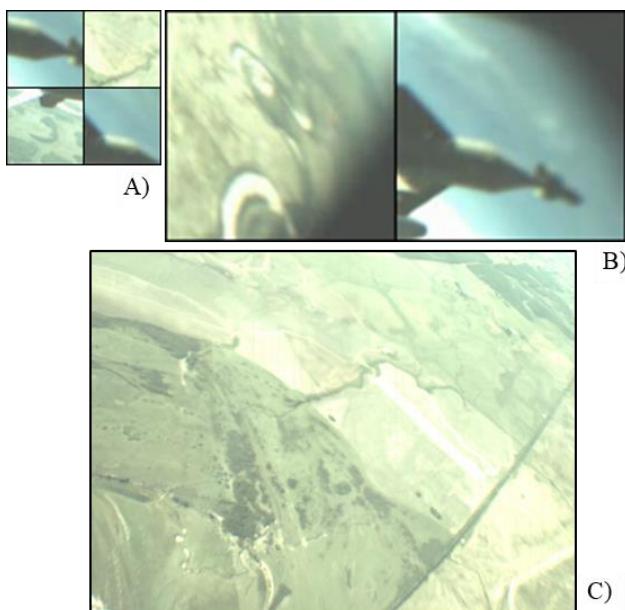


FIGURA 3.12 - Exemplos de amostras negativas utilizadas no processo de treinamento

A Figura 3.12 apresenta algumas imagens negativas utilizadas no experimento. Foram utilizadas imagens com dimensões de 53 por 53 pixels (Figura 3.12 - A), 125 por 125 pixels (Figura 3.12 - B) e 640 por 480 pixels (Figura 3.12 - C).

### 3.2.1.4 Criação do arquivo de configuração das amostras negativas

O arquivo de configuração das amostras negativas também é um arquivo texto e contém a localização relativa de cada arquivo de imagens negativas. Cada linha do arquivo (i.e. *negatives.dat*) define o nome do arquivo com a imagem negativa (Figura 3.13).

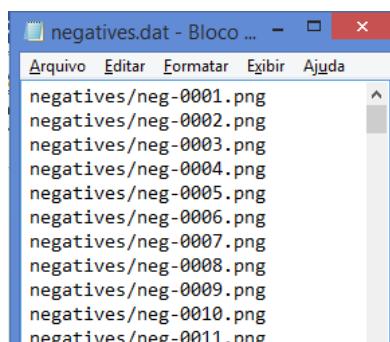


FIGURA 3.13 - Extrato do arquivo de configuração de amostras negativas

### 3.2.2 Processo de Treinamento

Com todos os componentes disponíveis, o processo de treinamento foi realizado utilizando uma ferramenta do OpenCV chamada *opencv\_traincascade*. Essa ferramenta disponibiliza a opção para o treinamento utilizando os atributos do Haar-like ou do LBP.

TABELA 3.1 - Relação de parâmetros gerais (OPENCV DEV TEAM, 2011-2014)

Parâmetro	Descrição
<i>-data &lt;cascade_dir_name&gt;</i>	Diretório onde será armazenado o classificador treinado (i.e. o arquivo XML).
<i>-vec &lt;vec_file_name&gt;</i>	Nome do arquivo binário das amostras positivas criado pela ferramenta <i>opencvcreatesamples</i> .
<i>-bg &lt;background_file_name&gt;</i>	Nome do arquivo de configuração das amostras negativas.
<i>-numPos &lt;number_of_positive_samples&gt;</i>	Quantidade de amostras positivas utilizadas no treinamento.
<i>-numNeg &lt;number_of_negative_samples&gt;</i>	Quantidade de amostras negativas utilizadas no treinamento.
<i>-numStages &lt;number_of_stages&gt;</i>	Quantidade de estágios em cascata.
<i>-precalcValBufSize &lt;calculated_vals_buffer_size_in_Mb&gt;</i>	Tamanho da memória temporária (i.e. <i>buffer</i> ) requerida para armazenar os valores dos atributos precalculados, em Mb.
<i>-precalcIdxBufSize &lt;calculated_idxs_buffer_size_in_Mb&gt;</i>	Tamanho da memória temporária requerida para armazenar os índices dos atributos precalculados, em Mb. Quanto maior for esse valor, mais rápido será o processo de treinamento.

Assim, algumas configurações devem ser definidas na execução da ferramenta. Para isso deve-se utilizar os parâmetros gerais (Tabela 3.1).

Em relação aos parâmetros do processamento em cascata, é necessário informar qual o tamanho das imagens positivas e quais os atributos (i.e. Haar-like ou LBP) que serão utilizados no treinamento (Tabela 3.2).

TABELA 3.2 - Relação de parâmetros de processamento em cascata (OPENCV DEV TEAM, 2011-2014)

Parâmetro	Descrição
<code>-featureType &lt;{HAAR(default), LBP}&gt;</code>	Seleciona o tipo dos atributos utilizados - Haar-like ou LBP.
<code>-w &lt;sampleWidth&gt;</code>	Largura em pixels das amostras positivas
<code>-h &lt;sampleHeight&gt;</code>	Altura em pixels das amostras positivas

Alguns parâmetros do algoritmo AdaBoost também devem ser definidos (Tabela 3.3).

TABELA 3.3 – Relação de parâmetros AdaBoost (OPENCV DEV TEAM, 2011-2014)

Parâmetro	Descrição
<code>-minHitRate &lt;min_hit_rate&gt;</code>	Taxa mínima desejada de sucesso requerida para cada estágio do classificador.
<code>-maxFalseAlarmRate &lt;max_false_alarm_rate&gt;</code>	Taxa máxima requerida de falsos positivos para cada estágio do classificador.

Na avaliação inicial, a ferramenta foi executada duas vezes. Uma vez configurada com os atributos Haar-like e outra com os atributos LBP. Assim, os seguintes parâmetros Haar-like foram configurados:

```
$ opencv_traincascade -data haar -vec samples.vec -bg negatives.dat -numPos 240 -numNeg 500 -numStages 20 -featureType HAAR -minHitRate 0.999 -maxFalseAlarmRate 0.5 -w 20 -h 20 -precalcIdxBufSize 256
```

As únicas modificações realizadas para a execução dos atributos LBP, foram: a alteração do parâmetro *data* para o valor “lbp” e do parâmetro *featureType* para o valor “LBP”.

Foram definidos 20 estágios com 99,9% de taxa mínima de acerto e 50% de taxa máxima de alarmes falsos. O parâmetro *precalcIdxBufSize* foi configurado para 256 (i.e. 256 Mb).

O treinamento foi executado em um computador portátil Dell Inspiron 14z, Intel® Core™ i7-3537U CPU @ 2.00GHz × 4, 8GB DDR3, 500GB 5400 RPM SATA HDD e 32GB mSATA SSD. O sistema operacional utilizado foi o Ubuntu Desktop 13.10.

Logo nessa etapa já foi possível verificar a enorme diferença de tempo de execução do processo de treinamento utilizando os atributos Haar-like e LBP. Utilizando as 240 amostras positivas e 500 amostras negativas, o processo com o Haar-like demorou 01 hora, 18 minutos e 9 segundos. Utilizando o LBP, o processo de treinamento foi realizado em somente 34 minutos e 17 segundos (Figura 3.14).

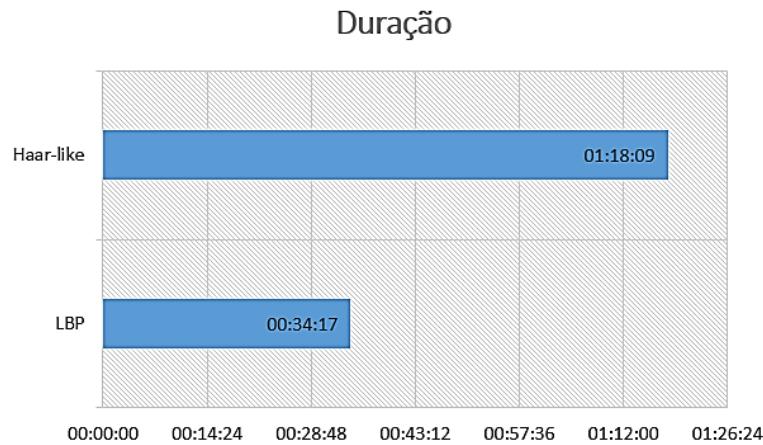


FIGURA 3.14 - Gráfico comparativo entre o tempo de treinamento dos atributos Haar-like e LBP.

A saída do processo de treinamento e especificamente, da ferramenta *opencv\_traincascade* é um arquivo XML (i.e. *cascade.xml*).

### 3.2.3 Processo de Identificação

Para o processo de identificação foi desenvolvido um protótipo para validação da aplicação das técnicas na identificação dos alvos. O protótipo foi desenvolvido na linguagem C++, com suporte às rotinas e classes do OpenCV.

O algoritmo desenvolvido para realizar o processo de identificação deve ler o arquivo de saída gerado pelo processo de treinamento (i.e. *cascade.xml*) e o vídeo a ser analisado. Em cada quadro do vídeo (Figura 3.15-a), são aplicadas transformações para geração da imagem em escala de cinza (Figura 3.15-b) e a equalização do seu histograma (Figura 3.15-c) para melhorar o contraste da imagem. O histograma representa a função de distribuição de ocorrência dos diversos níveis de cinza em uma imagem.



FIGURA 3.15 - a) Quadro original, b) quadro em escala de cinza e c) após equalização do histograma

A classe *CascadeClassifier*, disponível no OpenCV, é utilizada na operação de detecção de objetos. Neste trabalho, foi utilizada a função *detectMultiScale* que realiza o reconhecimento de objetos em diferentes tamanhos na imagem de entrada. Assim, cada quadro é lido e passado como parâmetro de entrada para a função, que retorna os alvos identificados em um vetor de retângulos. Cada elemento do vetor de retângulos representa a localização de um alvo identificado pelo algoritmo. Com isso, cada alvo é sinalizado na imagem analisada.

Os parâmetros para identificação são: *minSize* e *maxSize*, que respectivamente definem a dimensão mínima e máxima possível dos alvos. Nesta aplicação estas variáveis foram configuradas com os valores de 20 por 20 pixels para *minSize* e de 80 por 80 pixels para o *maxSize*. Os alvos com dimensões menores que *minSize* e maiores que *maxSize* serão descartados.

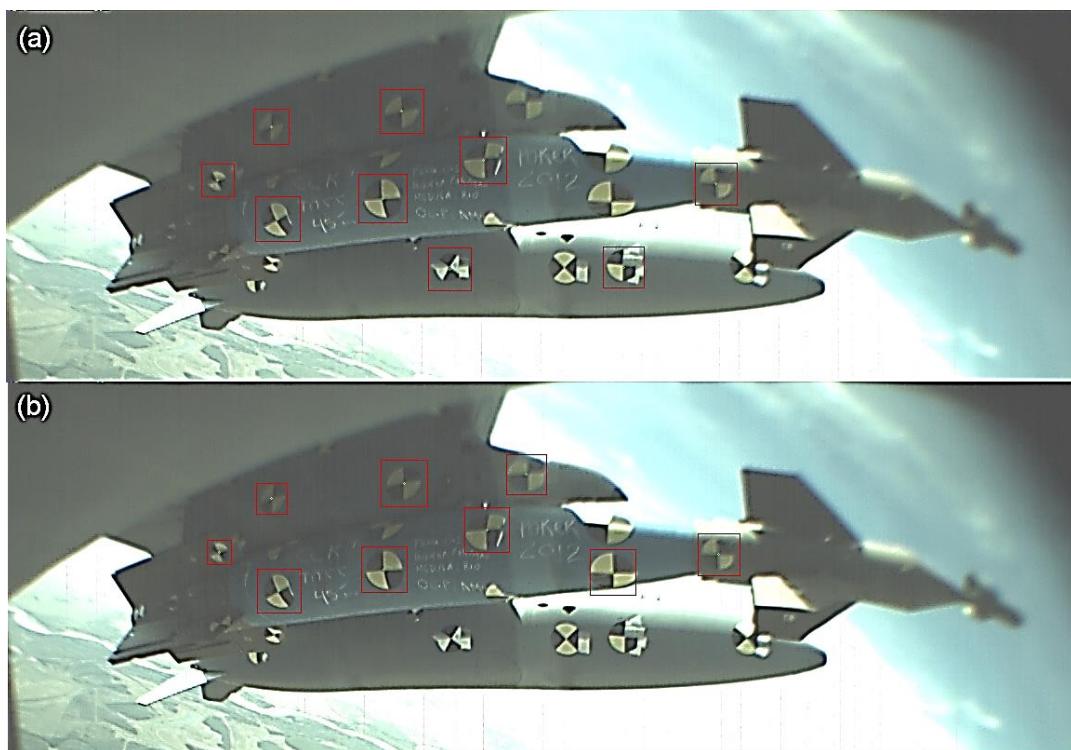


FIGURA 3.16 - Resultado do processo de identificação utilizando os atributos Haar-like (a) e LBP (b) - Quadro n° 1 (KUSUMOTO, et al., 2014)

Os alvos identificados foram sinalizados por um retângulo vermelho. Para a validação do algoritmo foram considerados somente os alvos que estão na superfície da carga. Os alvos no pilone e no tanque foram desconsiderados para o cálculo. Como resultado da análise do primeiro quadro da sequência de vídeo, é possível verificar que os resultados do processo de identificação dos dois atributos foram quase idênticos, sendo que o LBP (Figura 3.16-b) conseguiu identificar um alvo a mais que o Haar-like (Figura 3.16-a).

Entretanto, no quadro de número 74 do vídeo analisado, foi possível verificar que os atributos Haar-like (Figura 3.17-a) apresentaram melhores resultados do que o LBP (Figura 3.17-b), tendo neste caso identificado 3 alvos a mais.

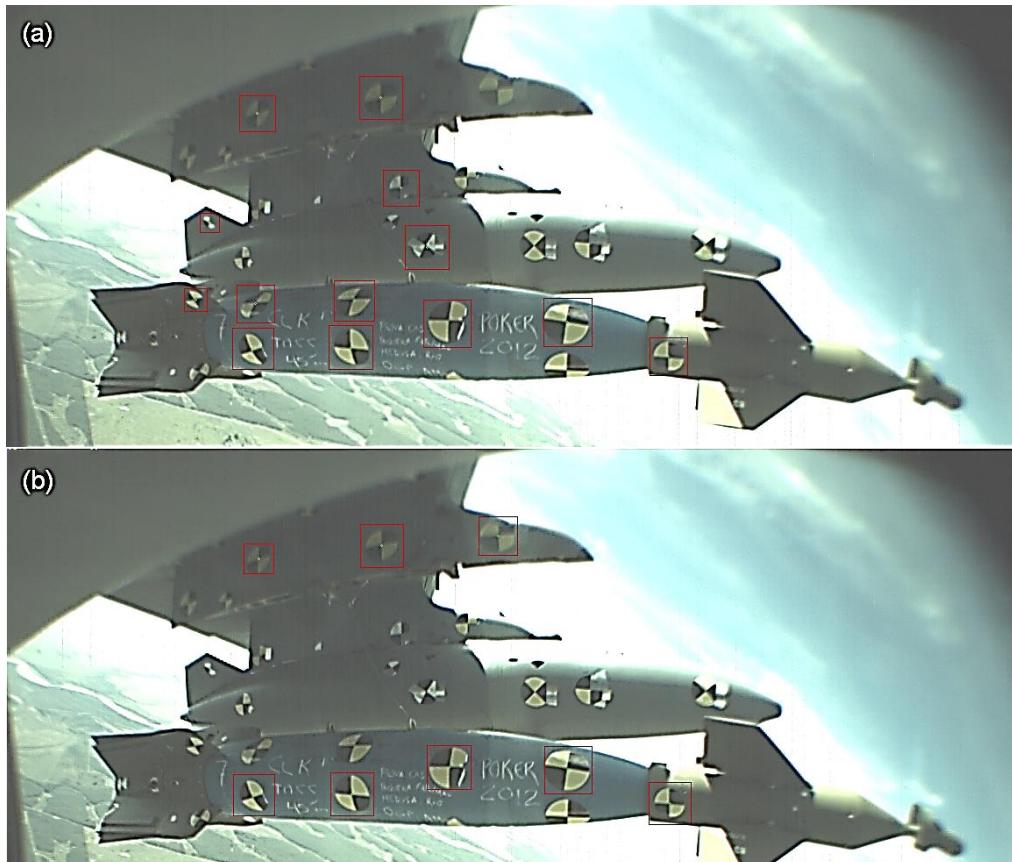


FIGURA 3.17 - Resultado do processo de identificação utilizando os atributos a) Haar-like e b) LBP - Quadro n° 74 (KUSUMOTO, *et al.*, 2014)

### 3.2.4 Resultados

Na análise dos resultados considera-se que os objetos identificados corretamente são chamados de Verdadeiro Positivo (VP) e os objetos que não foram identificados são chamados de Falso Negativo (FN). Além disto, como existe também a possibilidade do algoritmo identificar algo que não seja o alvo, esta ocorrência é chamada de Falso Positivo (FP).

Em 100 quadros do vídeo analisado, havia um total de 618 alvos na superfície da carga. As marcações na estrutura da asa e na superfície do tanque de combustível foram descartadas. A Tabela 3.4 apresenta os resultados do desempenho final.

TABELA 3.4 – Resultados do processo de identificação de alvos do vídeo analisado

Atributos	VP	FN	FP	Sensibilidade VP/(VP+FN)
Haar-like	570	48	322	92,23%
LBP	543	75	20	87,86%

É possível verificar, analisando a Tabela 3.4, que os resultados no processo de identificação utilizando os atributos Haar-like foram melhores. Neste caso, o algoritmo conseguiu identificar 92,23% dos alvos e o LBP atingiu uma taxa pouco menor, com 87,86% de sucesso na identificação dos alvos. Também é possível verificar que o Haar-like identificou 16 vezes mais FP do que o LBP.

Esta análise utilizou a métrica chamada de Sensibilidade (S) que foi expressa pela Equação 3.1 (CRUZ, SHIGUEMORI e GUIMARÃES, 2013). Esta métrica não considera o número de FP para o cálculo, pois basicamente, demonstra a porcentagem de acertos do algoritmo.

$$S = \frac{VP}{VP + FN} \quad (3.1)$$

Existem outras metodologias para evidenciar o desempenho do protótipo na identificação dos alvos no vídeo analisado tais como a métrica da Precisão (P). Neste caso, a Precisão (FAWCETT, 2006) pode ser calculada por:

$$P = \frac{VP}{VP + FP} \quad (3.2)$$

A Tabela 3.5 apresenta o resultado obtido utilizando a métrica de Precisão.

TABELA 3.5 - Resultado obtido utilizando a métrica Precisão

Técnica	Precisão
Haar-like	63,90%
LBP	96,45%

Os resultados desse experimento em particular foram apresentados no *34º European Telemetry and Test Conference*, em junho de 2014, em Nuremberg, Alemanha (KUSUMOTO, *et al.*, 2014).

### **3.3 Experimento com ensaios de separação em solo**

Para a realização dos ensaios de separação em solo, foram necessárias a definição e preparação dos meios requeridos, tais como:

1. A seleção da aeronave;
2. A verificação da correta operação dos sistemas da aeronave para os lançamentos; e
3. A alocação dos equipamentos, técnicos e mecânicos para o acompanhamento dos ensaios.

Enfim, após a realização de todos os acertos necessários, os ensaios de separação em solo aconteceram nos dias 08 e 27 de outubro de 2014.

#### **3.3.1 Preparação**

Durante o planejamento, optou-se por utilizar a aeronave AT-26 Xavante, que foi recentemente aposentada pela FAB. O IPEV utilizou o Xavante durante muitos anos em campanhas de ensaios, na formação de pilotos e engenheiros de prova e ainda possui alguns exemplares desativados que foram alocados para a execução de laboratórios experimentais do Curso de Ensaios em Voo (CEV) e para o desenvolvimento de projetos experimentais. O AT-26 Xavante é um projeto da empresa italiana Aermacchi e passou a ser fabricado pela Embraer na década de 70 para ser utilizado como avião de Ataque e Treinamento (AT).

Técnicos e mecânicos de aeronaves pertencentes à Divisão de Suprimento de Manutenção (ESM) do IPEV, realizaram uma análise detalhada nos sistemas elétricos e mecânicos da aeronave para verificar a viabilidade da realização dos ensaios. Uma carga sem explosivos foi disponibilizada pelo Instituto de Aeronáutica e Espaço (IAE). Com isso, a preparação final do dispositivo de ensaio foi realizada (Figura 3.18) de forma satisfatória.



FIGURA 3.18 - Montagem final do dispositivo de ensaio de separação em solo

Foram utilizados dois modelos (i.e. adesivos) de alvos para as marcações na superfície da carga. São marcações circulares nas cores preto/amarelo e preto/branco (Figura 3.19). O modelo nas cores preto/amarelo é comumente utilizado em ensaios de separação de carga. No vídeo analisado da Operação Poker, as marcações na superfície da carga eram do mesmo modelo circular nas cores preto/amarelo. A marcação nas cores preto/branco foi escolhida pela diferença de contraste entre as cores. Tais configurações foram requeridas para se avaliar qual a solução ótima de desempenho dos algoritmos de identificação de objetos.

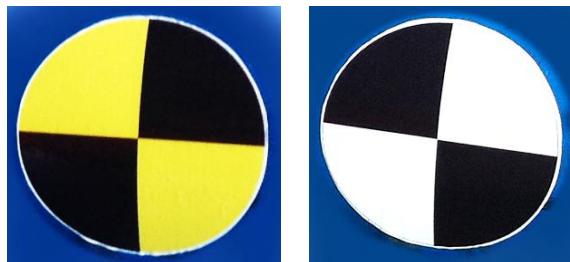


FIGURA 3.19 - Marcações (i.e. adesivos) usados na superfície da carga

Os lançamentos foram realizados nos hangaretes do IPEV, localizados no aeródromo de São José dos Campos, e foram acompanhados por uma equipe de apoio da ESM, por pesquisadores da Divisão de Pesquisa e Desenvolvimento (EPD) do IPEV e por alguns colaboradores do Instituto. A equipe de apoio da ESM foi responsável pelos lançamentos e pela preparação da carga. A cada lançamento, a carga era suspensa por um trator para depois ser novamente instalada no pilone para um novo lançamento (Figura 3.20).



FIGURA 3.20 - Instalação da carga no pilone

O sistema óptico foi composto por duas câmeras instaladas em um casulo fotográfico. As câmeras de alta velocidade e alta resolução utilizadas nos ensaios em solo foram as mesmas utilizadas na Operação Poker (i.e. Marca Mikrotron e modelo MotionBLITZ EoSens® Cube7).

Como a aeronave AT-26 não possui uma estação central, o casulo fotográfico e a carga foram instalados sob a asa, (Figura 3.21) nas estações inboard e outboard, respectivamente. A princípio, a proximidade do casulo fotográfico com a carga poderia resultar em uma área muito pequena de captura das câmeras, o que dificultaria na análise das imagens. Entretanto, o campo de visão das câmeras frontal e traseira foi considerado satisfatório após uma verificação inicial.

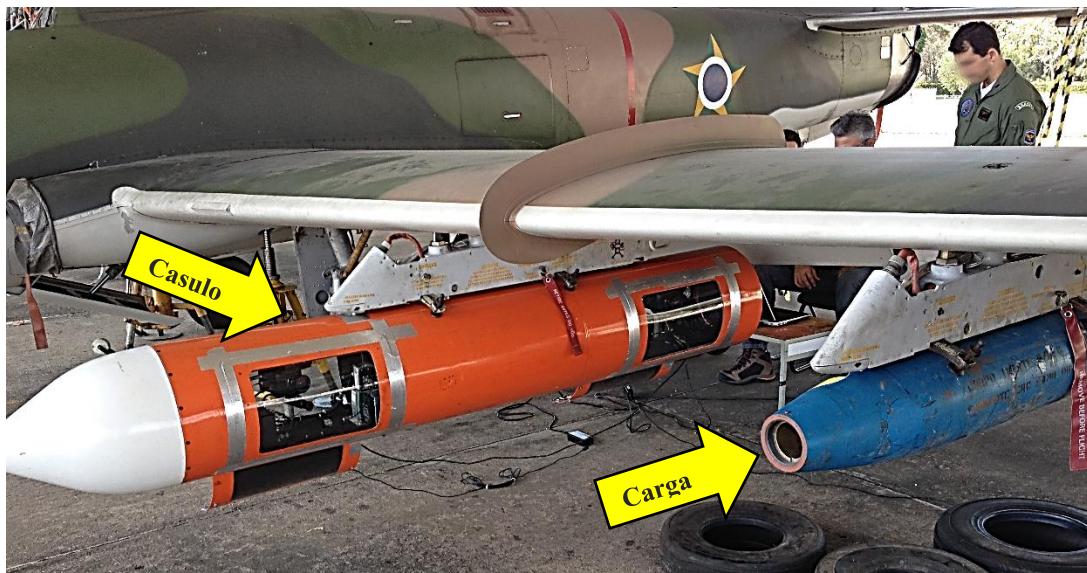
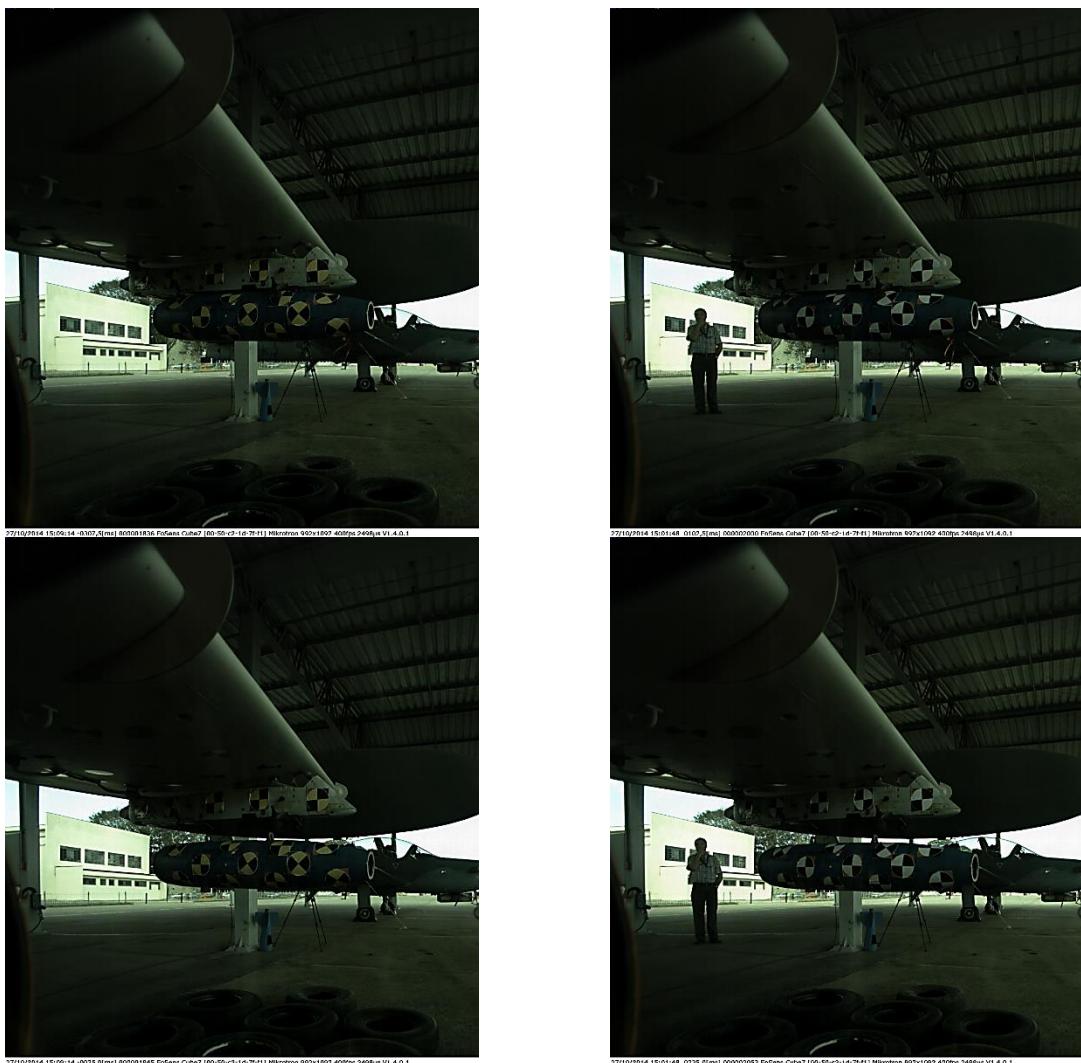


FIGURA 3.21 - Casulo fotográfico e carga instalados sob a asa do AT-26 Xavante

### 3.3.2 Execução dos ensaios

Ficou definido que haveria a execução de alguns lançamentos para ajuste e verificação dos parâmetros de gravação dos vídeos pelas câmeras de alta velocidade. Essa verificação foi necessária, pois ajustes de luminosidade, da quantidade de quadros para captura das imagens e de posicionamento das câmeras são essenciais para o sucesso dos lançamentos. Como exemplo, quanto maior o valor da aquisição de quadros por segundo, maior será a quantidade de luminosidade requerida para a gravação da sequência de imagens.

Para a avaliação inicial, foi requerida a execução de um lançamento para cada tipo de alvo (i.e. adesivo), totalizando duas separações em solo. Considerando que foram instaladas duas câmeras, houve a geração de quatro sequências de vídeos no ensaio de separação em solo, uma filmagem para cada tipo de alvo que foram capturados pelas câmeras frontal (Figura 3.22) e traseira (Figura 3.23).



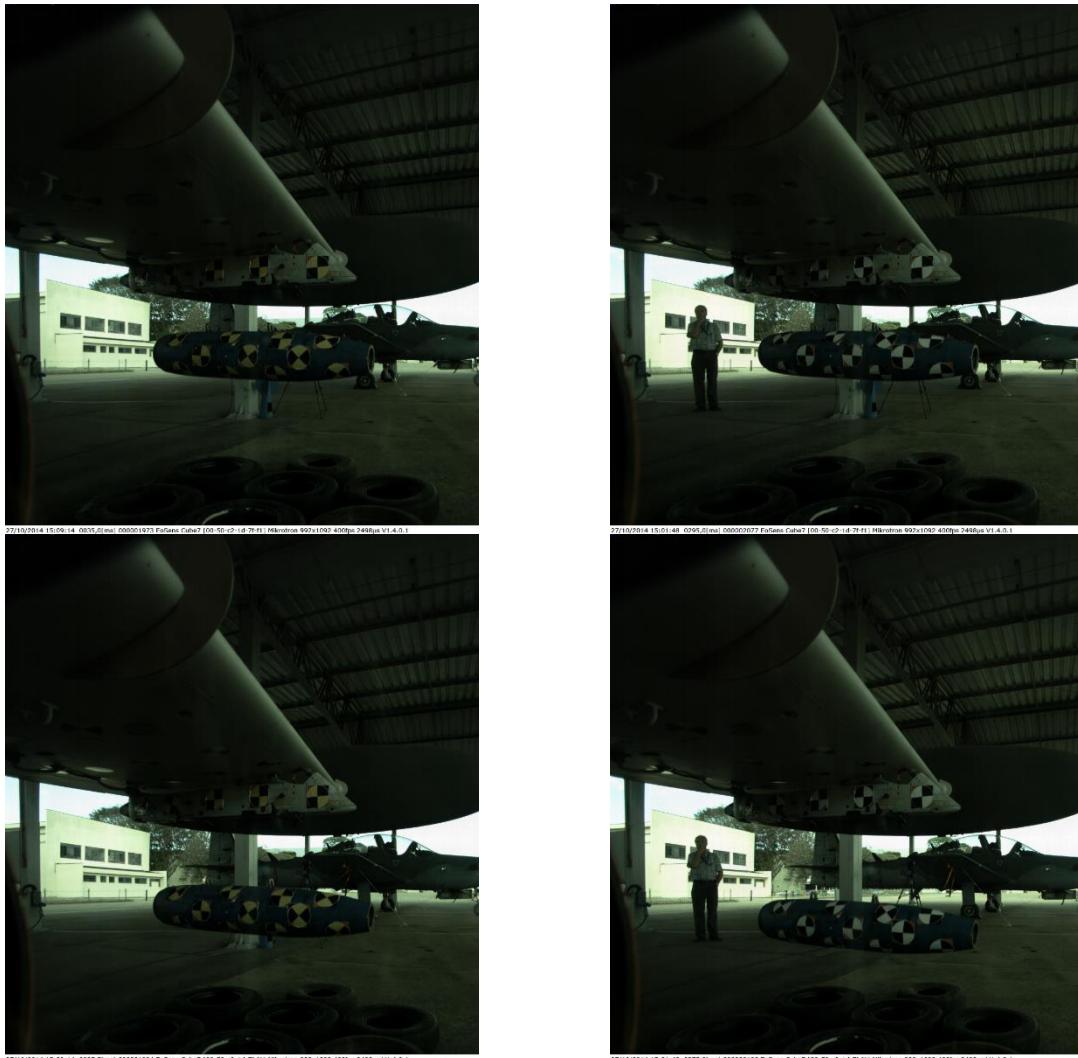
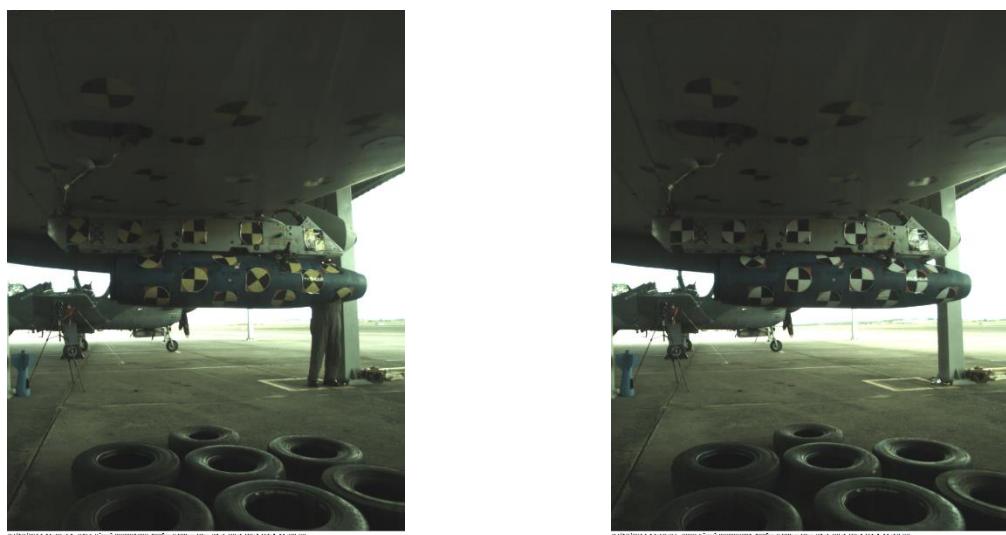


FIGURA 3.22 - Sequência de imagens do ensaio de separação em solo capturadas pela câmera frontal. Alvos nas cores preto/amarelo e preto/branco.



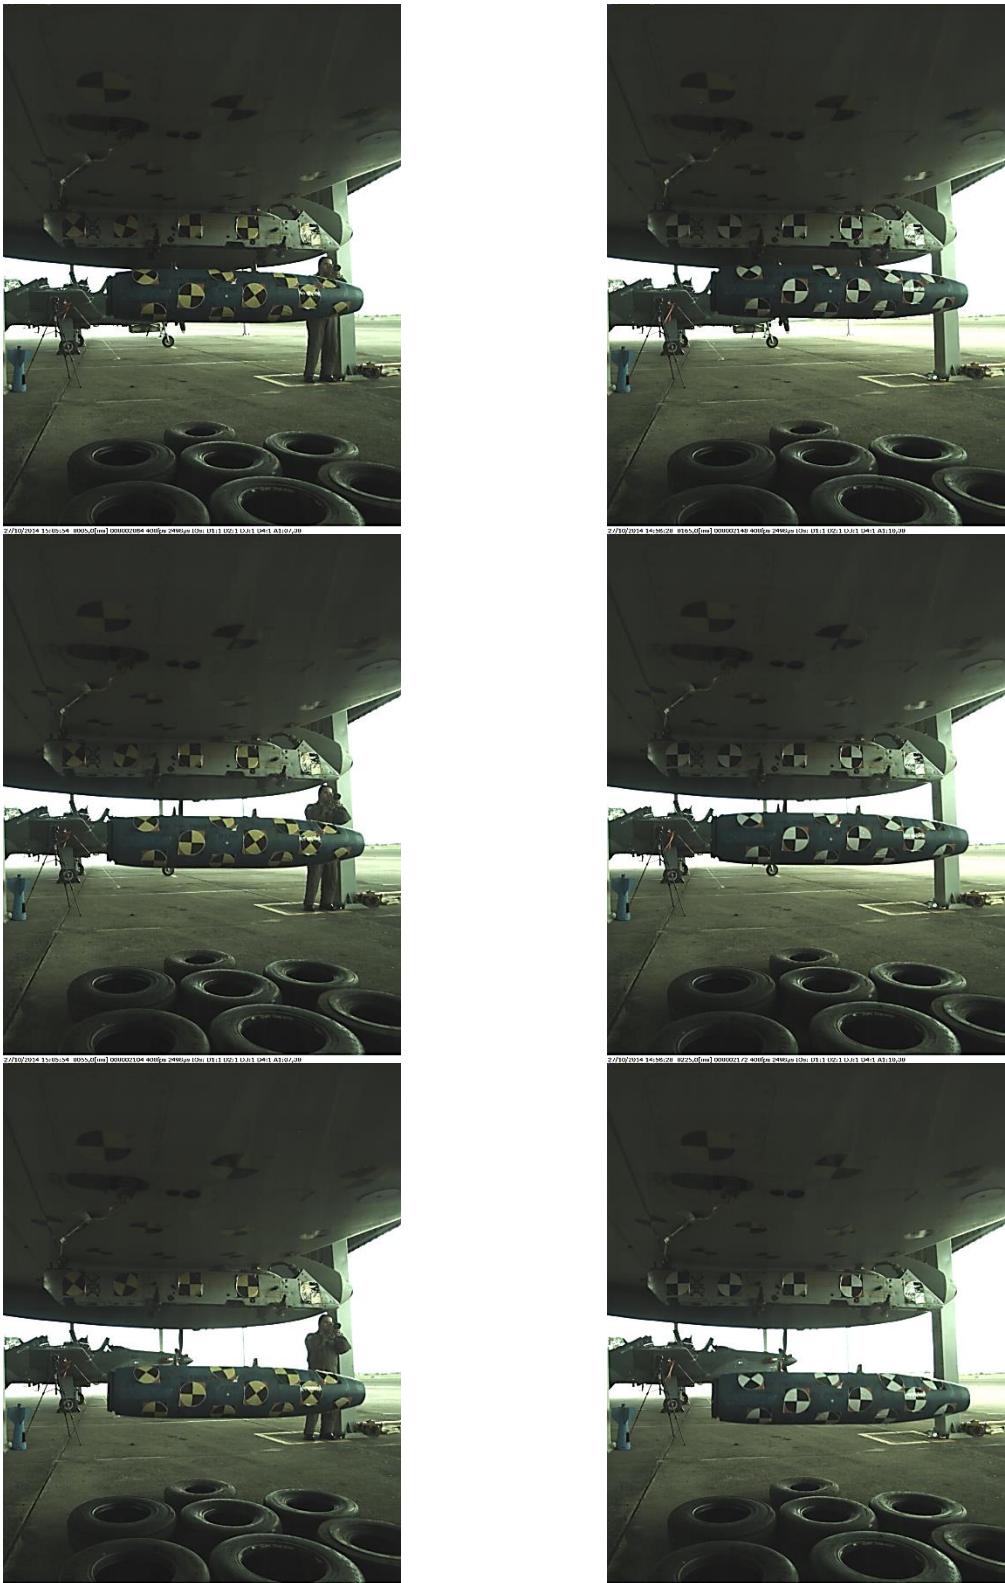


FIGURA 3.23 - Sequência de imagens do ensaio de separação em solo capturadas pela câmera traseira. Alvos nas cores preto/amarelo e preto/branco.

Infelizmente, mesmo com todo planejamento realizado, nos ensaios do dia 08 de outubro, ocorreram problemas durante a extração dos vídeos, especificamente, na configuração das câmeras. O problema foi que um dos operadores utilizou uma configuração diferente do

que havia sido definido e testado. Como os lançamentos foram realizados em um ambiente aberto e com muita luminosidade, visualmente, os vídeos não pareciam estar com configurações diferentes. Entretanto, a sequência de imagens capturadas por uma das câmeras ficou depreciada. Sendo assim, os vídeos desse ensaio foram descartados e um novo ensaio foi agendado para o dia 27 de outubro de 2014.

Os lançamentos realizados no dia 27 de outubro resultaram em quatro vídeos adquiridos a 400 qps. Os vídeos capturados pela câmera frontal e traseira foram respectivamente adquiridos com a resolução de 992 por 1112 pixels e de 880 por 1172 pixels, conforme configuração das câmeras realizada pelos operadores. A diferença de resolução não foi identificada no momento da gravação dos vídeos, entretanto, ambas as configurações atendem aos requisitos mínimos de resolução. Cada vídeo gravado resultou em um arquivo de tamanho médio de 4 GB.

É bom ressaltar, que não foi possível validar o desempenho em tempo real da ferramenta desenvolvida, pois as câmeras utilizadas não disponibilizam diretamente o acesso às imagens capturadas. Dessa forma, as imagens foram gravadas em dispositivos de armazenamento e disponibilizadas pelos operadores, após o seu descarregamento em um computador.

Neste ensaio foram usadas Lentes Kowa de 6.0mm que produzem imagens com menos distorções. Diferentemente do vídeo utilizado no primeiro experimento, não foram utilizadas as lentes “olho de peixe”, que distorcem consideravelmente as bordas das imagens.

### **3.3.3 Processo de Treinamento**

Assim como no primeiro experimento, foi necessário realizar a preparação para o processo de treinamento. A partir dos vídeos dos lançamentos do ensaio de separação em solo, um novo conjunto de amostras positivas foi gerado.

Dessa vez, foram utilizadas 600 amostras positivas dos alvos, incluindo as marcações nas cores preto/amarelo e preto/branco. Um número maior de amostras foi utilizado, pois amostras positivas do primeiro experimento também foram aproveitadas na composição desse conjunto (Figura 3.24). Todas as imagens tinham a mesma dimensão de 20 por 20 pixels.



FIGURA 3.24 - Exemplos de amostras positivas utilizadas no experimento de ensaio de separação em solo

O arquivo de configuração e o arquivo binário também foram gerados, conforme definido no Processo de Treinamento (Figura 3.3).

O conjunto de amostras negativas foi composto de 500 amostras de diferentes dimensões. Foram utilizadas amostras negativas do primeiro experimento, mais ROI segmentadas dos vídeos dos lançamentos em solo (Figura 3.25). Nesse caso específico, as imagens apresentadas na Figura 3.25 possuem a dimensão de 50 por 50 pixels.

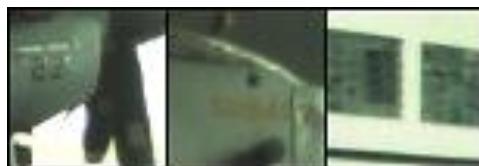


FIGURA 3.25 - Exemplos de amostras negativas utilizadas no experimento de ensaio de separação em solo

Em seguida, o arquivo de configuração das amostras negativas também foi criado.

A diferença na duração do Processo de Treinamento entre os atributos Haar-like e LBP também ficou evidente nesse experimento. Apesar de utilizar uma quantidade maior de amostras, tanto positivas quanto negativas, o processo de treinamento do LBP foi muito rápido e demorou apenas 2 minutos e 3 segundos. Já o Processo de Treinamento utilizando os atributos Haar-like, obteve um tempo de execução de 1 hora, 30 minutos e 28 segundos (Figura 3.26).

Alguns parâmetros utilizados nessa execução foram configurados com valores diferentes do primeiro experimento. Os parâmetros de quantidade de amostras positivas e negativas seriam diferentes de qualquer forma, pois foi utilizado um conjunto diferente de amostras. O número de estágios (i.e. 20) e as taxas mínimas de identificação e máxima de falso positivo foram configurados com os mesmos valores. A taxa mínima de identificação foi definida como 0.999 e a taxa máxima de falso positivo foi definida como 0.5. Já os parâmetros de tamanho da memória temporária para os valores de atributos e índices precalculados foram aumentados de 256 Mb para 2048 Mb. Consequentemente, a comparação do desempenho da separação em solo com o primeiro experimento (i.e Seperação da Operação Poker) mostra que

os tempos de execução dos algoritmos LBP e Haar-like foram respectivamente muito menores (i.e. 6% do tempo) e semelhantes (Figura 3.26).

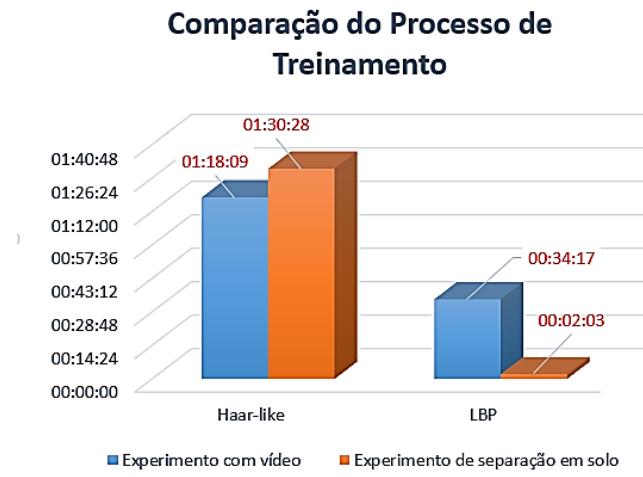


FIGURA 3.26 - Gráfico de comparação entre o tempo de treinamento no primeiro e no segundo experimento.

### 3.3.4 Processo de Identificação

Para a identificação, foi utilizado o mesmo protótipo de validação, porém, com tamanhos máximos de janela diferentes. No primeiro experimento, foram utilizados os valores de 20 por 20 pixels e 80 por 80 pixels para os parâmetros *minSize* e *maxSize*, respectivamente. Entretanto, neste experimento, em virtude da proximidade da câmera com os alvos, as dimensões de *maxSize* foram aumentadas para 100 por 100 pixels.

O arquivo *cascade.xml*, gerado pelo processo de treinamento, foi carregado pelo algoritmo e a função *detectMultiScale* foi utilizada na identificação dos alvos em cada quadro da sequência de vídeo do ensaio de separação em solo. Antes, as imagens foram transformadas em escala de cinza e o seu histograma foi equalizado (Figura 3.15).

Os alvos identificados foram sinalizados, neste experimento, pelas suas coordenadas *x* e *y* nas imagens. A função *detectMultiScale* retorna um vetor de retângulos com os alvos identificados. Cada alvo é identificado pelas suas coordenadas *x* e *y* que representa o ponto superior esquerdo do retângulo e pela sua largura e altura. Assim, o ponto central do retângulo, chamado *pc(x,y)* foi calculado pela Equação 3.3.

$$pc(x,y) = (targets[i].x + (targets[i].width/2), targets[i].y + (targets[i].height/2)) \quad (3.3)$$

Onde:

- $targets[i]$  o i-ésimo elemento (i.e. alvo) pertencente ao vetor de alvos identificados;
- $width$  a largura do i-ésimo retângulo do vetor de alvos identificados; e
- $height$  a altura do i-ésimo retângulo do vetor de alvos identificados.

Esta aplicação possui uma condição particular que simplifica e agiliza o processo de busca dos alvos, pois as análises podem ser realizadas em uma região específica da imagem capturada pelas câmeras. Neste caso em particular não há necessidade de se analisar a imagem inteira, pois no início do lançamento, a região onde a carga se localiza é conhecida. Assim como a análise é realizada somente nos primeiros segundos após a separação, foi possível definir uma ROI para os vídeos gravados pela câmera frontal e outra ROI para a câmera traseira.

O ROI da câmera frontal tinha início na coordenada  $x$ , deslocada de 230 pixels e largura de 600 pixels e a coordenada  $y$ , deslocada 480 pixels e altura de 370 pixels (Figura 3.27).

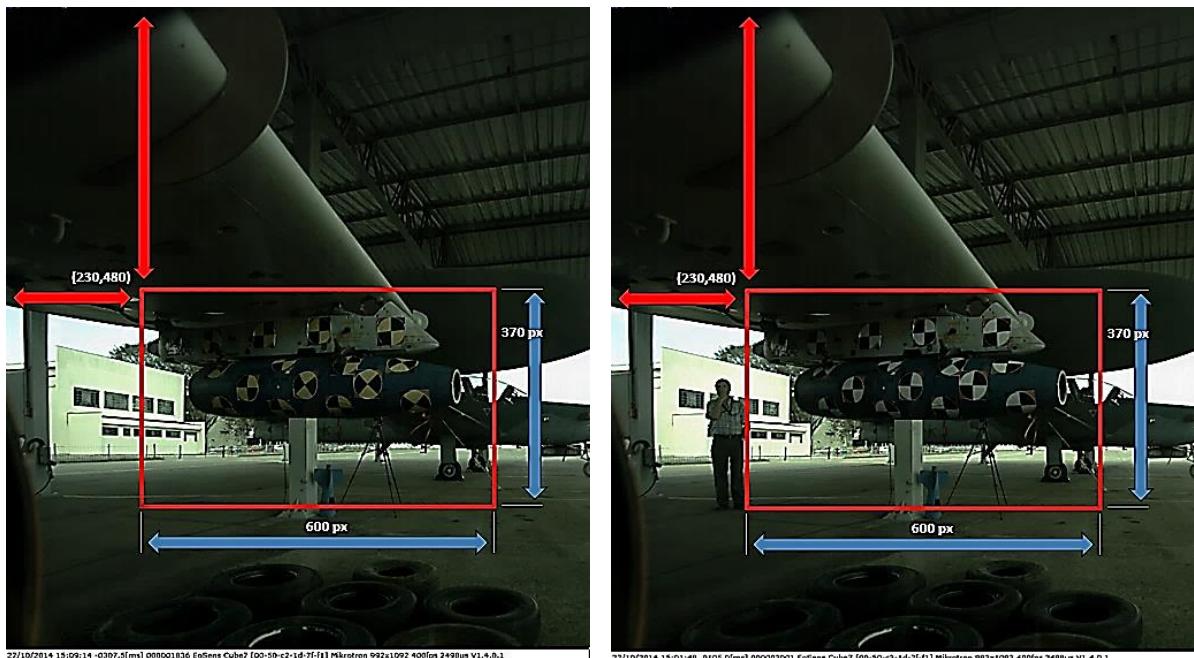


FIGURA 3.27 – ROI aplicada aos quadros na análise da câmera frontal

O ROI da câmera traseira tinha início na coordenada  $x$ , deslocada 90 pixels e largura de 740 pixels e a coordenada  $y$ , deslocada 380 pixels e altura de 340 pixels (Figura 3.28).

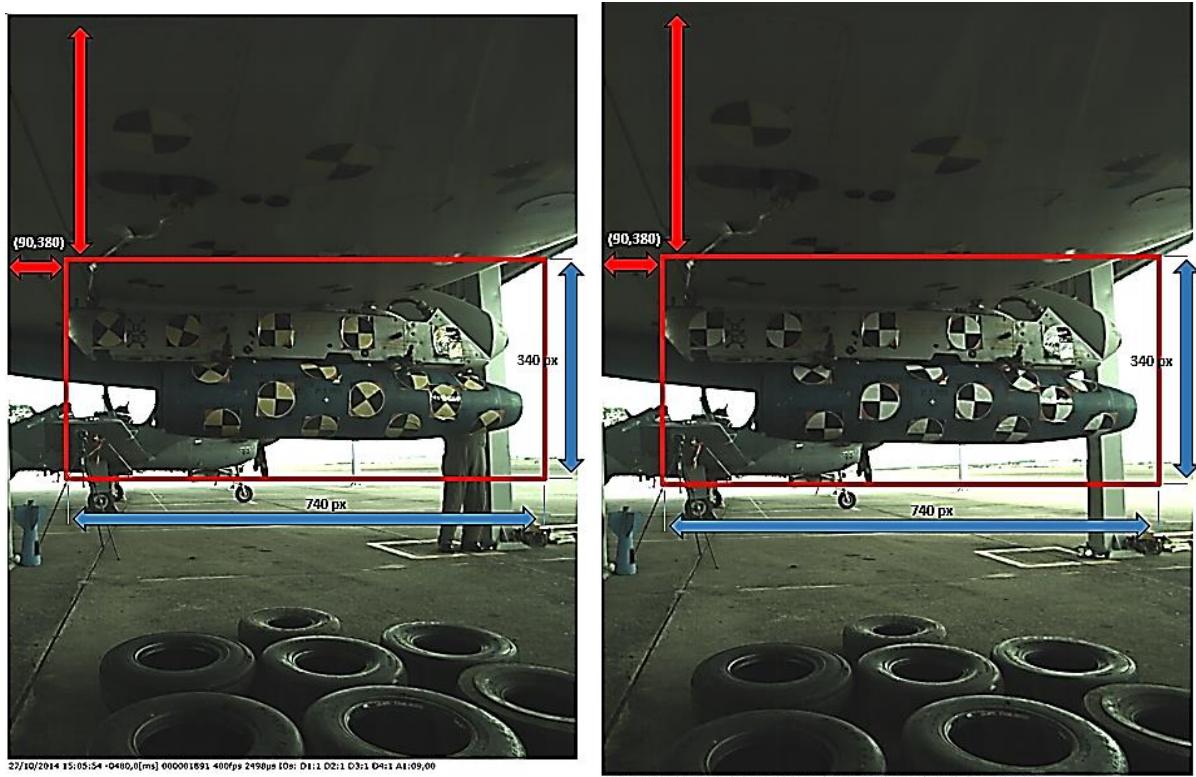


FIGURA 3.28 - ROI aplicada aos quadros na análise da câmera traseira

Após o processo de identificação dos alvos, basta realizar a transposição da posição dos alvos encontrados para a sua posição original. Nas Figuras 3.29, 3.30, 3.31 e 3.32 são apresentados os resultados da aplicação das técnicas Haar-like e LBP nas sequências de imagens.

A Figura 3.29 apresenta os alvos identificados pelo processo de identificação aplicado no vídeo da câmera frontal da separação em solo dos alvos em preto/amarelo. A sequência de quadros do lado esquerdo apresenta os alvos identificados utilizando os atributos Haar-like e a sequência do lado direito apresenta os alvos identificados utilizando os atributos LBP nos quadros 1, 70 e 100.

Nos quadros apresentados na Figura 3.29 é perceptível que a aplicação das técnicas é eficiente e consegue identificar quatro alvos instalados no pilone e cinco ou mais alvos na carga em todos os três quadros. Também é possível verificar que conforme a carga está mais distante da estrutura da asa da aeronave, alguns alvos que se encontravam na parte superior da carga são identificados. O quadro 70, resultado da aplicação da técnica LBP, apresenta um falso-positivo (FP).

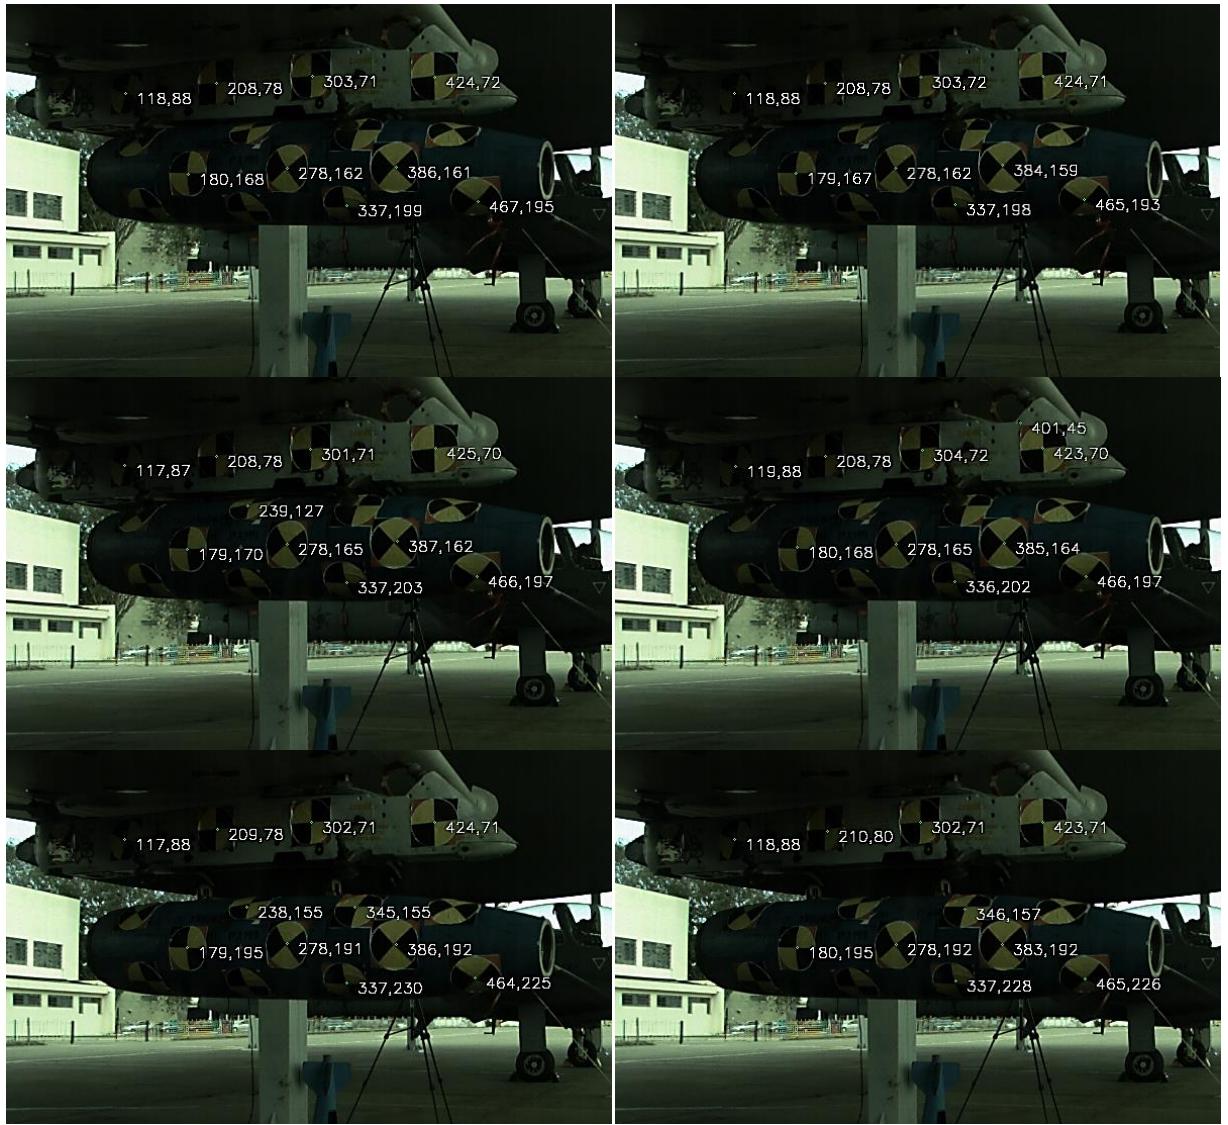


FIGURA 3.29 - Alvos identificados utilizando os atributos Haar-like (esquerdo) e LBP (direito) - Quadros nº 1, 70 e 100 da câmera frontal com alvos preto/amarelo

A Figura 3.30 apresenta os alvos identificados pelo processo de identificação aplicado no vídeo da câmera frontal da separação em solo dos alvos em preto/branco.

A sequência de quadros do lado esquerdo apresenta os alvos identificados utilizando os atributos Haar-like e a sequência do lado direito utilizando os atributos LBP nos quadros 1, 70 e 100.



FIGURA 3.30 - Alvos identificados utilizando os atributos Haar-like (esquerdo) e LBP (direito) – Quadros n° 1, 70 e 100 da câmera frontal com alvos preto/branco

Nos experimentos com a câmera frontal na identificação dos alvos nas cores preto/branco, também pode-se observar que são identificados quatro alvos no pilone e quatro alvos ou mais na carga. No quadro 1, por exemplo, analisado pela técnica Haar-like, são identificados sete alvos na carga. Também é notória, uma quantidade maior de FP nos quadros apresentados na Figura 3.30.

A Figura 3.31 apresenta os alvos identificados pelo processo de identificação aplicado no vídeo da câmera traseira da separação em solo dos alvos em preto/amarelo. A sequência de quadros do lado esquerdo apresenta os alvos identificados utilizando os atributos Haar-like e a sequência do lado direito utilizando os atributos LBP nos quadros 101, 170 e 200. Nesse caso, o vídeo capturado possuía um tempo maior de duração antes do lançamento, e se, a análise ocorresse nos primeiros 100 quadros, somente quadros da carga ainda inerte seriam analisados

após a separação. Portanto, a análise foi realizada nos quadros 101 ao 200. No vídeo com as marcações em preto/amarelo, o lançamento ocorre logo nos primeiros instantes.

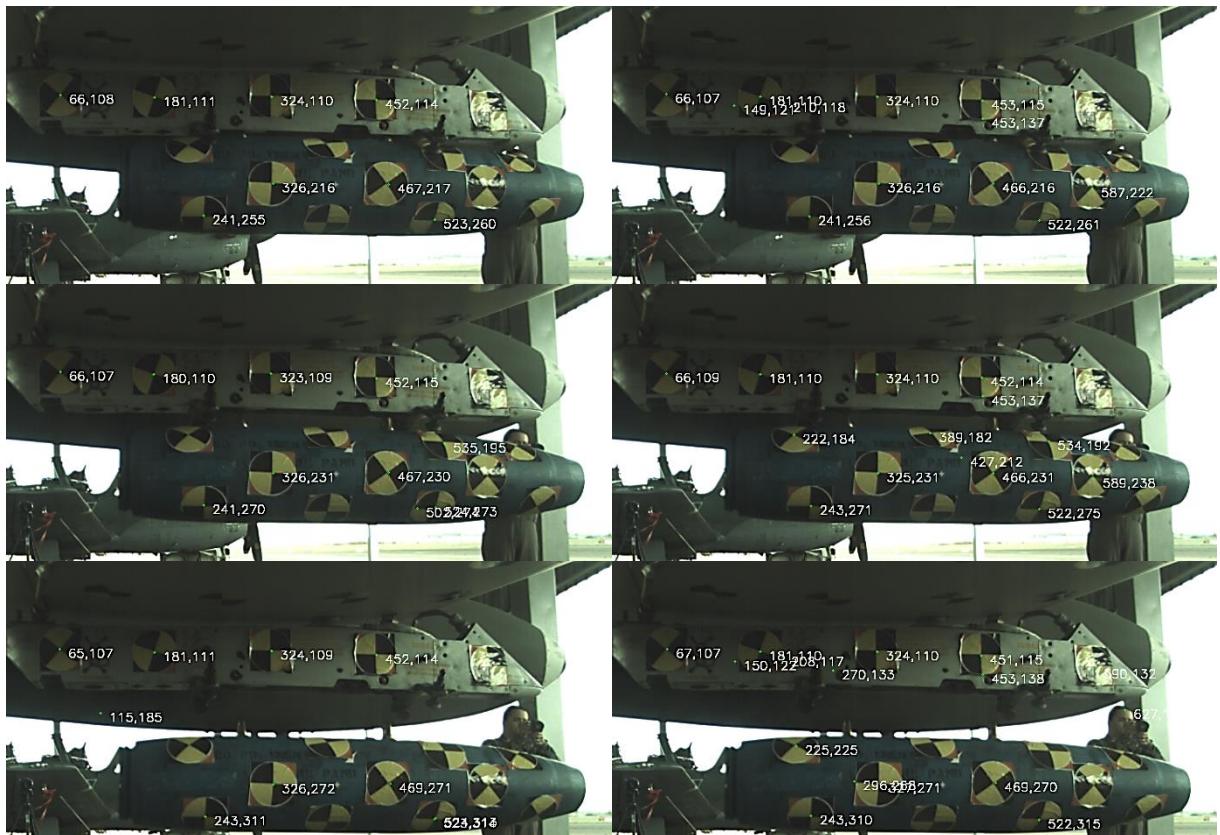


FIGURA 3.31- Alvos identificados utilizando os atributos Haar-like (esquerdo) e LBP (direito) – Quadros n° 101, 170 e 200 da câmera traseira com alvos preto/amarelo

A análise das imagens obtidas pela câmera traseira apresentou uma quantidade muito grande de FP, principalmente, pela técnica LBP. Isso poderá ser mais bem quantificado na apresentação dos resultados consolidados. Entretanto, nos quadros apresentados, foram identificados pelo menos quatro ou mais alvos no pilone e quatro ou mais alvos na carga. No quadro 170 analisado pela técnica LBP foram identificados 8 alvos na carga.

A Figura 3.32 apresenta os alvos identificados pelo processo de identificação aplicado no vídeo da câmera traseira da separação em solo dos alvos em preto/branco. A sequência de quadros do lado esquerdo apresenta os alvos identificados utilizando os atributos Haar-like e a sequência do lado direito utilizando os atributos LBP nos quadros 1, 70 e 100.

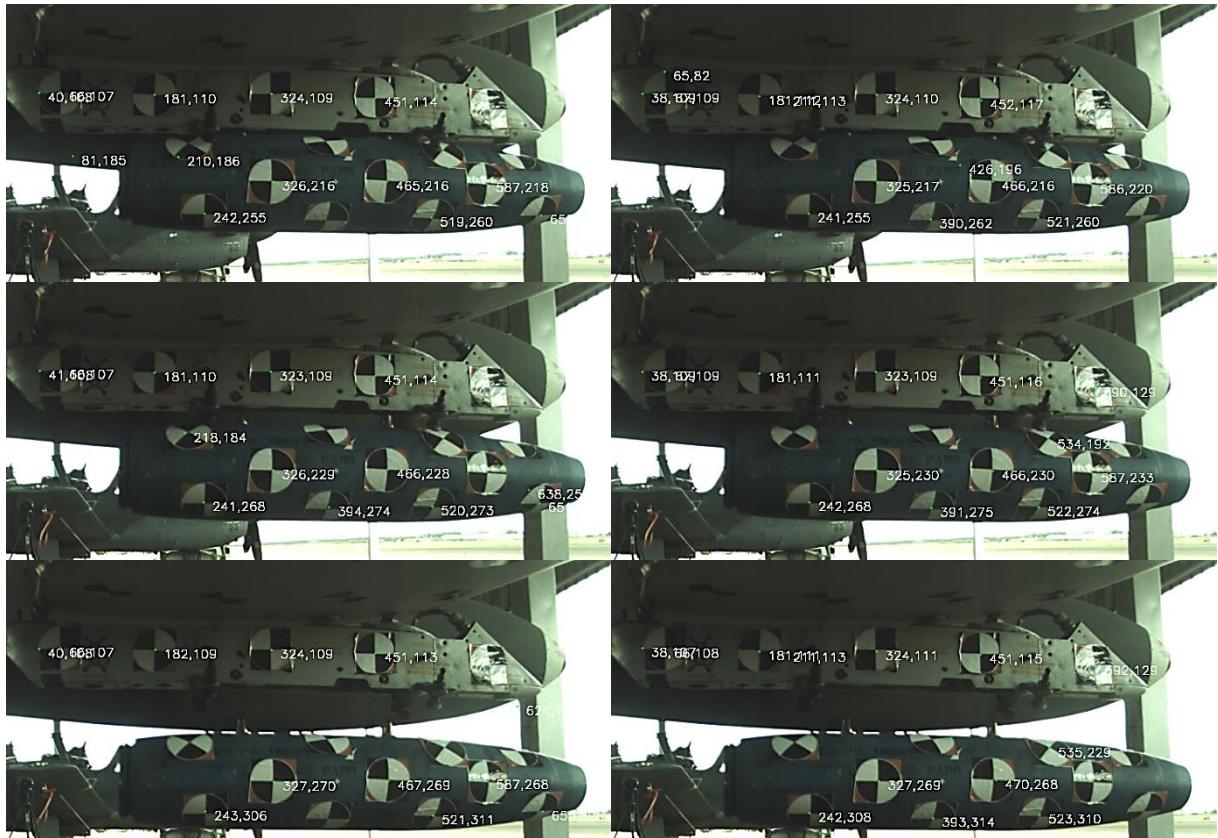


FIGURA 3.32 - Alvos identificados utilizando os atributos Haar-like (esquerdo) e LBP (direito) – Quadros n° 1, 70 e 100 da câmera traseira com alvos preto/branco

Nos quadros apresentados na Figura 3.32, com os alvos nas cores preto/branco, foram identificados quatro ou mais alvos no pilone e cinco ou mais alvos na carga.

### 3.3.5 Resultados

Para se realizar uma análise quantitativa da aplicação das técnicas nos vídeos capturados nos lançamentos dos ensaios de separação de carga em solo, foram utilizados os 100 primeiros quadros de cada vídeo. A exceção foi o vídeo adquirido pela câmera traseira no lançamento da carga com alvos nas cores preto/amarelo, a qual foi necessária analisar as imagens a partir do quadro de número 101 até o quadro de número 200.

Para se definir quais alvos o protótipo deveria identificar, a fim de se totalizar a quantidade de Verdadeiro-Positivo e Falso-Negativo, foram considerados na análise os alvos mais aparentes no pilone e na carga em cada vídeo (Figura 3.33).



FIGURA 3.33 – Alvos considerados para a consolidação dos resultados. Câmera frontal (esquerdo) e câmera traseira (direito)

Como pode ser observado na Figura 3.33, foram considerados para o cálculo da métrica de Sensibilidade, 9 alvos (quatro no pilone e 5 na carga) para cada quadro. Foram analisados 100 quadros de cada sequência de vídeo, portanto, no total foram considerados 900 alvos a serem identificados pelo protótipo. A definição dos alvos considerados foi necessária para se levantar o número de FN.

Assim, o protótipo apresentou os seguintes resultados (Tabela 3.6) no processo de identificação para os alvos nas cores preto/amarelo considerando os 900 alvos definidos.

TABELA 3.6 – Resultados consolidados para 900 alvos nas cores preto/amarelo

Câmera	Frontal		Traseira	
	Técnica	Haar-like	LBP	Haar-like
<b>VP</b>	895	847	805	813
<b>FP</b>	14	89	108	294
<b>FN</b>	5	53	95	87
<b>Precisão VP/(VP+FP)</b>	98,46%	90,49%	88,17%	73,44%
<b>Sensibilidade VP/(VP+FN)</b>	99,44%	94,11%	89,44%	90,33%

Os atributos LBP apresentam grande quantidade de FP. Esse fato penaliza o desempenho medido pela métrica de Precisão. Fica evidente o melhor desempenho dos atributos Haar-like em comparação ao LBP com ambas as métricas.

Os resultados consolidados do processo de identificação dos alvos nas cores preto/branco considerando os 900 alvos são apresentados na Tabela 3.7.

TABELA 3.7 – Resultados consolidados para 900 alvos nas cores preto/branco

Câmera	Frontal		Traseira	
Técnica	Haar-like	LBP	Haar-like	LBP
<b>VP</b>	885	873	863	900
<b>FP</b>	67	131	192	275
<b>FN</b>	15	27	37	0
<b>Precisão VP/(VP+FP)</b>	92,96%	86,95%	81,80%	76,60%
<b>Sensibilidade</b>	98,33%	97,00%	95,89%	100,00%
<b>VP/(VP+FN)</b>				

Utilizando os alvos nas cores preto/branco, a quantidade de FN aumentou somente na análise das imagens da câmera frontal e com os atributos Haar-like (i.e. de 5 para 15), cujo valor pode ser considerado pequeno. Nos outros casos, houve uma diminuição na quantidade de FN, o que é satisfatório. Em particular na análise das imagens da câmera traseira e com os atributos LBP, não houve a ocorrência de nenhum FN. Essa melhora na eficiência da identificação dos alvos é explicada pelas cores preto/branco dos alvos. Os atributos Haar-like utilizam a soma das intensidades dos pixels das áreas mais escuras e mais claras, baseada nos atributos de dois, três e quatro retângulos. Nos alvos preto/branco, o contraste entre as duas áreas é bem mais evidente que nos alvos preto/amarelo. Nos atributos LBP, as texturas dos limiares das cores também resultam em melhores atributos (i.e. classificadores) e consequentemente, maior quantidade de possíveis alvos identificados.

De maneira geral, os resultados apresentaram uma grande quantidade de FP, principalmente, na utilização dos atributos LBP. A alta taxa de ocorrência de FP, resultante do processo de identificação, em ambos os casos, não é um fator que invalida o resultado final, pois, é possível ainda aplicar outras técnicas (e.g. Redes Neurais Artificiais) para a confirmação dos FP.

A definição de quais alvos seriam considerados como identificáveis pelo protótipo foi subjetiva (Figura 3.33). A totalização do número de FN depende dessa definição. Na análise das imagens da câmera traseira utilizando os alvos nas cores preto/amarelo, o alvo sinalizado

como um retângulo tracejado na Figura 3.33 foi o maior contribuinte para o grande número de FN, o qual foi identificado somente em 8 dos 100 quadros analisados. Nesse caso específico, se desconsiderarmos esse alvo, os resultados apresentados da métrica Sensibilidade, seriam muito melhores (Tabela 3.8).

TABELA 3.8 – Resultados consolidados considerando 4 alvos na carga - Câmera traseira com alvos nas cores preto/amarelo

Câmera Traseira - alvos preto/amarelo		
Técnica	Haar-like	LBP
<b>VP</b>	797	800
<b>FP</b>	108	294
<b>FN (4 alvos na carga)</b>	3	0
<b>Sensibilidade (VP/VP+FN)</b>	99,63%	100,00%

Nesta aplicação o descarte de alvos cuja imagem ainda não está muito bem definida não irá prejudicar o resultado final, pois os cálculos de localização espacial da carga com 6DoF não depende da identificação de todos os alvos. Entretanto por se tratar de um processo de convergência de mínimos quadrados, quanto maior a quantidade de alvos identificados em ambas às imagens estereoscópicas, melhor será a correlação entre eles. Isso irá melhorar a exatidão do cálculo de posição tridimensional da carga.

Nos resultados apresentados acima, foram considerados somente 9 alvos por quadro na contagem dos VP. Nesta aplicação, se outro alvo fosse identificado, ele seria descartado dos resultados apresentados. Neste caso em particular, pode-se propor a utilização da seguinte métrica alternativa (Equação 3.4) para a validação do algoritmo.

$$P_k = \frac{VP_k}{VP_k + FP} \quad (3.4)$$

Onde  $VP_k$  é o número de VP que o algoritmo identificou e FP é o número de Falso Positivos. O  $VP_k$  difere do VP, pois não considera somente os alvos definidos para o processo de identificação. Qualquer alvo identificado corretamente incrementa o valor de  $VP_k$ . Nesse caso específico, como não há definição de qual alvo o algoritmo deve identificar, não é possível realizar o somatório do número de ocorrências de FN. Portanto, a métrica de Sensibilidade não pode ser calculada. A Tabela 3.9 apresenta os resultados com esta nova métrica, considerando todos os alvos identificados pelo algoritmo cujos resultados são ligeiramente melhores.

TABELA 3.9 – Resultados de  $P_k$  considerando todos os alvos identificados pelo algoritmo.

Câmera	Frontal		Traseira	
	Técnica	Haar-like	LBP	Haar-like
<b>Alvos nas cores preto/amarelo</b>				
<b>VP<sub>k</sub></b>	963	878	834	922
<b>FP</b>	14	89	108	294
<b>P<sub>k</sub></b>	98,57%	90,80%	88,54%	75,82%
<b>Precisão*</b>	98,46%	90,49%	88,17%	73,44%
<b>Alvos nas cores preto/branco</b>				
<b>VP<sub>k</sub></b>	1037	997	995	1095
<b>FP</b>	67	131	192	275
<b>P<sub>k</sub></b>	93,93%	88,39%	83,82%	79,93%
<b>Precisão*</b>	92,96%	86,95%	81,80%	76,60%

\* Resultado anterior da métrica de Precisão

### 3.4 Avaliação de desempenho

Para este projeto de pesquisa havia a necessidade de se utilizar uma câmera que permitisse o controle de seus dispositivos, através de uma programação embarcada. Assim, seria possível a execução, na própria câmera, do processo de identificação dos alvos em tempo real utilizando as imagens capturadas. Outra alternativa, seria utilizar uma câmera que disponibilizasse uma saída de vídeo em tempo real de alta velocidade e resolução. Dessa forma, outro dispositivo embarcado poderia acessar diretamente as imagens capturadas pela câmera e realizar o seu processamento.

Foram realizadas exaustivas pesquisas com fornecedores, inclusive nas conferências onde foram apresentados os artigos acadêmicos deste trabalho, com a finalidade de se adquirir câmeras com essas características. A empresa alemã Kappa Optronics, em conjunto com a empresa americana Curtiss-Wright, apresentou algumas de suas câmeras específicas para a aplicação em ensaios em voo e informou que estava desenvolvendo uma solução que poderia atender essa demanda. Infelizmente, não houve tempo hábil para a sua apresentação, devido a atrasos no desenvolvimento.

Portanto, para verificar a viabilidade da utilização da ferramenta desenvolvida para a aplicação em um ambiente embarcado em tempo quase real, foi realizada uma análise comparativa de desempenho (i.e. *benchmark*) em dispositivo embarcado e o desempenho obtido

foi comparado com o do sistema de referência. Para isso, foi utilizado no sistema embarcado o Raspberry Pi - Modelo B e como sistema de referência, um computador portátil.

O Raspberry Pi (Figura 3.34) é um projeto de baixo custo desenvolvido pela organização educacional sem fins lucrativos Raspberry Pi Foundation, baseada no Reino Unido (RASPBERRY PI FOUNDATION, 2014). Seu objetivo é promover o desenvolvimento a nível acadêmico do estudo da ciência da computação e assuntos afins. A compra desse dispositivo foi realizada via importação no sítio da RS Components, que é uma representante autorizada, com custo de US\$ 35,00 não incluído os custos de frete e de importação.

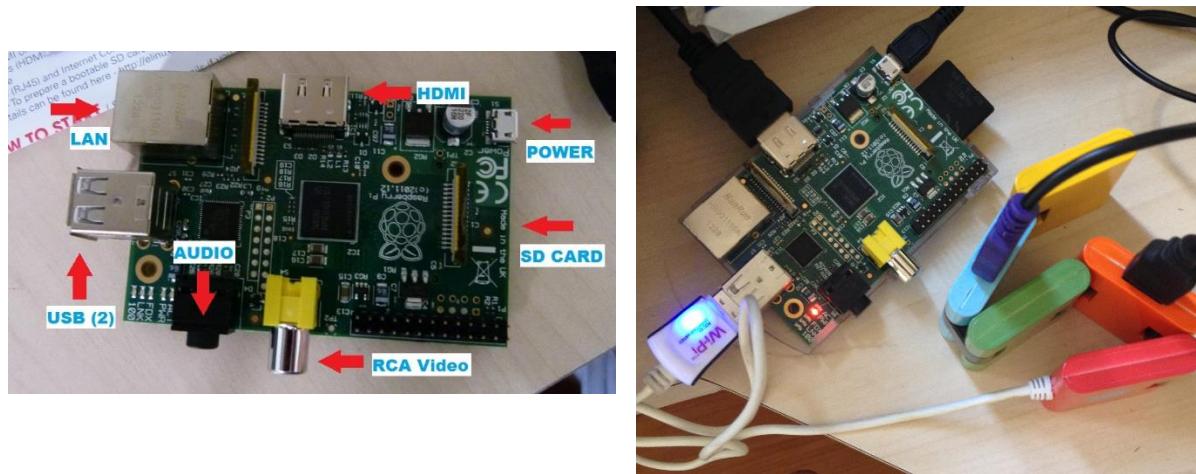


FIGURA 3.34 – Raspberry Pi - Modelo B

Este dispositivo é microcomputador integrado com dimensões semelhantes a um cartão de crédito que possui uma boa configuração. A Tabela 3.10 apresenta a configuração do modelo utilizado neste experimento. O sistema operacional utilizado no Raspberry Pi é o Raspbian que é um sistema derivado da distribuição Debian.

TABELA 3.10 – Relação dos recursos disponíveis no Raspberry Pi Model B

Recurso	Descrição
<b>Processador</b>	Broadcom BCM2835 700MHz ARM1176JZFS com Videocore 4 GPU
<b>Memória Principal</b>	512 MB RAM
<b>Portas USB</b>	2
<b>HDMI</b>	1
<b>Rede</b>	10/100 Mbps Ethernet
<b>GPIO</b>	8
<b>Video</b>	RCA socket
<b>Armazenamento</b>	SD Card
<b>Energia</b>	microUSB socket
<b>Áudio</b>	3,5mm audio out jack
<b>Dimensões</b>	85,6 x 53,98 x 17,00 mm

Dessa forma, o Raspberry Pi possui as características necessárias que o habilitam como um dispositivo que pode ser embarcado e assim utilizado neste experimento.

Para a determinação do desempenho do protótipo no processo de identificação dos alvos, foi inserido no algoritmo marcações de tempo antes e depois da função que realiza o processo de identificação dos 100 quadros retirados do vídeo. A função recebe um quadro como parâmetro de entrada, transforma a imagem em escala de cinza, realiza a equalização do seu histograma, executa a função *detectMultiScale* e percorre o vetor de retângulos gerado pela função anterior realizando as marcações nos alvos identificados.

Inicialmente, a análise seria realizada com a leitura dos vídeos gravados dos lançamentos do ensaio de separação de carga em solo. Entretanto, a memória instalada no Raspberry Pi não suportou a leitura dos arquivos de vídeo, que possuem o tamanho médio de 4 GB. Portanto, os quadros considerados no processo de identificação foram extraídos dos vídeos e utilizados nesta análise.

Para quantificação de desempenho, os resultados obtidos nesta configuração foram comparados com os do processo de identificação realizado em um computador portátil Dell Inspiron 14z, Intel® Core™ i7-3537U CPU @ 2.00GHz × 4, 8GB DDR3, 500GB 5400 RPM SATA HDD e 32GB mSATA SSD que utilizava o sistema operacional Ubuntu Desktop 13.10. Os resultados de desempenho do computador portátil Dell Inspiron são apresentados na Tabela 3.11. Todas os valores medidos são apresentados no Apêndice A.1.

Mesmo que as medições possam ter sido realizadas da forma correta é necessário considerar a precisão de medição dos valores de tempo de processamento para cada quadro. Assim, cada valor de tempo medido do processo de identificação possui uma incerteza em sua medição, considerado neste cálculo como o seu desvio padrão, e o seu fator de abrangência (INMETRO, 2012).

TABELA 3.11 – Tempo do processo de identificação em computador portátil

Técnica	Câmera	Alvos	Tempo Médio por Quadro - TMQ(s)
Haar-like	Frontal	preto/amarelo	0,097064s±0,008963s @ 1σ
		preto/branco	0,097149s±0,002172s @ 1σ
	Traseira	preto/amarelo	0,11674s±0,0024414s @ 1σ
		preto/branco	0,12043s±0,0025908s @ 1σ
LBP	Frontal	preto/amarelo	0,038034s±0,0013426s @ 1σ
		preto/branco	0,038663s±0,001879s @ 1σ
	Traseira	preto/amarelo	0,042283s±0,0017432s @ 1σ
		preto/branco	0,042146s±0,0020712s @ 1σ

Dessa forma, utilizando os atributos Haar-like na análise dos alvos preto/amarelo com a câmera Frontal, o valor medido de TMQ tem 68,26% de probabilidade (i.e. fator de abrangência de  $1\sigma$ ) de estar dentro da faixa de valores de  $0,097064s \pm 0,008963s$  (Figura 3.35).

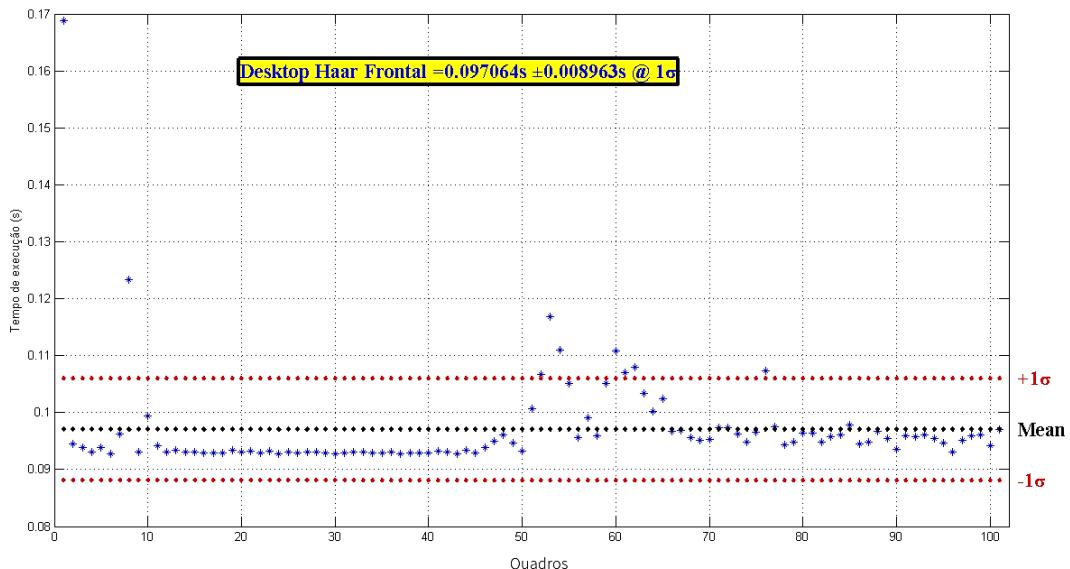


FIGURA 3.35 – Gráfico da incerteza da medição dos tempos do processo de identificação considerando os 100 quadros

Como resultado é possível verificar que o tempo de execução no processo de identificação utilizando os atributos LBP são bem menores que o tempo de execução dos atributos Haar-like. Em alguns casos (i.e. câmera traseira com alvos preto/branco), o tempo de execução utilizando os atributos LBP chegou a ser 35% do tempo comparado ao Haar-like.

Com os valores apresentados na coluna de Tempo Médio por Quadro (TMQ), em segundos, é possível estimar o tempo de processamento para a identificação de uma quantidade específica de quadros. Na Figura 3.36 é apresentado o tempo médio esperado de processamento para 200 (TM 200Q), 100 (TM 100Q) e 30 (TM 30Q) quadros.

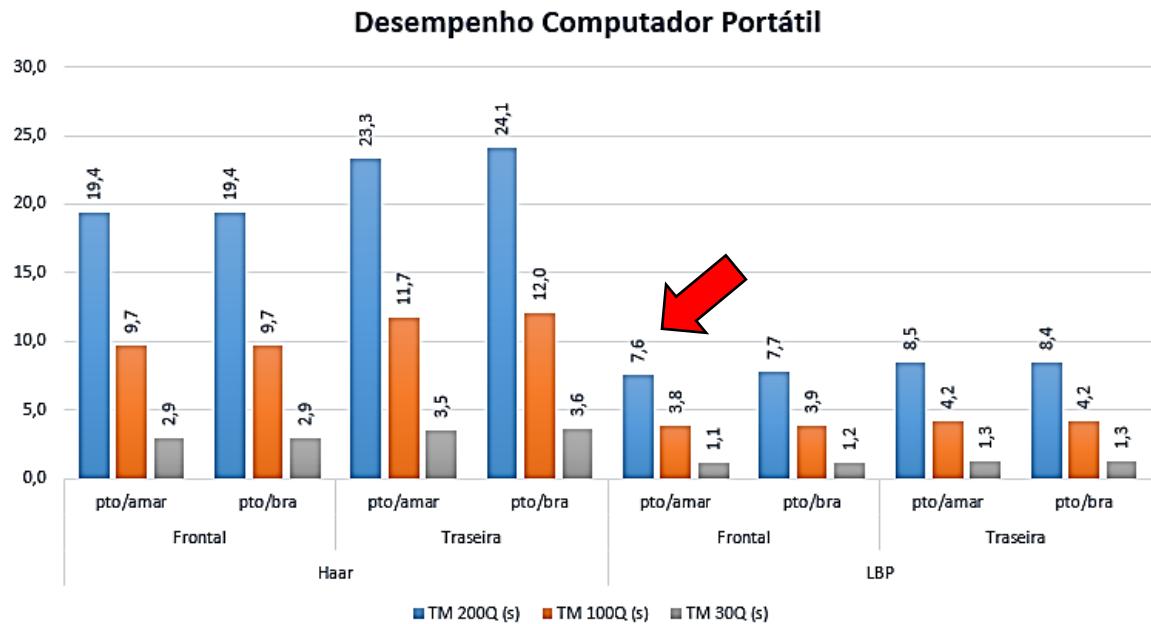


FIGURA 3.36 – Gráfico de desempenho do processo de identificação em um computador portátil

De acordo com os resultados apresentados na Figura 3.36, a execução do processo de identificação no computador portátil, não consegue atingir o tempo requerido para processamento em tempo real de imagens amostradas em 200 qps. O melhor desempenho obtido foi no processamento das imagens da câmera frontal utilizando os atributos LBP e alvos preto/amarelo, com duração de 7,6 segundos. O pior desempenho foi no processamento das imagens da câmera traseira pelos atributos Haar-like com alvos preto/branco, no qual o tempo de processamento foi de 24,1 segundos para os mesmos 200 quadros.

O desempenho apresentado no Raspberry Pi é consideravelmente pior em relação ao computador portátil. Esse resultado já era esperado, entretanto, é necessário, porém, considerar as diferenças de configuração entre os dois dispositivos. A Figura 3.37 apresenta a comparação do Tempo Médio por Quadro (TMQ) processado em um Computador Portátil e no Raspberry Pi. Os valores medidos dos 100 quadros para o Raspberry Pi são apresentados no Apêndice A.2.

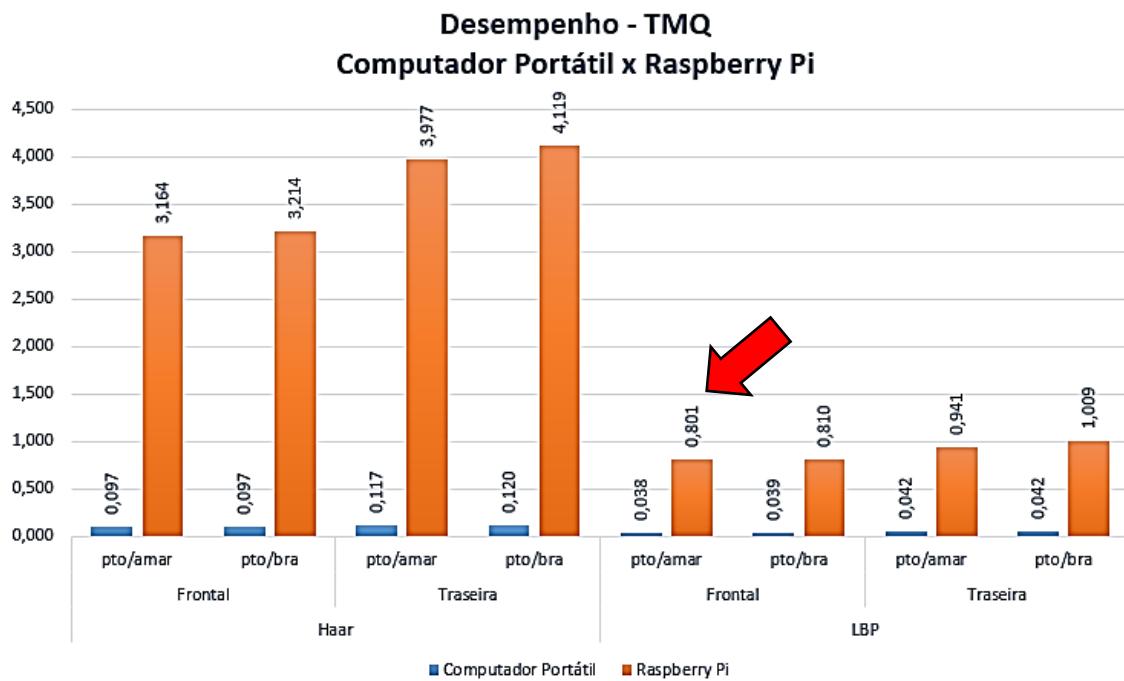


FIGURA 3.37 – Gráfico comparativa do desempenho entre um computador portátil e o Raspberry Pi

No Raspberry Pi, em relação ao seu tempo de processamento por quadro (TMQ), o melhor desempenho foi de 0,801 segundos. Assim como no computador portátil (Tabela 3.11), o tempo de processamento de identificação com os atributos LBP foi muito menor do que o obtido pelo Haar-like. No processo de identificação das imagens, o TMQ com atributos LBP foi aproximadamente 25% do TMQ com atributos Haar-like.

Na projeção dos valores de TMQ para TM 200Q, TM 100Q e TM 30Q (Figura 3.38), também é possível verificar os valores medidos nesta configuração também não satisfazem o requisito para a aplicação em tempo real. O TM 200Q de melhor desempenho no Raspberry Pi foi de 160,2 segundos (i.e. pouco menos de 3 minutos) para a análise dos quadros da câmera frontal, utilizando os atributos LBP com alvos nas cores preto/amarelo.

Os resultados comprovam a deficiência na utilização dessas técnicas no processo de rastreamento dos alvos em imagens em alta velocidade. Entretanto, deve ser considerado que as técnicas aplicadas neste trabalho possuem como finalidade a identificação dos alvos na carga, que é o primeiro passo para a automatização do rastreamento dos alvos na análise de sua trajetografia.

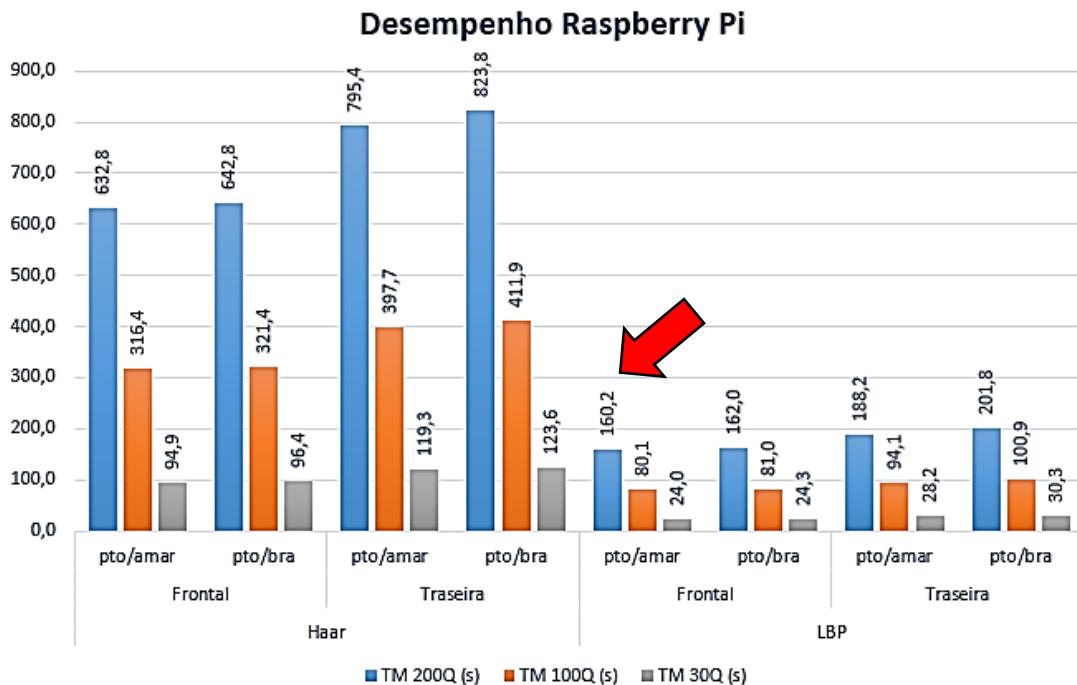


FIGURA 3.38 - Gráfico de desempenho do processo de identificação no Raspberry Pi

Portanto, os valores de tempo de identificação por quadro (TMQ) são mais importantes para o processo de validação. O TMQ indica em quanto tempo a ferramenta deverá executar a identificação dos alvos na primeira etapa da análise de sua trajetografia. Assim, um valor de 1 segundo de TMQ para o processamento de um quadro no Raspberry Pi, pode ser ainda ser considerado satisfatório, já que o sucesso desta aplicação deverá ser obtido muito tempo antes do lançamento efetivo da carga externa.

Uma possível solução de rastreamento dos alvos identificados neste trabalho foi apresentada no *50th International Telemetering Conference*, em outubro de 2014, na cidade de San Diego, nos Estados Unidos. No trabalho (KUSUMOTO, *et al.*, 2014), foi utilizada a técnica chamada Continuously Adaptive Mean Shift (*Camshift*) apresentada por BRADSKI (1998) cuja finalidade é o rastreamento de objetos em tempo real. O algoritmo aplica o processo de identificação dos alvos no primeiro quadro da sequência de vídeo e gera um vetor de retângulos com os alvos identificados. A posição de cada alvo identificado é utilizada como ponto inicial do processo de rastreamento dos alvos. A Figura 3.39 apresenta o rastreamento dos alvos, resultado do processo de identificação e de rastreamento.

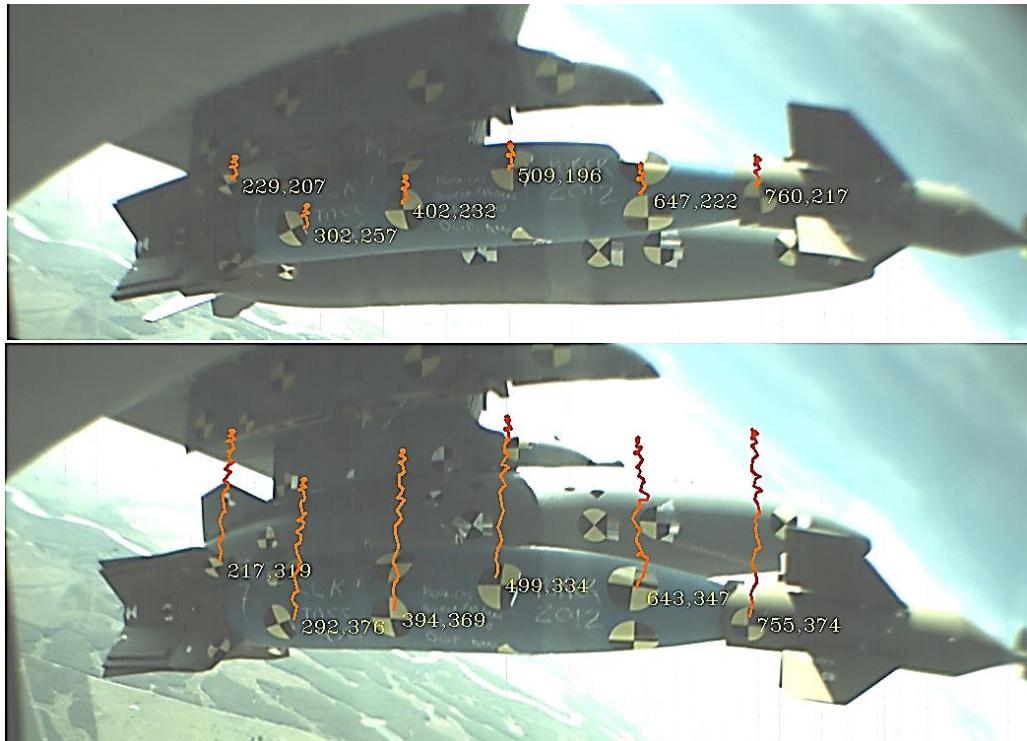


FIGURA 3.39 – Resultados obtidos no processo de rastreamento de alvos (KUSUMOTO, *et al*, 2014)

Os resultados obtidos são preliminares, mas promissores na aplicação da técnica Camshift no rastreamento dos alvos identificados em ensaios de separação de cargas externas.

## 4 Conclusão

Este trabalho apresenta a aplicação de duas técnicas da área de visão computacional para o reconhecimento de padrões na identificação de alvos em ensaios de separação de cargas externas. Com os resultados obtidos foi possível comprovar a utilização dessas técnicas em uma primeira etapa de um sistema automatizado de trajetografia de tempo real, que utiliza imagens com alta resolução e capturadas em alta velocidade. A identificação visual dos alvos na carga e a sua localização em relação às coordenadas da imagem é o primeiro passo para o rastreamento e posteriormente, para a reconstrução de sua trajetória.

Com o desenvolvimento do protótipo para validação das técnicas, foi possível verificar um bom desempenho das duas técnicas em relação às taxas de identificação, ao tempo de duração do processo de treinamento e ao tempo de duração do processo de identificação.

De maneira geral, ambos os atributos alcançaram altas taxas de identificação (i.e. acima de 87%) dos alvos nos experimentos realizados, tendo como base a métrica Sensibilidade. Esse valor é importante, pois a Sensibilidade leva em consideração os valores de FN em seu cálculo (Equação 3.1). Os FN representam os alvos que não foram identificados. Considerando a métrica Precisão, os resultados obtidos alcançaram boas taxas, mas também apresentaram taxas menores como no primeiro experimento (i.e. 63,90%). A métrica Precisão considera os valores de FP em sua fórmula (Equação 3.2). Entretanto, os FP não representam um obstáculo insolúvel. É possível aplicar técnicas para a confirmação dos alvos identificados, resultado em valores menores de FP.

Os atributos LBP apresentaram tempos muito menores de duração do processo de treinamento e identificação. Na etapa de treinamento dos atributos Haar-like, nos dois experimentos foram necessários mais de 1 hora nessa etapa. No processo de treinamento no primeiro experimento, os atributos LBP apresentaram aproximadamente a metade do tempo de duração e pouco mais de dois minutos no segundo experimento. No processo de identificação, os atributos LBP também se mostraram mais rápidos, chegando a aproximadamente 25% do tempo apresentado utilizando os atributos Haar-like.

É importante ressaltar que o processo de treinamento, apesar de parecer demorado, em alguns casos, esse tempo pode ser ainda maior como na utilização de milhares de imagens positivas e negativas. Com mais amostras, os classificadores são mais genéricos e podem alcançar bons resultados na análise em diferentes situações. Neste trabalho, foram utilizados

conjuntos com centenas de imagens positivas e negativas com resultados satisfatórios. Além disso, o processo de treinamento pode ser inserido na fase Preparação das campanhas de ensaios em voo.

O desempenho no processo de identificação pode ser maximizado com a utilização das GPU disponíveis no Raspberry Pi. No processo de treinamento, o desempenho alcançado pode ser melhor com utilização de um modelo de programação multi processamento como o OpenMP.

Para a finalidade específica deste trabalho, os resultados obtidos através da realização dos experimentos e da avaliação de desempenho comprovam a viabilidade da aplicação dos atributos Haar-like e LBP no processo de identificação de alvos em ensaios de separação de cargas externas.

Considerando que a quantidade de FP resultante do processo de identificação pode ser minimizado, os atributos LBP apresentaram os melhores resultados, especialmente, na análise dos alvos nas cores preto e branco. Além disso, os tempos de duração dos processos de treinamento e identificação também foram menores utilizando os atributos LBP, o que melhora a eficiência na sua utilização. Dessa forma, é possível afirmar que os objetivos definidos nesse trabalho foram alcançados.

Este trabalho contribuiu com a demonstração da aplicação de técnicas de visão computacional na área de ensaios em voo, especificamente, na área de ensaios de separação de cargas externas. Dessa forma, novas aplicações na área aeroespacial podem ser desenvolvidas utilizando as imagens como fonte de dados. Assim, os trabalhos futuros devem incluir:

1. A aplicação das técnicas de identificação apresentadas neste trabalho utilizando outros tipos de alvos, com formatos diversos e cores diferentes;
2. A aplicação de técnicas de RNA para a confirmação dos alvos que auxiliaria na automatização do processo de identificação, maximizando o resultado final;
3. A localização exata dos alvos a nível de pixel. Para isso, técnicas de calibração devem ser realizadas com a finalidade de se obter as coordenadas com a precisão necessária.
4. A utilização de câmeras de vídeo com capacidade de captura em alta resolução e em alta velocidade que proporcione a possibilidade de se embarcar os códigos necessários para o processo de identificação dos alvos ou então, forneça o acesso direto às imagens capturadas pela câmera para processamento em dispositivo embarcado; e

5. A utilização de outros dispositivos embarcados, com melhores configurações de processamento e de memória para a verificação de desempenho.

## Referências

- ADVISORY GROUP FOR AEROSPACE RESEARCH AND DEVELOPMENT. **Store separation flight testing.** Neuilly sur Seine, 1986. (AGARD Flight Test Technique Series on Store Separation Flight Testing, v. 5).
- BAY, H.; TUYTELAARS, T.; VAN GOOL, L. SURF: Speeded Up Robust Features. EUROPEAN CONFERENCE ON COMPUTER VISION, 9., 2006, Graz. **Proceedings...** 2006. 404-417.
- BIANCHI, M. F. **Extração de características de imagens de faces humanas através de wavelets, PCA e IMPCA.** 2006. 137 f. Dissertação (Mestrado em Engenharia Elétrica) - Universidade de São Paulo, São Carlos.
- BIDINOTTO, J. H. **Proposta conceitual de excitador de flutter alternativo para ensaios em vôo.** 2007. 91 f. Dissertação (Mestrado em Engenharia Mecânica) - Universidade de São Paulo, São Carlos.
- BRADSKI, G. R. Computer vision face tracking as a component of a perceptual user interface. In: IEEE WORKSHOP ON APPLICATIONS OF COMPUTER VISION, 4., 1998, Princeton. **Proceedings...** Piscataway: IEEE, 1998. p. 214-219.
- BRASIL. Ministério da Defesa. Comando da Aeronáutica. **DCA 1-1: Doutrina Básica da Força Aérea Brasileira.** Brasília, DF, 2012.
- BRASIL. Ministério da Defesa. Comando da Aeronáutica. Departamento de Ciência e Tecnologia Aeroespacial. **Regimento Interno do Instituto de Pesquisas e Ensaios em Voo.** São José dos Campos, 2013.
- CENKO, A. Lessons learned in 30 years of store separation testing. In: AIAA AEROSPACE SCIENCES MEETING INCLUDING THE NEW HORIZONS FORUM AND AEROSPACE EXPOSITION, 47., 2009, Orlando. **Proceedings...** Reston: AIAA, 2009.
- CONCI, A.; AZEVEDO, E.; LETA, F. R. **Computação gráfica:** teoria e prática. Rio de Janeiro: Elsevier, 2008. v. 2.
- CRUZ, J. E. C.; SHIGUEMORI, E. H.; GUIMARÃES, L. N. F. Comparação entre HOG+SVM e Haar-like em cascata para a detecção de campos de futebol em imagens aéreas e orbitais. In: SIMPÓSIO BRASILEIRO DE SENSORIAMENTO REMOTO, 16., 2013, Foz do Iguaçu. **Anais...** São José dos Campos: INPE, 2013. p. 8154-8161.
- DAVIS, R. E.; FOOTE, F. C. **Surveying:** theory and practice. New York: McGraw-Hill, 1953.
- DENIHAN, S. G. **The benefits and risks associated with use of the wind tunnel in safe separation flight test.** 2003. 74 p. Thesis (M. Sc. in Aviation Systems) - University of Tennessee, Knoxville.

**DEPARTAMENTO DE CIÊNCIA E TECNOLOGIA AEROESPACIAL. FAB realiza lançamento de bombas guiadas a laser.** São José dos Campos, 2012. Disponível em: <<http://www.fab.mil.br/noticias/mostra/10803/>>. Acesso em: 24 jan. 2014.

FAWCETT, T. An introduction to ROC analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, June 2006.

FOLLADOR, R. D. C. **Análise modal operacional aeroelástica aplicada em ensaios em voo a partir de excitação por turbulência contínua.** 2009. 101 f. Dissertação (Mestrado Profissional em Engenharia Aeroespacial) - Instituto Tecnológico de Aeronáutica, São José dos Campos.

GONZALEZ, R. C.; WOODS, R. E. **Processamento digital de imagens.** 3. ed. São Paulo: Pearson Prentice Hall, 2010.

HALLAMASEK, K. et al. Comparative analysis of H.264 and Motion-Jpeg2000 compression for video telemetry. In: THE EUROPEAN SOCIETY OF TELEMETRY (Org.). **etc 2012: Conference Proceedings... Gernlinden:** BoD, 2012. p. 167-174.

HE, D.; WANG, L. Texture unit, texture spectrum, and texture analysis. **IEEE Transactions on Geoscience and Remote Sensing**, v. 28, n. 4, p. 509-512, July 1990.

HUMMEL, G. et al. Prototyping and training of computer vision algorithms in a synthetic UAV mission test bed. In: AEROSPACE SCIENCES MEETING, 52., 2014, Maryland. **Proceedings...** Reston: AIAA, 2014. (AIAA 2014-1322).

INMETRO. **Vocabulário Internacional de Metrologia:** Conceitos fundamentais e gerais e termos associados (VIM 2012). Duque de Caxias, RJ : INMETRO, 2012. 94 p.

INSTITUTO DE PESQUISAS E ENSAIOS EM VOO. **Programa de Segurança de Voo em Ensaios (PSVE).** Revisão C. São José dos Campos: IPEV/SIPAA, 1999.

INTERNATIONAL CIVIL AVIATION ORGANIZATION. **Model Aircraft Accident and Incident Investigation (AIG) Regulations.** 1. ed. [S.l: s.n.], 2013.

KO, B.; KWAK, S. Survey of computer vision-based natural disaster warning systems. **Optical Engineering**, v. 51, n. 7, 2012. Disponível em: <<http://dx.doi.org/10.1117/1.OE.51.7.070901>>. Acesso em: 24 nov. 2014.

KUSUMOTO, A. Y. et al. Track targets identification in store separation tests using digital image processing techniques. In: EUROPEAN TELEMETRY AND TEST CONFERENCE, 34., 2014, Nuremberg. **Proceedings...** Wunstorf: AMA Service GmbH, 2014. p. 72-76.

KUSUMOTO, A. Y. et al. Tracking track targets in external store separation using computer vision. In: INTERNATIONAL TELEMETRY CONFERENCE, 2014, San Diego. **Proceedings...** [S.l: s.n.], 2014.

LEITE, N. P. O. **Sistema de trajetografia GPS diferencial/inercial.** 1997. 200 f. Dissertação (Mestrado em Engenharia Eletrônica e Computação) - Instituto Tecnológico de Aeronáutica, São José dos Campos.

LEITE, N. P. O.; VASCONCELOS, L. E. G.; KUSUMOTO, A. Y. Fast on-board tracking system for external stores separation. In: ANNUAL INTERNATIONAL TELEMETERING CONFERENCE, 49., 2013, Las Vegas. **Proceedings...** [S.l: s.n.], 2013. p. 1088 -1097.

LIAO, S. et al. **Learning multi-scale block local binary patterns for face recognition.** Seoul: Springer, 2007. p. 828–837.

LOWE, D. G. Distinctive image features from scale-invariant keypoints. **International Journal of Computer Vision**, v. 60, n. 2, p. 91-110, Nov. 2004.

MIKROTRON. **Overview High-Speed Recording Cameras.** [S.l], 2012. Disponível em: <<http://www.mikrotron.de/en/high-speed-camera-solutions/high-speed-recording-cameras/ueberblick.html>>. Acesso em: 30 out. 2014.

OJALA, T.; PIETIKAINEN, M.; HARWOOD, D. A Comparative study of texture measures with classification based on feature distributions. **Pattern Recognition**, v. 29, p. 51-59, 1996. OPENCV DEV TEAM. **nonfree. Non-free functionality.** OpenCV 2.4.8.0 documentation. [S.l], 2011-2013. Disponível em:

<<http://docs.opencv.org/modules/nonfree/doc/nonfree.html>>. Acesso em: 15 fev. 2014.

OPENCV DEV TEAM. **Opencv documentation.** [S.l], 2011-2014. Disponível em: <<http://docs.opencv.org/>>. Acesso em: 04 abr. 2014.

PAPAGEORGIOU, C. P.; OREN, ; POGGIO, T. A general framework for object detection. In: INTERNATIONAL CONFERENCE ON COMPUTER VISION, 6., 1998, Bombay. **Proceedings...** Piscataway: IEEE, 1998. p. 555-562.

RASPBERRY PI FOUNDATION. **Homepage.** Cambridgeshire, 2014. Disponível em: <<https://www.raspberrypi.org/>>. Acesso em: 22 mar. 2014.

SHIGUEMORI, H.; MARTINS, M. P.; MONTEIRO, M. V. T. **Landmarks recognition for autonomous aerial navigation by neural networks and gabor transform.** San José: SPIE Digital Library, 2007.

SOUZA, L. B. D. R. **SALEV - Sistema de Automatização do Laboratório de Ensaios em Voo.** 2005. 169 f. Dissertação (Mestrado em Engenharia Eletrônica e Computação) - Instituto Tecnológico de Aeronáutica, São José dos Campos.

SPAHR, H. R. Theoretical store separation analyses of a prototype store. **Journal of Aircraft**, v. 12, n. 10, p. 807-811, Oct. 1975.

SPIE; IS&T. **Journal of Electronic Imaging Special Sections – Video Surveillance and Transportation Imaging Applications.** [S.l.]: SPIE Digital Library, 2013. Disponivel em: <<http://electronicimaging.spiedigitallibrary.org/issue.aspx?journalid=94&issueid=927109>>. Acesso em: 23 Nov 2014.

STOLIKER, F. N. **Introduction to flight test engineering.** Neuilly sur Seine: AGARD, 1995. (AGARD Flight Test Techniques Series, v. 14).

SZELISKI, R. **Computer vision: algorithms and application.** London: Springer, 2011.

TELEMETRY GROUP. **Telemetry Standards (Part 1), IRIG Standard 106-13 Chapter 10.** New Mexico: Range Commanders Council, 2013.

THE GIMP TEAM. **GNU Image Manipulation Program.** [S.l.], 2015. Disponível em: <<http://www.gimp.org/>>. Acesso em: 23 Mar. 2013.

UNITED STATES. Department of Defense. **Aircraft/Stores compatibility:** systems engineering data requirements and test procedures. Wright-Patterson AFB, OH, 1998. (MIL-HDBK-1763).

UNITED STATES. Department of Defense. **MIL-STD-1289D:2003:** airborne stores, ground fit and compatibility requirements. Huntsville, 2003.

VASCONCELOS, L. E. G. D. **Calibração anemométrica de aeronaves usando processamento de imagens digitais.** 2011. 121 f. Dissertação (Mestrado em Ciências em Ciência e Tecnologia da Computação) - Universidade Federal de Itajubá.

VIANA, M. V. P. **Ensaios em voo para certificação de integração de cargas externas em aeronaves militares.** 2011. 205 f. Dissertação (Mestrado em Engenharia Aeroespacial) - Instituto Tecnológico de Aeronáutica, São José dos Campos.

VIOLA, P.; JONES, M. Rapid object detection using a boosted cascade of simple features. In: IEEE COMPUTER VISION AND PATTERN RECOGNITION, 2001, Kauai. **Proceedings...** Piscataway: IEEE, 2001. v. 1.

WANG, L.; HE, D.-C. Texture classification using texture spectrum. **Pattern Recognition**, v. 23, n. 8, p. 905–910, 1990.

WILLIS, S.; LANGER, B. A dual compression ethernet camera solution for airborne applications. In: ANNUAL INTERNATIONAL TELEMETRY CONFERENCE, 34., 2014, San Diego. **Proceedings...** Wunstorf: AMA Service GmbH, 2014. p. 77-81.

WORLD WIDE WEB CONSORTIUM. **Extensible Markup Language (XML).** Cambridge, 2014. Disponível em: <<http://www.w3.org/XML/>>. Acesso em: 15 fev. 2014.

## Apêndice A – Medições de Tempo do Processo de Identificação

### A.1 Medição de 100 quadros em Computador Portátil

#	Haar				LBP			
	Frontal		Traseira		Frontal		Traseira	
	pto/amar (s)	pto/bco (s)	pto/amar (s)	pto/bco (s)	pto/amar (s)	pto/bco (s)	pto/amar (s)	pto/bco (s)
0	0,169	0,100	0,116	0,121	0,038	0,038	0,043	0,042
1	0,094	0,098	0,120	0,121	0,038	0,038	0,041	0,042
2	0,094	0,099	0,139	0,121	0,039	0,038	0,042	0,042
3	0,093	0,098	0,117	0,121	0,038	0,038	0,042	0,043
4	0,094	0,100	0,116	0,121	0,038	0,038	0,043	0,042
5	0,093	0,100	0,117	0,121	0,051	0,039	0,042	0,043
6	0,096	0,103	0,116	0,145	0,038	0,040	0,042	0,042
7	0,123	0,098	0,118	0,121	0,038	0,038	0,044	0,042
8	0,093	0,098	0,116	0,121	0,038	0,039	0,042	0,062
9	0,099	0,102	0,117	0,121	0,038	0,056	0,042	0,041
10	0,094	0,099	0,116	0,121	0,038	0,038	0,059	0,042
11	0,093	0,099	0,117	0,121	0,038	0,038	0,042	0,042
12	0,093	0,100	0,116	0,121	0,038	0,038	0,042	0,042
13	0,093	0,098	0,118	0,121	0,038	0,038	0,042	0,041
14	0,093	0,098	0,116	0,121	0,038	0,038	0,042	0,041
15	0,093	0,097	0,117	0,120	0,038	0,038	0,042	0,042
16	0,093	0,100	0,116	0,121	0,038	0,038	0,042	0,042
17	0,093	0,100	0,117	0,121	0,038	0,038	0,042	0,042
18	0,093	0,098	0,116	0,120	0,038	0,038	0,042	0,042
19	0,093	0,099	0,118	0,121	0,038	0,038	0,042	0,042
20	0,093	0,098	0,116	0,120	0,038	0,038	0,041	0,042
21	0,093	0,097	0,117	0,120	0,038	0,038	0,042	0,042
22	0,093	0,097	0,116	0,120	0,038	0,038	0,042	0,042
23	0,093	0,099	0,117	0,120	0,038	0,038	0,041	0,042
24	0,093	0,098	0,116	0,120	0,038	0,038	0,041	0,042
25	0,093	0,097	0,117	0,121	0,038	0,039	0,042	0,042
26	0,093	0,099	0,116	0,121	0,038	0,038	0,042	0,042
27	0,093	0,099	0,117	0,121	0,038	0,038	0,042	0,042
28	0,093	0,098	0,116	0,121	0,038	0,038	0,042	0,042
29	0,093	0,098	0,117	0,121	0,038	0,038	0,042	0,042
30	0,093	0,098	0,116	0,121	0,038	0,038	0,042	0,041
31	0,093	0,099	0,117	0,121	0,038	0,038	0,041	0,042
32	0,093	0,099	0,116	0,121	0,038	0,038	0,042	0,042

33	0,093	0,096	0,117	0,121	0,038	0,038	0,042	0,042
34	0,093	0,097	0,116	0,121	0,038	0,038	0,042	0,042
35	0,093	0,097	0,118	0,120	0,038	0,038	0,042	0,042
36	0,093	0,099	0,116	0,121	0,038	0,039	0,042	0,042
37	0,093	0,097	0,117	0,120	0,038	0,038	0,042	0,042
38	0,093	0,096	0,116	0,120	0,038	0,038	0,042	0,042
39	0,093	0,098	0,118	0,121	0,038	0,038	0,042	0,042
40	0,093	0,100	0,116	0,120	0,038	0,038	0,042	0,042
41	0,093	0,097	0,117	0,120	0,038	0,038	0,042	0,042
42	0,093	0,097	0,116	0,121	0,038	0,038	0,041	0,042
43	0,093	0,098	0,117	0,121	0,038	0,038	0,042	0,042
44	0,093	0,098	0,116	0,120	0,038	0,038	0,042	0,042
45	0,094	0,095	0,117	0,121	0,038	0,038	0,043	0,042
46	0,095	0,099	0,116	0,120	0,038	0,038	0,042	0,042
47	0,096	0,099	0,117	0,121	0,038	0,038	0,042	0,042
48	0,095	0,099	0,116	0,121	0,038	0,038	0,041	0,042
49	0,093	0,100	0,117	0,120	0,038	0,038	0,042	0,042
50	0,101	0,104	0,116	0,121	0,038	0,038	0,042	0,043
51	0,107	0,105	0,118	0,121	0,038	0,038	0,042	0,042
52	0,117	0,099	0,116	0,121	0,038	0,038	0,042	0,042
53	0,111	0,095	0,117	0,120	0,038	0,038	0,041	0,042
54	0,105	0,095	0,116	0,121	0,038	0,038	0,042	0,042
55	0,096	0,096	0,117	0,120	0,038	0,038	0,042	0,042
56	0,099	0,095	0,116	0,121	0,038	0,038	0,042	0,042
57	0,096	0,095	0,118	0,121	0,038	0,038	0,042	0,042
58	0,105	0,095	0,116	0,120	0,038	0,038	0,042	0,042
59	0,111	0,095	0,118	0,121	0,038	0,038	0,042	0,042
60	0,107	0,095	0,117	0,121	0,038	0,039	0,042	0,042
61	0,108	0,095	0,117	0,121	0,038	0,038	0,042	0,042
62	0,103	0,095	0,116	0,120	0,038	0,038	0,043	0,042
63	0,100	0,095	0,118	0,121	0,038	0,038	0,042	0,042
64	0,102	0,096	0,117	0,120	0,038	0,039	0,042	0,042
65	0,097	0,095	0,120	0,120	0,038	0,038	0,042	0,042
66	0,097	0,095	0,116	0,120	0,038	0,038	0,043	0,042
67	0,096	0,095	0,117	0,120	0,038	0,038	0,042	0,042
68	0,095	0,095	0,117	0,120	0,038	0,038	0,043	0,042
69	0,095	0,095	0,118	0,120	0,038	0,038	0,042	0,042
70	0,097	0,095	0,117	0,120	0,038	0,038	0,043	0,042
71	0,097	0,095	0,117	0,120	0,038	0,039	0,042	0,042
72	0,096	0,095	0,116	0,120	0,038	0,038	0,043	0,042
73	0,095	0,095	0,117	0,120	0,038	0,039	0,042	0,042
74	0,097	0,095	0,116	0,119	0,038	0,038	0,043	0,042
75	0,107	0,095	0,117	0,119	0,038	0,040	0,042	0,042
76	0,097	0,095	0,116	0,120	0,038	0,039	0,043	0,042
77	0,094	0,095	0,117	0,120	0,038	0,040	0,042	0,042

78	0,095	0,095	0,116	0,120	0,038	0,039	0,043	0,042
79	0,096	0,095	0,117	0,119	0,038	0,040	0,042	0,042
80	0,096	0,095	0,115	0,119	0,038	0,039	0,043	0,043
81	0,095	0,095	0,116	0,119	0,038	0,040	0,043	0,042
82	0,096	0,095	0,115	0,119	0,038	0,039	0,043	0,042
83	0,096	0,095	0,116	0,119	0,038	0,039	0,043	0,043
84	0,098	0,095	0,115	0,119	0,038	0,039	0,043	0,043
85	0,095	0,095	0,116	0,119	0,038	0,039	0,042	0,043
86	0,095	0,095	0,115	0,119	0,038	0,039	0,042	0,043
87	0,097	0,095	0,116	0,119	0,038	0,039	0,043	0,042
88	0,095	0,096	0,115	0,119	0,038	0,039	0,043	0,043
89	0,094	0,096	0,116	0,119	0,038	0,039	0,042	0,043
90	0,096	0,096	0,115	0,120	0,038	0,039	0,042	0,042
91	0,096	0,096	0,116	0,119	0,038	0,039	0,042	0,042
92	0,096	0,097	0,115	0,119	0,038	0,040	0,042	0,042
93	0,095	0,098	0,117	0,119	0,038	0,040	0,042	0,042
94	0,095	0,096	0,115	0,119	0,038	0,040	0,042	0,042
95	0,093	0,096	0,116	0,119	0,038	0,040	0,042	0,042
96	0,095	0,096	0,115	0,119	0,038	0,041	0,042	0,042
97	0,096	0,096	0,116	0,119	0,038	0,040	0,042	0,042
98	0,096	0,096	0,115	0,119	0,037	0,041	0,042	0,042
99	0,094	0,096	0,117	0,119	0,038	0,040	0,042	0,042
<b>TMQ</b>	<b>0,097</b>	<b>0,097</b>	<b>0,117</b>	<b>0,120</b>	<b>0,038</b>	<b>0,039</b>	<b>0,042</b>	<b>0,042</b>

## A.2 Medição de 100 quadros no Raspberry

#	Haar				LBP			
	Frontal		Traseira		Frontal		Traseira	
	pto/amar (s)	pto/bco (s)	pto/amar (s)	pto/bco (s)	pto/amar (s)	pto/bco (s)	pto/amar (s)	pto/bco (s)
0	3,162	3,254	3,957	4,111	0,809	0,824	0,948	1,011
1	3,161	3,253	3,968	4,144	0,808	0,808	0,936	0,997
2	3,184	3,251	3,984	4,133	0,805	0,806	0,942	0,998
3	3,168	3,243	3,956	4,127	0,796	0,812	0,931	1,012
4	3,201	3,260	3,956	4,130	0,802	0,818	0,941	1,006
5	3,165	3,254	3,970	4,129	0,804	0,815	0,936	1,014
6	3,186	3,249	3,976	4,133	0,810	0,816	0,940	1,006
7	3,179	3,234	3,964	4,114	0,809	0,805	0,939	1,007
8	3,190	3,239	3,946	4,108	0,801	0,813	0,943	1,007
9	3,167	3,254	3,968	4,115	0,800	0,814	0,938	1,004
10	3,162	3,235	3,986	4,129	0,804	0,820	0,939	1,011
11	3,179	3,242	3,944	4,132	0,808	0,811	0,933	0,993
12	3,184	3,248	3,994	4,139	0,805	0,803	0,939	1,004
13	3,166	3,235	3,971	4,132	0,798	0,804	0,940	0,996

14	3,183	3,249	3,984	4,145	0,796	0,815	0,940	0,997
15	3,171	3,231	3,985	4,138	0,812	0,816	0,935	1,006
16	3,171	3,250	3,965	4,140	0,806	0,811	0,943	1,006
17	3,173	3,231	3,968	4,152	0,807	0,806	0,938	1,008
18	3,161	3,235	3,977	4,128	0,808	0,805	0,936	1,003
19	3,182	3,214	3,980	4,146	0,799	0,812	0,931	1,006
20	3,196	3,224	3,978	4,125	0,815	0,813	0,931	1,008
21	3,158	3,231	3,948	4,140	0,809	0,811	0,930	1,004
22	3,179	3,225	3,978	4,113	0,805	0,801	0,942	1,005
23	3,159	3,222	3,972	4,119	0,803	0,802	0,931	1,002
24	3,177	3,217	3,964	4,102	0,799	0,813	0,945	1,004
25	3,177	3,214	3,973	4,131	0,812	0,814	0,936	1,003
26	3,166	3,227	3,990	4,132	0,803	0,809	0,939	1,002
27	3,171	3,193	3,955	4,125	0,813	0,804	0,928	0,999
28	3,181	3,219	3,983	4,152	0,806	0,804	0,943	1,016
29	3,167	3,218	3,961	4,130	0,798	0,814	0,927	1,006
30	3,176	3,211	3,986	4,134	0,812	0,814	0,937	1,002
31	3,164	3,209	3,970	4,146	0,804	0,806	0,940	1,008
32	3,170	3,200	3,970	4,134	0,804	0,798	0,948	1,018
33	3,161	3,192	3,961	4,108	0,804	0,802	0,930	1,008
34	3,163	3,209	3,978	4,137	0,802	0,804	0,940	1,002
35	3,147	3,199	3,965	4,081	0,812	0,812	0,929	0,997
36	3,161	3,214	3,974	4,108	0,805	0,802	0,942	1,003
37	3,159	3,204	3,979	4,118	0,807	0,799	0,933	0,996
38	3,181	3,206	3,938	4,132	0,805	0,797	0,936	0,997
39	3,159	3,201	3,976	4,148	0,798	0,801	0,934	1,008
40	3,168	3,187	3,986	4,128	0,807	0,803	0,944	1,006
41	3,179	3,204	3,960	4,140	0,808	0,788	0,932	1,000
42	3,175	3,204	3,979	4,146	0,809	0,787	0,935	1,007
43	3,197	3,189	3,958	4,138	0,803	0,792	0,922	1,003
44	3,185	3,187	3,990	4,114	0,799	0,801	0,937	1,006
45	3,183	3,172	3,970	4,130	0,811	0,809	0,936	1,006
46	3,194	3,184	3,988	4,124	0,803	0,797	0,935	1,009
47	3,172	3,147	3,976	4,127	0,799	0,793	0,934	1,004
48	3,170	3,173	3,985	4,135	0,806	0,793	0,937	1,003
49	3,173	3,175	3,998	4,138	0,799	0,798	0,929	1,011
50	3,181	3,185	3,994	4,149	0,813	0,804	0,928	0,998
51	3,167	3,167	4,007	4,125	0,808	0,794	0,932	1,005
52	3,176	3,179	3,975	4,161	0,793	0,792	0,933	1,012
53	3,162	3,169	3,959	4,134	0,803	0,797	0,936	1,004
54	3,171	3,202	3,974	4,144	0,798	0,804	0,942	1,007
55	3,173	3,173	3,953	4,131	0,817	0,803	0,937	1,005
56	3,167	3,188	3,961	4,131	0,812	0,794	0,942	1,010
57	3,161	3,177	3,960	4,141	0,800	0,791	0,940	1,003
58	3,150	3,186	3,990	4,133	0,800	0,801	0,934	1,008

59	3,167	3,189	4,015	4,134	0,796	0,803	0,938	1,004
60	3,171	3,197	4,020	4,162	0,806	0,806	0,939	1,002
61	3,173	3,194	3,984	4,112	0,808	0,794	0,953	1,007
62	3,185	3,219	3,997	4,112	0,793	0,793	0,944	1,005
63	3,162	3,170	4,005	4,110	0,804	0,804	0,943	0,997
64	3,180	3,213	4,017	4,142	0,797	0,801	0,948	1,020
65	3,161	3,192	4,003	4,137	0,813	0,802	0,941	1,008
66	3,170	3,196	4,007	4,139	0,810	0,796	0,940	1,008
67	3,172	3,207	4,011	4,102	0,797	0,794	0,934	1,011
68	3,154	3,208	4,015	4,136	0,801	0,800	0,945	1,018
69	3,142	3,189	3,983	4,124	0,803	0,803	0,941	1,010
70	3,174	3,196	4,004	4,109	0,811	0,806	0,946	1,015
71	3,171	3,186	4,006	4,122	0,796	0,804	0,948	1,016
72	3,160	3,212	3,987	4,104	0,787	0,802	0,951	1,014
73	3,170	3,207	3,944	4,103	0,790	0,809	0,948	1,010
74	3,152	3,200	3,999	4,113	0,794	0,822	0,945	1,009
75	3,151	3,187	3,988	4,082	0,800	0,822	0,937	1,023
76	3,144	3,195	3,984	4,108	0,789	0,810	0,944	1,018
77	3,151	3,187	3,996	4,094	0,784	0,817	0,950	1,020
78	3,171	3,205	4,005	4,105	0,783	0,824	0,952	1,020
79	3,166	3,218	3,981	4,097	0,791	0,823	0,955	1,022
80	3,139	3,204	3,978	4,094	0,800	0,828	0,962	1,025
81	3,115	3,195	3,968	4,078	0,782	0,818	0,952	1,018
82	3,150	3,209	3,957	4,115	0,782	0,818	0,943	1,016
83	3,159	3,207	3,957	4,101	0,798	0,829	0,951	1,025
84	3,152	3,213	3,957	4,086	0,792	0,824	0,954	1,030
85	3,148	3,205	3,950	4,080	0,800	0,832	0,943	1,025
86	3,118	3,219	3,950	4,093	0,782	0,818	0,957	1,017
87	3,137	3,213	3,952	4,069	0,783	0,819	0,956	1,014
88	3,152	3,248	3,929	4,098	0,799	0,831	0,957	1,020
89	3,130	3,249	3,946	4,095	0,796	0,829	0,956	1,014
90	3,153	3,259	3,941	4,097	0,793	0,836	0,953	1,019
91	3,138	3,247	3,940	4,066	0,784	0,822	0,940	1,020
92	3,131	3,277	3,913	4,111	0,786	0,825	0,956	1,036
93	3,137	3,270	3,922	4,066	0,806	0,826	0,941	1,015
94	3,129	3,251	3,949	4,093	0,799	0,837	0,951	1,019
95	3,133	3,247	4,166	4,083	0,799	0,842	0,952	1,017
96	3,150	3,284	4,072	4,082	0,785	0,839	0,949	1,011
97	3,128	3,248	3,955	4,070	0,803	0,835	0,946	1,017
98	3,129	3,228	3,962	4,077	0,792	0,831	0,950	1,010
99	3,139	3,225	4,002	4,079	0,791	0,838	0,934	0,999
<b>TMQ</b>	<b>3,164</b>	<b>3,214</b>	<b>3,977</b>	<b>4,119</b>	<b>0,801</b>	<b>0,810</b>	<b>0,941</b>	<b>1,009</b>

## FOLHA DE REGISTRO DO DOCUMENTO

1. CLASSIFICAÇÃO/TIPO  DM	2. DATA  13 de Julho de 2015	3. REGISTRO Nº  DCTA/ITA/DM-033/2015	4. N° DE PÁGINAS  107
5. TÍTULO E SUBTÍTULO:  <b>IDENTIFICAÇÃO DE ALVOS EM ENSAIOS DE SEPARAÇÃO DE CARGA UTILIZANDO VISÃO COMPUTACIONAL</b>			
6. AUTOR(ES):  <b>ANDRÉ YOSHIMI KUSUMOTO</b>			
7. INSTITUIÇÃO(ÕES)/ÓRGÃO(S) INTERNO(S)/DIVISÃO(ÕES):  <b>Instituto Tecnológico de Aeronáutica - ITA</b>			
8. PALAVRAS-CHAVE SUGERIDAS PELO AUTOR:  1. Ensaios em Voo. 2. Cargas Externas. 3. Visão Computacional. 4. Identificação de alvos. 5. Haar-like. 6. LBP.			
9. PALAVRAS-CHAVE RESULTANTES DE INDEXAÇÃO:  Visão por computadores; Reconhecimento de alvo; Separação de cargas externas; Processamento de imagens; Ensaios em voo; Engenharia eletronica.			
10. APRESENTAÇÃO: <span style="float: right;"><b>X Nacional    Internacional</b></span>  ITA, São José dos Campos. Curso de Mestrado. Programa de Pós-Graduação em Ciências e Tecnologias Espaciais. Área de Sistemas Espaciais, Ensaios e Lançamentos. Orientador: Prof. Dr. Rogério Pirk; coorientador: Dr. Nelson Paiva Oliveira Leite. Defesa em 02/07/2015. Publicada em 2015.			
11. RESUMO:  O presente trabalho apresenta a aplicação de técnicas de visão computacional na identificação de alvos (i.e. marcações) na superfície de cargas em campanhas de ensaios de separação de cargas externas. A identificação dos alvos na superfície da carga alijada é o primeiro passo para o seu rastreamento e consequentemente, para a análise de sua trajetografia. Foram utilizados os atributos Haar-like e MB-LBP para composição dos classificadores que realizaram a identificação dos alvos nas imagens capturadas em alta resolução (i.e. 720p ou mais) e em alta velocidade (i.e. 200 quadros por segundo ou mais). Em ambos os casos, foi necessária realização de duas etapas, a saber: treinamento dos classificadores e identificação dos alvos na imagem. Como premissa básica, todas as ferramentas utilizadas foram de livre acesso e, portanto, não possuem restrições de uso. As bibliotecas do OpenCV foram utilizadas para a manipulação das imagens e para a aplicação das técnicas escolhidas. Para a validação da ferramenta desenvolvida, foram analisadas sequências de imagens de um voo de ensaio de separação de carga capturadas em uma campanha de desenvolvimento de uma bomba guiada a laser e de ensaios de separação em solo realizadas no IPEV. O tempo de execução do processo de identificação dos alvos em um computador portátil foi comparado ao tempo de execução do mesmo processo em um dispositivo que pode ser embarcado na aeronave, com a finalidade de se verificar o desempenho da ferramenta. Os resultados obtidos nos experimentos se mostraram satisfatórios e puderam comprovar a aplicação das técnicas na identificação dos alvos em ensaios de separação de carga.			
12. GRAU DE SIGILO:  <span style="margin-right: 10px;"><input checked="" type="checkbox"/> (X) OSTENSIVO</span> <span><input type="checkbox"/> ( ) RESERVADO</span> <span><input type="checkbox"/> ( ) SECRETO</span>			